



石油生产预测的生物启发的模型：结合基因调节的优化和径向基函数网络

bao liu¹ · yuqing liang¹ · zirun zhu¹ · lei gao²

收到：2023年12月25日 /接受：2025年4月10日©
Crown 2025

抽象的

石油生产预测在石油领域开发、部署和生产计划的过程中起着至关重要的作用，尤其是在储层管理方面，但其准确性通常不令人满意。为了解决这个问题，我们提出了一个以石油生产预测的生物启发模型，该模型将一种新的遗传算法（称为DNA-GA）与根本基础功能（RBF）神经网络相结合。DNA-GA是根据DNA的调节机制设计的，并应用于与梯度下降方法一起优化RBF网络。DNA-GA可以有效地改善人群的多样性并防止过早收敛，从而产生高收敛精度和出色的优化能力。基于Schaffer和Rosenbrock函数的测试表明，与现有的优化算法（例如Fire-Flip y算法）相比，DNA-GA的收敛精度分别提高了65.38%和67.69%，并且收敛速度也增加了50%。以预测准确性和收敛速度，生物启发的模型应用于现实世界的石油领域，极大地超过了传统的神经网络模型。针对传统RBF神经网络和GA优化的RBF神经网络的比较分析显示，生物启发的模型的预测性能有了很大的增强。特别地，平均绝对误差（MAE）分别减少了75%和50%。此外，通过平均收敛迭代衡量的收敛速度与GA优化的RBF神经网络相比提高了57%。这些结果证明，RBF神经网络和DNA-GA算法的组合可以大大提高石油生产的预测准确性。

关键字生物启发的模型·遗传算法·rbf神经网络·dna·石油生产预测

1简介

由于迅速的生态发展，对石油资源的需求不断增长，需要有效的石油利用。随着储量的迅速下降，石油领域的生产不断生产

减少和经济回报受到影响。为了维持石油生产能力的稳定性，水注射通常用于石油领域的剥削中。但是，注水会改变油井的特征，并影响未来的石油回收率。因此，必须准确预测水注入石油生产，以了解油井的石油和水特征，指导石油领域的开发并改善生产结果。

✉ Lei Gao
lei.gao@csiro.au
Bao Liu
liubao@upc.edu.cn
Yuqing Liang
2763769480@qq.com
Zirun Zhu
1097306866@qq.com

¹ College of Control Science and Engineering, China University of Petroleum, Qingdao 266580, China

² Commonwealth Scientific and Industrial Research Organisation (CSIRO), Waite Campus, Urrbrae, SA 5064, Australia

石油领域的注射和生产系统本质上是复杂的，非线性的，并且受许多具有不确定性和相互依赖性的因素的影响。这使得开发一种用于预测石油领域生产的精确注射产生模型。近几十年来，已经开发了各种模型来预测石油领域的生产，包括传统的数学或物理模型以及机器学习模型。传统模型，包括回归分析，衰减曲线方法和数值模拟方法，已被广泛用于石油生产预测中。但是，这些方法呈现了几种

实际应用中的局限性。例如, Albertoni和Lake采用多次线性回归来预测石油生产并分析了储层注入。但是, 该方法假定变量之间的线性关系, 从而使捕获油井中普遍存在的非线性特征不足[1, 2]。Salazar等。基于叠加原理的电容电抗模型, 将衰减曲线结合在一起。然而, 这种方法越过地质复杂性, 并努力地将其叠加原理应用于大多数储层数据的主要非线性行为[3, 4]。此外, Zhang等人。利用数值仿真方法用于储层建模和预测。尽管这些方法为地下流动性提供了详细的见解, 但它们的准确性重大依赖于物理模型的构建, 通常会导致预测精度有限和计算成本高。总而言之, 传统的石油井生产预测模型遭受了不足的非线性建模, 适用性差和预测准确性较低。

为了解决传统模型的局限性, 在石油领域提取过程中已应用机器学习模型来预测石油生产。机器学习模型通过其适应性和强大的数据处理能力(例如K-Means聚类[6, 7], 支持向量机[8, 9], Random Forest [10, 11], XGBOOST [11, 12]和神经网络[13, 14]来克服传统模型在处理非线性问题和时间序列依赖性方面的缺点。在这些机器学习方法中, 神经网络模型是最广泛使用的, 这是由于它们的卓越绘制非线性关系的能力及其在调整参数方面的影响, 例如基于特定情况的隐藏层和学习率的数量和学习率。例如, Cheng等人。提出了动态自适应背部传播(BP)神经网络模型[15]。该模型使用遗传算法和粒子群优化来优化BP神经网络的参数。但是, 该模型预测的准确性仍然需要改进。在另一项研究中, Zhang等人。通过RBF神经网络和支持向量机预测油井生产[16]。但是, 该模型在优化过程中的效率较小, 并且容易属于局部优势。

尽管已经对石油生产预测的建模和预测进行了深入的研究, 但传统的神经网络模型仍然遭受缓慢的转化率和落入局部最小值的倾向[17, 18]。为了进一步提高传统神经网络的预测准确性, 智能优化算法包括在神经网络训练过程中。其中, 遗传算法由于其强大的搜索能力和广泛的适用性而引起了人们对研究人员的更多关注, 并且通常将其用于功能选择和机器学习的高参数优化。Alfarizi等。将遗传优化算法引入

人工神经网络模型有效地克服了传统神经网络的局限性, 例如大量误差和对局部Optima的敏感性[19]。但是, 传统的遗传算法也容易发生融合和局部最佳。为了解决这个问题, Song等。改进了基于贪婪思想和局部调度规则的免疫遗传算法, 这不仅提高了石油生产预测模型的学习能力和鲁棒性, 而且增强了其搜索能力[20]。提出了一种具有多物镜优化的免疫克隆算法, 利用增强的交叉和突变算子, 从解决方案质量和计算成本方面, 它优于其他改进的遗传算法[21]。尽管取得了这些进步, 但仍需提高准确性的提高。最近, 受人体系统启发的想法为改进传统优化算法提供了一个新的想法[22, 23], 基因调节网络模型的改进效果更为明显。例如, Zang等人。提出了一种称为CM-DNAGA的混合遗传算法, 该算法利用了DNA编码和解码方法。基于云模型, 使用云模型的Y条件正常云发生器用作GA的交叉操作员, 而基本的正常云发生器在突变阶段被用作突变操作员。这些增强能力有助于提高石油生产预测模型的质量和操作效率[24]。尽管该算法结合了生物启发的编码和云模型的特性, 但它无法完全克服遗传算法的局限性, 例如过早收敛性和不可靠的收敛精度。这些研究表明, 传统优化算法的结合在提高神经网络模型预测石油生产的有效性方面取得了进步, 但是预测准确性仍然不满意。

为了解决上述改进方案的弊端, 这些方案很容易被捕获到局部Optima中, 并且在油产生预测中没有足够的预测精度, 我们提出了一种生物启发的优化算法以实时调整神经网络参数, 以避免计算增加。在传统的遗传操作员的基础上, 我们通过结合了生物基因DNA分子的复制, 转录和突变机制, 设计了一个新的自适应算子。这进一步导致了基于基因调节机制(称为DNA-GA)的遗传优化算法的发展。

在这项研究中, 我们首先使用传统的RBF神经网络建立了石油生产前词典模型, 然后我们利用DNA-GA算法来增强RBF神经网络的梯度下降优化方法。本文的主要贡献总结如下。(1) DNA-GA算法利用DNA碱基配对法




图1基因表达调节的机制

编码和增强遗传算法的选择，交叉和变形阶段。(2)在选择阶段，使用轮盘赌轮选择和排序的组合来改善选择操作员。(3)在跨界阶段，新个体是根据自适应量词因素和互补基本配对原理的指导来转录的。(4)在突变阶段，取代突变和重组突变根据DNA基因的特异性突变发生。通过降低传统遗传算法的不变优化效果，我们表明DNA-GA的性能较高。因此，这提高了石油生产预测模型的预测准确性，从而实现了令人满意的准确预测。我们的研究证实，整合以生物启发的优化算法可以显著提高石油生产预测的准确性，这为提高石油生产预测的准确性提供了一种有希望的方法。

2人类的基因调节

基因调节是一种控制生物内基因表达的机制，主要是通过DNA分子的复制，转录和翻译来完成的。此过程主要发生在三个级别上：(1)控制基因在DNA分子水平上的控制，转录和翻译；(2)在微生物水平上改变新陈代谢；(3)多细胞生物学水平的细胞分化和发育。理解基因调节对于理解活机中的遗传和进化至关重要。

2.1基因表达调节的机制

基因表达调节发生在转录水平，通过复制，转录和DNA分子的翻译来控制生物的生长。脱氧核糖核酸

分子是一种双螺旋大分子化合物，由四个核苷酸组成：腺嘌呤脱氧核苷酸(A)，胞嘧啶脱氧核苷酸(C)，鸟嘌呤脱氧核苷酸(G)和胸腺胺脱氧核苷酸(T)。单链DNA被认为是由四个不同字母组成的字符串：A, G, C和T [25]。

DNA的复制和转录过程是通过聚合酶催化的，使用单链DNA作为模板和四个脱氧核苷酸作为材料。当酶的活性达到一定水平时，根据基础互补配对原理进行转录：基础A对应于碱基T和碱基C对应于碱基G，然后产生新的DNA分子链并完成遗传信息的传播。该程序如图1所示。

2.2基因突变的机制

生物学中的基因突变是指DNA分子突然可遗传的变异。碱基对的组成或顺序的变化会导致基因突变。根据DNA分子碱基的变化，基因突变通常可以分为碱基置换突变，移位突变，缺失突变和插入突变，如图2所示。

基因突变可以自发发生或被诱导。诱导会导致生物产生大量和不同数量的遗传突变，并产生更多的新遗传信息，然后根据需求培养出新的品种，这对于生物学进化非常重要。

随着数学工具的整合，基因调节网络中已经出现了许多理论模型。不断扩大的研究表明，在医疗领域的应用值很高。此外，基因调节网络是跨学科领域，包括数学，信息学，计算机科学和生物学，在系统设计[26]中具有很大的参考价值[26]




图2基因突变过程

组优化算法[27]。基于基因调节网络机制的新优化算法对于提高石油生产的预测准确性至关重要。

3使用DNA-GA算法优化RBF遗传网络

3.1 DNA-GA

遗传算法（GA）是一种自适应全局优化算法，模仿了自然界生物的遗传和进化过程[28]。它通过选择，交叉和突变将目标函数编码为染色体，从而发现了目标函数的最佳解决方案。遗传算法具有广泛的应用范围和强大的强大特征，可以找到优化问题的全球最佳解决方案，并有效防止神经网络在训练过程中陷入局部最佳问题。但是，传统的编码方法可能导致过早的收敛性，一旦误差达到一定值，ga弱的优化削弱了，从而无法完全证明基因调节的作用。近年来，通过加强跨界和变化过程[29, 30]做出了努力来改善传统GA，但是早产融合的问题仍然存在。为了解决GA的局限性，本文提出了基于基因调节的DNA-GA，并通过增强单个编码模式，复制，交叉和突变过程来升级传统GA。结果，提高了DNA-GA的优化精度和速度。

表1 DNA-GA模块与人类基因调节机制之间的相应关系

DNA-GA		Gene Regulation in Human	
Module	Role	Mechanism	Role
Individual coding	Guide individuals to encode in quaternary coding method	Principle of complementary base pairing	Guiding the synthesis of DNA double-stranded by complementary pairing of A-T and C-G
Replication	Guiding the improved selection operator to copy the parent individual	Principle of survival of the fittest	Individuals or genes that can adapt to nature are selected to survive
Transcription	Guiding the transcription of adaptive transcription factor to produce new individuals	Transcription	Guiding genetic information to flow from DNA to RNA under the action of RNA polymerase
Mutation	Guiding the mutation of adaptive mutation factor to generate new individuals	Mutation	Causing sudden and heritable variation on DNA molecules

基因调节。受到DNA中基本成对原理的启发，DNA-GA采用了第四纪编码方法来编码个体。其次，受自然界生存原则的启发，通过将轮盘和分类组合以选择父母以进行复制，可以改善选择操作员。然后，受到DNA转录的启发，使用自适应转录因子来指导转录过程并产生新个体。最后，受到基因突变过程中的位移突变和重组突变的启发，改善了自适应突变因子以增强逃避局部优势的能力。

表1显示了DNA-GA模块与人类机制之间的相应关系




图3针对个体人群的第四纪基本代码

3.1.1 核心原则

(1) 单个编码

DNA-GA算法使用基于DNA链中碱基的编码方法。单个DNA分子可以表示为一组四个字母： $\{a, t, c, g\}$ (图1)。结果，染色体是用第四纪编码方法编码的。在该方法中，0表示碱基a，1代表碱基C，2代表碱基g，而3表示碱基。初始亲属由随机生成的第四纪数序列表示。例如， $x = 203,103,210,322,031$ 代表长度15的个体。如果个人的数量达到 N ，则 k -th ($1 \leq k \leq N$)个体的结构如图3。 X_L 表示参数值， X_i ($1 \leq i \leq L$)的值是零和三之间的整数。

本文开发的第四纪碱基编码方法是在基因调节中DNA分子的编码模式的启发。个人的编码模式忽略了基础的顺序和数量。将DNA中DNA的复制，转录和基因突变纳入DNA-GA的选择，交叉和突变中，并根据基础互补配对的原理处理信息。

(2) 复制

选择性复制通过保留具有较大拟合度值的个体来模仿自然存活的过程。传统的遗传算法使用轮盘赌法来选择个人来复制，并保留下一代的多样性。但是，当个体之间的劣势差异在回避的后期阶段很小时，收敛速度会减慢。在这项研究中，通过将轮盘方法与排序相结合，可以改善选择操作员。轮盘方法仍在进化的早期阶段使用以维持人口多样性。尽管在中间和后来的阶段，即个人之间的拟合度差异很小，以更好地反映生物进化过程中自然生存原理，但采用了对排序进行选择。个人以降序的拟合度值进行排序，只有较高的人是

保留。 k -th individual $p(x_k)$ 的改进选择概率的计算如下：

$$\begin{cases} p(x_k) = \frac{q}{1-(1-q)^N} \times [(1-q)^{k-1} + (1-q)^{N-k+1}] & (k \leq \frac{N}{2}) \\ p(x_k) = 0, & (k > \frac{N}{2}) \\ q = fit_{avg} / \sum_{i=1}^{N-\frac{N}{2}+1} fit(x_i) \end{cases} \quad (1)$$

在其中， N 是人口中的个体数量， k 是按拟合度排序的个体的序列数， q 是平均耐心选择概率， fit_{avg} 是人口中个体的平均值， i 是 i 的平均值， i 是 i 的序列序列有序的序列序列。

单个选择的概率与拟合度值密切相关。首先，我们对从小到大的个人进行排名。当 k 小于 $\frac{N}{2}$ 时，我们计算了根据公式(1)中所示的平均耐度选择概率 q 选择当前个体的概率。当 k 大于 $\frac{N}{2}$ 时，我们将选择的个体的概率设置为0，也就是说，不是被选择。

(3) 转录

在传统的遗传算法中，分频器根据一定的跨界率来概述父母的信息，以形成新的上级个体。人口中的父亲通常采用线性自适应交叉率。但是，该过程将减少种群的多样性，并导致近交，这增加了过早收敛的风险并陷入局部最佳状态。

为了应对上述挑战，灵感来自DNA的文字过程，我们建议改善传统遗传算法的自适应交叉过程。基于转录因子进行转录，当转录因子达到不同的活性值时，选择来自亲本个体的不同基因片段。然后，根据基础互补配对的原则，在介绍后产生新个体，保留人口多样性，并有效避免过早的收敛性和局部最佳效果。使用转录因子确定操作的起源和长度。如果变体因子为 p_c ，则转录的长度通常为 $a = L \cdot p_c$ 。转录的片段可以表示为： $[X_{L-a}, X_{L(1-p_c)}, \dots, X_L]$ ，其中 L 是单个编码的长度。介绍过程如图4所示。

如果起点是 x_i ，则可以将转换之前的个体表示为： $X = [X_{i+1}, X_{i+2}, \dots, X_{i+n}, X_{i+n}]$;转录后的个人可以表示为： $X = f(x) \equiv [\overline{X_{i+1}}, \overline{X_{i+2}}, \dots, \overline{X_{i+n}}]$;在哪里， x_i 表示

移位突变；如果 $(0.5 < m \leq 1)$ ，使用重组突变。

在生物学进化中，基因突变的发生和个体在环境中的效果密切相关。具有较高的个人具有更强的性能和突变的可能性较低。为了反映这种关系，基于sig-moid函数的自适应突变因子 q_c 被定义为：

$$q_c = q_0 \times \exp\left(\frac{fit_{\max} - fit}{fit_{\max}}\right) + \frac{1}{1 + q_0} \times \exp^{-\frac{\Delta fit_{\max}}{\Delta S}} \quad (3)$$

在其中， q_0 是最初的突变因子， fit 是突变之前的效果， $fit_{\max}$ 是人群中的最大个性， $\Delta fit_{\max}$ 是人群中最大个性的最大变化量， ΔS 的最大生成数量是当前人群和最大人群之间的生成数量，其最大人群已更改为0，并且已更改为0 {and}。

如公式 (3) 所示，个体突变面与个人舒适性的变化率和人口的最佳个人效果有关。当拟合和变化率较高时，突变因子较小，阻止了上级人群被破坏。相反，较大的突变因子可以保留弹出多样性，并增强算法的局部优化能力。

该算法的转录过程根据基因DNA表达进行运动。选择特定的片段以转录个体，并将转录过程映射为0对应于3和1对应于2。变异过程是基于基因突变机制设计的，并选择了特定的片段以进行单个变异操作。选择变化模式是最多选择的，从而可以修复代码。




图6 DNA-GA的结构

3.1.2 DNA-GA的优化过程

在DNA-GA中，个体是由四边形编码创建的，然后使用改进的遗传操作员并根据拟合度的函数适应自身。上述过程的流程图如图6所示。

特定过程如下：

Step 1: Establish the objective function optimization model according to the decision variables and constraints.

Step 2: Encode the individuals according to the quaternary coding method to generate the initial population.

Step 3: Calculate the fitness of each individual to determine whether the conditions for error iteration are met. If so, go to Step 8, otherwise go to Step 4.

Step 4: According to the improved selection operator of formula (1), the parent individual with high fitness value is copied.

Step 5: Identify the adaptive transcription factor of formula (2), and transcribe the parents according to the principle of complementary base pairing.

Step 6: Determine the adaptive mutation factor according to formula (3), and generate a new population through mutation.

Step 7: Determine whether the maximum number of iterations has been reached. If so, go to Step 8, otherwise go to Step 3.

Step 8: Obtain the optimal solution.

DNA-GA算法的优化过程：

3.1.3 DNA-GA的复杂性分析

在DNA-GA算法的时间复杂性分析中，我们在这里利用了大符号。大符号通常忽略常数，低阶和系数，描述了随着数据大小的增加而描述算法的增长趋势，并且不代表实际的执行时间。因此，我们计算每个模块的时间复杂性，然后执行加法操作，并确定仅保留最高数量级项。

本文将最大迭代次数设置为 g ，人口大小为 n ，可变空间维度为 d ，并且目标函数为 M 。初始化总体的时间复杂性为 $O(n \cdot d)$ ，效果函数的时间复杂性为 $O(n \cdot m)$ ，并且在算法迭代过程中使用了两个分类操作。时间复杂性为 $O(2n \cdot (\log N) \cdot m)$ ，复制过程的时间复杂性为 $O(n^2 \cdot m)$ ，转录过程的时间复杂性为 $O(n \cdot m)$ ，突变过程的时间复杂性为 $O(n \cdot m)$ 。总而言之，总时间复杂性 $O(n \cdot d + n \cdot m + 2n \cdot (\log n) \cdot m + n^2 \cdot m)$

$+ n \cdot m + n \cdot m + n \cdot m) = O(n^2 \cdot m)$ 。与其他智能优化算法相比，计算成本增加了。

3.2由DNA-GA优化的RBF神经网络

3.2.1 RBF原则

包括RBF类型在内的神经网络能够通过模拟从人脑启发的机制，具有强大的自学能力和适应性能力来执行非线性操作，因此它们经常被用于预测模型中。

RBF神经网络是一个典型的三层feedfor-ward网络，具有输入层，隐藏层和输出层[31]。第一层是输入层，由信号源节点组成，这些节点仅传输数据而不转换输入信息。第二层是隐藏层，基于特定要求的节点数量可变，具有带有高斯函数核的神经元。这层

空间地图输入信息。第三层是外部层，对输入模式有反应。输出层中的神经元利用线性函数，线性加权隐藏层中神经元的输出，以产生整体的神经网络输出。RBF神经网络的结构如图7所示。

在图7中， i 是输入节点的数量， j 是隐藏节点的数量， m 是输出节点的数量， $X = [X_1, X_2, X_3, \dots, X_i, X_{i+1}, \dots, X_m]$ 是输入数据， $H = [H_1, H_2, H_3, \dots, H_j]$ 是隐藏的数据， $Y = [Y_1, Y_2, Y_3, \dots, Y_m]$ 是输出数据。

3.2.2由DNA-GA优化的RBF

在预测石油领域的产量时，由于预测问题的非线性和不确定性，传统的统计方法并非足够精确。RBF神经网络模型有望应对挑战[32]。但是，在处理非线性和滞后性质等复杂问题时，它可能面临较低的收敛率和局部最佳。为了提高预测模型的准确性，本文结合了DNA-GA算法 - 静态和动量梯度训练，以优化RBF神经网络的参数。DNA-GA优化的RBF神经网络的结构如图8所示。

在图8中， c_{ij} 是高斯功能在隐藏层中的中心点的坐标向量，与输入数据相同的维度 $\|x - c_{ij}\|^2$ 被定义为euclidean distance euclidean distance input layer and hidden vector之间的euclidean distance， b_j 是 b_j 的均值， b_j 是隐藏层的hidden nodes， w_j 是隐藏层与输出层的权重。 $y = h_j w_j$ 表示实际输出， E 是错误指示器函数，并且隐藏层被激活




图7 RBF神经网络的结构




图8基因调控优化的RBF神经网络的结构

通过高斯功能：

$$h_j = \exp\left(-\frac{\|x - c_j\|^2}{2b_j^2}\right) \quad (4)$$

动量梯度训练过程如下：

$$w_j(k) = w_j(k-1) + \Delta w_j(k) + \alpha[w_j(k-1) - w_j(k-2)] \quad (5)$$

$$\Delta w_j(k) = -\eta \frac{\partial E_k}{\partial w_j} = \eta e h_j \quad (6)$$

$$b_j(k) = b_j(k-1) + \Delta b_j(k) + \alpha[b_j(k-1) - b_j(k-2)] \quad (7)$$

$$\Delta b_j(k) = -\eta \frac{\partial E_k}{\partial b_j} = \eta e w_j h_j \frac{\|x - c_j\|^2}{b_j^3} \quad (8)$$

$$c_{ji}(k) = c_{ji}(k-1) + \Delta c_{ji}(k) + \alpha[c_{ji}(k-1) - c_{ji}(k-2)] \quad (9)$$

$$\Delta c_{ji}(k) = -\eta \frac{\partial E_k}{\partial c_{ji}} = \eta e w_j h_j \frac{x_j - c_{ji}}{b_j^2} \quad (10)$$

在上面的公式中， $\eta \in (0, 1)$ 是学习效率， $\alpha \in (0, 1)$ 是动量因子。

我们将误差绝对值累积指数用作参数选择的最小目标函数：

$$J = \sum_{i=1}^M |y(i) - y_m(i)| \quad (11)$$

在这种方法中，我们将RBF神经网络的误差指标函数用作辅助评估函数。

DNA-GA优化的RBF神经网络的训练过程如图9所示。

使用基因调节遗传算法训练RBF神经网络与动量疗程训练相结合的步骤如下：

Input: n individuals consist of parameters of RBF neural network: length of Gaussian function, b_j ; Center vector, c_{ij} ; Weight from hidden layers to the output layer, w_j ; the individual code X ; i.e., $X = (X_1, X_2, X_3, \dots, X_L)$, maximum epochs p .

Output: Optimum fitness value y_x and the corresponding individual x_o .

Step 1: Apply the gradient optimization training to optimize the neural network's parameters preliminarily. Use Eqs. (5) and (6) to calculate the w_j , Use Eqs. (7) and (8) to calculate the b_j , and use Eq. (9) (10) to calculate the c_{ij} .

Step 2: Establish the objective function F according to the m various constraints; i.e.

$F = (f_1, f_2, f_3, \dots, f_m)$; After encoding, initialize populations $x = (x_1, x_2, x_3, \dots, x_n)$.

Step 3: Evaluate individuals' fitness fit using Eq. (11) as the minimum objective function to select parameters.

Step 4: Determine the transcription factor p_c and the mutation factor q_c according to the fitness value, then through replicate, transcription and mutation to produce new populations.

Step 5: Judge whether the error index of the new population is satisfied. If so, go to **step 6**; otherwise, continue iteration. If it arrives the maximum epochs but not find the optimal solution, skip the loop.

Step 6: When the iterations stop, the individual with the optimal fitness is selected as the optimum.

Step 7: Decode the output sequence $X_o = (X_{o1}, X_{o2}, X_{o3}, \dots, X_{oL})$, obtain the optimum parameters, b_j , c_{ij} and w_j .

Step 8: End

3.3 模型绩效评估和稳定性分析

使用平均绝对误差 (MAE), 平均相对误差 (MRE), 均方根误差 (MSE) 来比较本工作中模型的预测结果。MAE反映了预测值和外部值之间的误差, MRE反映了从预测值到实际值的偏差, MSE反映了预测值和实际值之间的差异程度。

$$MAE = \frac{1}{M} \sum_{i=1}^M |y(i) - y_m(i)| \quad (12)$$

$$MRE = \sum_{i=1}^M \frac{|y(i) - y_m(i)|}{y_m(i)} \times 100\% \quad (13)$$

$$MSE = \frac{1}{M} \sum_{i=1}^M (y(i) - y_m(i))^2 \quad (14)$$

在哪里, M 是用于测试的石油生产样品总数; $y_m(i)$ 表示第 i 样品的真正石油产量; $y(i)$ 表示第 i -thement 的预测值。

DNA-GA优化的RBF神经网络预测模型需要保证模型的稳定性, 这也需要验证。

定理: 当 $0 < \eta < 2 / \|h_j\|^2$ 时, 神经网络预测模型稳定

证明: 构建显示为 follows 的 Lyapunov 函数:

$$L(k) = \frac{1}{2} [e_i(k)]^2 \quad (15)$$

然后:

$$\begin{aligned} \Delta L(k) &= L(k+1) - L(k) \\ &= \frac{1}{2} [e_i(k+1)]^2 - \frac{1}{2} [e_i(k)]^2 \\ &= \frac{1}{2} [e_i(k+1) - e_i(k)][e_i(k+1) + e_i(k)] \\ &= \Delta e_i(k) \left[e_i(k) + \frac{1}{2} \Delta e_i(k) \right] \end{aligned} \quad (16)$$

来自公式 (7):

$$w_j(k) = w_j(k-1) + \Delta w_j(k) \quad (17)$$

在此公式中, w 是网络的重量矩阵。




图9由DNA-GA优化的RBF神经网络的训练过程

所以:

$$\begin{aligned} \Delta w_j(k) &= w_j(k) - \Delta w_j(k-1) \\ &= -\eta \frac{\partial E_k}{\partial \Delta w_j} = \eta e h_j \end{aligned} \quad (18)$$

众所周知:

$$\begin{aligned} \Delta e_i(k) &= \left[\frac{\partial e_i(k)}{\partial w} \right] \Delta w = -[h_j]^T \Delta w \\ &= -[h_j]^T \eta e_i(k) h_j \end{aligned} \quad (19)$$




图10的Schaffer和Rosenbrock函数的四种方法的优化曲线

将Rosenbrock函数设置为50，每种算法进行30个比较实验。Schaffer和Rosenbrock函数的光学曲线如图9所示。在图10a中，FA和GA的均具有更长的时间，而DNA-GA的收敛时间最短，而DNA-GA具有最短的收敛时间，并且最接近的最接近趋势是所有算法中的最佳最佳值。在图10B中，DNA-GA的收敛速率最快，其最终收敛值是最小值，它也比其他三种算法更接近实际最佳值。

在测试函数的全局最佳最佳中，有许多局部解决方案，Rosenbrock函数的最佳位于一个长而狭窄的抛物线谷中，因此很难找到它。如表2所示，使用五个性能指标比较这些算法的优化功能。

在这项研究中，将DNA-GA应用于优化径向基函数（RBF）神经网络以提高其收敛速度和准确性。Schaffer和Rosen-Brock功能用于评估DNA-GA的性能，并与传统的GA，AFSA和ANT FA进行比较。结果表明，DNA-GA在减少搜索最佳值所需的最大迭代次数方面具有显著优势（表1）。在Schaffer函数实验中，DNA-GA的平均迭代次数为32，比传统的GA相比提高了57.33%，比AFSA比60.49%，比FA提高了42.86%。同样，在Rosenbrock函数实验中，DNA-GA的平均迭代次数为36，比传统GA的56.62%改善，比AFSA相比59.55%，比FA相比47.83%。发现的最佳和实际最佳值之间的误差用于评估算法的准确性。在Schaffer函数实验中，全局最大值为1，而DNA-GA的最佳最佳为0.99901，误差为 9.9×10^{-4} ，为0.243%，

比传统的GA，AFSA和FA提高0.207%和0.189%。在Rosenbrock函数实验中，全局最小值为0，而DNA-GA的Optimum为0.63，误差为81.0%，67.7%和82.3%，比传统的GA，AFSA和FA（分别）提高了82.3%。就算法的运行时间而言，DNA-GA的优化时间显然比FA和ASFA的优化时间更长，并且比GA的优化时间更长。结果，与其他算法相比，DNA-GA在收敛速率和精度方面具有明显优势，但优化时间略有优势。

4.2生物启发的模型及其石油生产预测的性能

4.2.1应用背景和参数设置

这项研究旨在使用神经网络非线性建模方法预测石油生产。为此，使用了来自2,000多个石油领域的2,000多个石油和水井的水注入和石油生产数据。从2015年1月到2016年12月，对数据的分析表明，石油产量和注入套管压力密切相关，并且注射模型具有滞后。因此，采用了神经网络非线性模拟方法。

在这项研究中，我们考虑了广泛适用的背面传播（BP）和径向基函数（RBF）神经网络，以预测石油的产生。BP神经网络是一种前馈网络，使用反向传播算法训练，该算法通过层次向后传播错误，并通过梯度下降算法更新权重。BP网络擅长解决非线性问题，但可能会陷入本地Optima，并且需要大量的培训时间。RBF神经网络，径向基函数网络，

表2四种算法的优化性能

Test functions	Algorithms	Performance index				
		Minimal iterations	Maximal iterations	Average iterations	Average optimum	Running time
Schaffer	GA	9	100	75	0.99659	0.83820
	AFSA	16	92	81	0.99695	0.77540
	FA	6	76	56	0.99713	0.51720
	DNA-GA	12	56	32	0.99901	1.08280
Rosenbrock	FA	11	95	69	3.56e + 1	0.64840
	GA	15	100	83	3.32e + 1	1.12220
	AFSA	16	89	89	1.95e + 1	0.54789
	DNA-GA	13	65	36	0.63e + 1	1.20159

为径向基础功能建立最佳中心和半径，并使用最小二乘法确定权重。RBF网络具有快速的训练速度和高精度，但它对数据噪声敏感，并且可能会遇到问题。如图13所示，我们将油井数据馈送到BP和RBF神经网络中进行预测。与BP网络相比，RBF网络表现出了卓越的预测性，这使我们采用DNA-GA算法来增强RBF油产量预测模型。

使用DNA-GA通过汇编1,100组输入和输出数据，使用小波噪声降低并将其归一化，然后将1,000个数据作为训练样本，其余100个作为测试样品，从而使用DNA-GA进行了优化的RBF神经网络。在这项工作中，我们关注基于四个重要因素/特征的石油生产预测：原始井 $Q_{in1}(k)$ 的水量数量，原始孔注射 $Q_{in2}(k)$ 的水注射，对二级井中的水注射孔 $Q_{in3}(k)$ 和袖子压力 $P_g(k)$ 。石油生产 $Q_{out}(k)$ 被视为神经网络的输出。我们使用具有六个输入的三层RBF神经网络模型，包括四个选定的功能和反馈状态 $Q_{out}(k-1)$ 和 $Q_{out}(k-2)$ 。图11说明了基于RBF神经网络的石油生产预测模型的结构。

特别是，RBF神经网络模型由一个带有6个神经元的输入层组成，一个神经元的隐藏层和一个带有一个神经元的输出层。我们使用传统的GA和DNA-GA优化了RBF神经网络，其参数设置如表3所示。

在表3中， η 是RBF的学习率， α 是动量因子， E 是理想的错误， MG 是最大迭代。在算法中， N 是种群的尺寸， G 是最大迭代， p 和 q 是ga， p_0 和 q_0 的交叉概率和突变概率是转录因子参数和DNA-ga的初始变异因子。




图11基于RBF神经网络的石油生产预测模型的结构

4.2.2 石油生产预测结果和模型比较

通过设置上述参数，我们在相同数量的迭代次数下显示了GA和DNA-GA的误差曲线，并且实验效应如图12所示。从该图中可以明显看出，DNA-GA的DNA-GA优于GA的ga在人群优化的准确性和速度方面均优于GA。它成功避免了过早的融合。

为了显示算法优化过程中的效果函数的变化，表4显示了迭代中个体效果的变化。

为了证明DNA-GA的优势，我们使用经典的返回propagation (BP) 神经网络，常规RBF神经网络，由GA-RBF (GA-RBF) 优化的RBF神经网络建立了油井注入模型，并通过DNA-GA (DNA-GA-RBF) 优化了RBF神经网络 (DNA-GA-RBF)，以相应地预测油的生产。这些模型在测试数据集上的实验性能如图13所示。

表3传统GA，DNA-GA和RBF的参数设置

GA				DNA-GA				RBF			
p	q	N	G	p_0	q_0	N	G	η	α	E	MG
0.6	0.05	40	100	0.6	0.05	40	100	0.10	0.85	0.001	500

图12迭代错误
目标函数最佳
由传统ga a
DNA-GA

of
ization
nd the




表4优化O
迭代pro的功能

f fitness
cess

Fitness function initial value	Transcription factor	Post-transcriptional fitness value	Variation factor	Variation fitness value
46.51	0.12	47.62	0.09	48.78




图13石油生产中使用的不同模型预测的比较

n

如图13所示,传统的BP神经网络模型的收敛性较慢且准确性较低。尽管RBF神经网络模型可以提高模型的转化率,但它并不能显著提高准确性。GA可以提高RBF神经网络模型的训练速度和准确性,但是随着目标函数的训练误差的降低,其优化效率降低。

DNA-GA不仅提高了RBF神经网络预测模型的准确性,而且融合更快。但是,早期算法的效率仍然需要改进。

为了确保结果的鲁棒性,我们使用各种算法进行了30项比较测试,并从这30个实验中获得了评估指标的平均值。结果显示在表5中。

表5比较了测试数据集上石油生产模型的评估指标。基于第一三个评估指标,DNA-GA-RBF神经网络模型超过了GA-RBF模型和RBF神经网络模型。与RBF模型相比,DNA-GA-RBF模型的MAE,MRE和MSE分别降低了74.2%,7.34%和80.3%。与GA-RBF模型相比,MAE降低了50.3%,MRE降低了4.95%,MSE降低了69.6%。但是,DNA-GA-RBF的运行时间显然比其他模型更长。这些结果表明,DNA-GA具有卓越的优化能力,DNA-GA-RBF神经网络模型具有更高的训练精度,但是需要改善优化时间。

5个讨论

提出的DNA-GA是一种基于改善遗传操作员的新型GA。与传统的GA相比,DNA-GA的遗传操作员根据个体效果的变化进行了修改,从而提高了自适应能力。DNA-GA算子的自适应改善体现在适应性转录因子和适应性突变参数中。在传统的GA中,交叉率和突变率设置为特定值,这将减少人口的分化,导致近交,并增加过早收敛的风险并降至局部最佳。在DNA-GA算法中,这两者都与个体的功能值有关,这会在迭代过程中变化。公式(2)可以根据个体的功能值动态调整交叉概率,以便具有较高效果值的个体具有较小的交叉概率,从而加速了算法的收敛速度;公式(3)还可以根据个体的拟合度动态调整变异概率,以增加人口的多样性并避免

算法属于局部优化。在图10b中,Rosenbrock上DNA-GA和GA的选择结果表明,DNA-GA具有更快的收敛速度和更高的选择精度,这也可以通过表2中记录的结果证明。但是,DNA-GA具有多种限制性:(1)最大程度的效果是不一致的:(1)在同一效果下,它的最高数字也不是相同的,它可能是效果的。(2)根据人口拟合度的变化,改善了DNA-GA的遗传操作员,这使计算方法复杂,并且某些参数仍需要主观调整;(3)DNA-GA在优化的早期阶段具有较低的效率,这可以通过测试功能优化的实验证明,这表明DNA-GA的最小迭代并不优于传统算法的最低效率。(4)DNA-GA算法的运行时间很长,优化速度缓慢,当应用于复杂模型时,这将变得更加问题。为了应对这些挑战,未来的研究将探索几种增强功能。我们计划将不同的搜索方法应用于优化过程的不同阶段,例如块级和网络级别的搜索,以提高早期效率并降低整体计算复杂性[39]。此外,我们将采用进化策略来提高收敛速度和鲁棒性[39]。最后,我们旨在合并先进的随机优化技术,以增强DNA-GA在现实世界应用中处理不确定性的能力[40]。

此外,为了增强基于DNA-GA的改进石油生产预测模型的概括能力,有必要使模型简单稳定,降低参数冗余,并解释不同区域油田之间特性的差异。从预言中,DNA-GA改进的RBF石油生产预测模型需要合适的输入特征,例如水注射和管道压力,在确定种群大小,初始基因算子以及优化迭代的数量之前,应对其进行过滤和归一化。

关于模型的适用性,我们需要分析特定问题。由于其出色的结合速度和自适应能力,我们的模型适合解决具有较高时间序列依赖性的非线性复杂系统问题,并且通过相关性和不确定性(例如石油生产预测)而产生了极大的影响,并且可以获得良好的预测准确性。因此,我们可以考虑将其应用于电力载荷,股价预测金融场和河流水流的预测。此外,我们可以尝试将DNA-GA模型应用于解决最佳解决方案问题,模式识别,数据挖掘和图像处理。例如,在机器学习中,可以将人工神经网络的训练算法改进到更高级的算法中,例如基于背部传播,改善梯度下降,莫蒙梯度下降等的梯度下降,以便它可以添加训练数据

4. Cao F, Luo H, Lak LW (2015) 通过从finder Data Eith Kova I方法与电容/电阻模型相结合的finfient-Eld数据模型来推断油率预测。SPE水库EDEN ENG 18 (04) : 534 – 553 5。碳酸盐蒸发物 40 (1) : 1-146。Liao Q, Xue L, Lei G, Xu L, Sun S, Patil S (2022) K-Means群集和经验建模的水流量性能统计预测。PE T SCI 19 (03) : 1139 – 1152 7。J大数据11 (1) : 117 – 1178。Ma K, Wu C, Huang Y (2024) 基于改进的鲸鱼算法优化的支持向量机的油井生产率预先字典。J PE Explor Prod Technol 14 (12) : 3251 – 32609。Li J, Bian X (2024) 改进的最小二乘支持向量机模型, 基于灰狼优化器算法, 用于预测CO₂酸化油的最低可靠性压力。Energ Technol 12 (5) : 7 – 1210。Liu B, Gao L, Li B, Marcos-Martinez R, Bryan B (2020) 非公制机器学习, 用于绘制森林覆盖率和探索影响因素。Landsc Ecol 35 : 1683 – 1699 11。石油, 天然气和水生产实验。传感器 (巴塞尔) 22 (14) : 5 32612。Mohammadian E, Kheirollahi M, Liu B, Ostadhassan M, Sabet M (2022) 案例研究, 一项案例研究, 对伊朗的异源性碳酸盐储层中的机器学习使用机器学习的岩石物理岩石键入和通透性预测。SCI REP 12 (1) : 4505 13。Sharipov MI (2021) 开发了一种使用神经网络控制石油和天然气生产过程的方法。Memetic Comput Adv Autom II : 3 – 1414。Panja P, Jia W, McPherson B (2022) 使用堆叠的长期记忆 (LSTM) 网络预测sarocief的井绩效。专家Syst Appl 205 : 11767015。Cheng X, Hu X, Li Z, Geng C, Liu J, Liu M, Zhu B, Li Q, Chen Q (2022) 使用遗传算法和粒子群优化BP神经网络算法来改善海洋油漏油的预测。水空土壤污染233 (8) : 202216。张Y, 王R, 王X (2021) 基于RBF神经网络和支持向量机的原油管道中蜡换速率的预测方法。E 3S Web Conf 271 : 0400717。ABAziz MF, Mostafa SA, Mohd. Foozy CF, Mohammed MA, Elhoseny M, Abualkishik AZ (2021) 将Elman复发性神经网络与粒子群优化算法整合在一起, 以改善对多学科数据集的混合培训。专家Syst Appl 183 : 11544118。AbdelB, Mohamed R, Hezam I, Sallam K, Hameed I (2024) 二进制优化问题的有效二元杂种算法: 分析, 验证, 验证, 案例研究。Int J Comput Intell Syst 17 (1) : 1 – 319。Alfarizi MG, Stan ko M, Bikmukhametov T (2022) 使用遗传算法和人工神经网络结合使用遗传算法在水流中进行井控制优化。上游油气技术9 : 1 0007120。Song L, Liu C, Shi H, Zhu J (2022) 一种改进的免疫遗传算法, 用于解决批处理处理的功能快捷的车间调度问题。无线沟渠计算2022 (1) : 2856056 21。Zhu S, Cai J, Sun E (2023) 基于改进的多目标免疫克隆算法的移动边缘方案的移动边缘计算。无线网29 (4) : 1737 – 1750
22. Liu B, Xu M, Gao L, Yang J, DI X (2022) 一种用于高维优化的混合方法: 将粒子雕像与神经内分泌 - 免疫系统中的机制结合在一起。基于知识的Syst 253 : 10952723。Liu B, Yang J, Gao L, Thiruvady D, Nazari A (2021) 生物启发的启发性动力学编程, 用于高精度实时流量控制多元时间表的河流系统。基于知识的Syst 230 : 10738124。Zang W, Ren L, Zhang W, Liu X (2018) 基于云模型的DNA遗传算法, 用于数值优化问题。Futur Gen Comput Syst 81 : 465 – 477 25。专家Syst Appl 206 : 117861 26。Nazin V, Poznyak S (2024) mir-Descent方法中的非二次代理函数, 用于设计不确定性的非线性动态系统的强大控制器。计算数学数学物理64 (4) : 820 – 83227。Li D, Pan Z, Hu G, Anderson G, He S (2021) 来自多层加权基因共表达网络的主动模块均衡: 一种连续的优化方法。IEEE/ACM Trans Comput Biol BioInf 18 (6) : 2239 – 224828。Franciskus A, Taviti N, Chamandeep K (2024) 高级混合CNN-BIST MAGEN, 该模型用GA和FFO增强, 以增强旋风强度的预测。Alex Eng J 92 : 346 – 35729。Xie F, Sun Q, Zhao Y, Du H (2022) 基于多层突变的改进的定向跨界遗传算法。J控制SCI ENG 2022 (1) : 439895230。Yin Y, Yu L, Jie S, Jia X (2023) 基于网格图的遗传算法, 用于解决机器人路径计划问题。Eng Lett 31 (4) : 180 – 18931。Zhang S, Liang Y, Xu Z, Li H, Wang G, Cheng K (2024) (2024) 基于RBF-Stochastic响应表面方法的主动分布网络的最佳调度。电力系统Res 232 : 11036332。Zhang D, Wang H, Shan S, Wang C (2023) 动态表面适应性RBF RBF神经网络控制, 用于一类非线性不确定系统。Electron Lett 59(23):1 – 4 33。Guo Y, Gong J (2020) Group targets tracking using maximum entropy fuzzy based on firefly algorithm and particle filter In: 2020 7th International Forum on Electrical Engineering and Automation (IFEAA), pp 937 – 942 34。Hu Y, Zhang Z, Zhang Z, Li Z, Tang Q (2024) 数学和以学习为导向的多目标人工蜜蜂菌落算法, 用于能源感知的富裕组装工作店工作店调度问题。Eng Appl Artif Intell 133 : 10863435。Zhao J, Mark P, Vincent Y, Zhang Z (2024) 一种混合遗传搜索和基于动态编程的基于动态编程的拆分算法, 用于多行驶时间依赖的车辆路由问题。Eur J Oper Res 317 (3) : 921 – 935 36。Yue M, Guo B, Hu T, Guo X (2009) 遗传算法参数的研究以及粒子群的优化和shuff frog frog-log-leap-leaping算法的比较。In: 2009 2nd International Conference on Power Electronics and Intelligent Transportation System (PEITS), pp 77 – 80 37。Huang J, Zeng J, Bai Y, Cheng Z, Qi L, Liang D (2021) Layout optimization of fiber Bragg grating strain sensor network based on modified artificial fish swarm algorithm. Opt Fiber Technol 65 : 102583 38。PIL RS, Hazlie M, Ru WW, Azam MM, Nadzirah MN (2022) 基于基于纤维级算法和线性编程组合的定向过电流继电器的最佳协调。AIN SHAMS ENG J 13 (6) : 10177739。Zhang H, Hao K, Gao L, Wei B, Tang X (2024) 增强了坡度, 可逐步进行可微分的建筑搜索。IEEE跨神经Net W学习系统35 (7) : 9606 – 9620

40. Zhang Z, Guo C, Wei Q, Guo Z, Gao L (2021) 在订购订单多站点的Tex-Tile Manufacturing中的双目标随机订单计划问题。 *Comput Ind Eng* 158 : 10736741。 Liub, Xu M, Gao L (2024) 增强的群智能优化：受到免疫系统中细胞协调的启发。基于知识的Syst 290 : 111557

出版商的注释Springer自然在已发表的地图和机构之后的法律要求方面仍然保持中立。