



一种基于分解和学习自动机的新型多代理体系结构，以杂交多目标元启发术

Islame F. C. Fernandes¹ · Elizabeth F. G. Goldberg² · Silvia M. D. M. Maia²

收到：2023年11月1日 / 接受：2025年4月12日 ©作者，根据Springer-Verlag GmbH德国的独家许可，Springer Nature 2025

抽象的

混合元启发术可以有效地解决多目标优化问题。最近，研究人员对被称为*architectures*的程序产生了兴趣，可以为杂交任意元启发术提供通用的功能和功能。尽管先前提出的多代理体系结构*MO-MAHM*实现了针对双目标问题的高质量解决方案，但其应用于两个以上的目标需要进一步讨论。为此，本文提出了*MO-mahm_E*，*MO-MAHM*处理两个或多个目标的扩展。*MO-mahm_E*维护粒子群优化和多代理范式的概念，包括粒子运动和试剂智能。此外，它使用基于分解的速度运算符，从聚合功能和增强学习自动机方案进行预先介绍来支持代理的决策。本文表明，这些算法组件可以显著改善建筑性能。我们将*MO-mahm_E*应用于最多四个目标的二次分配问题。杂交结合了三种进化算法和局部搜索。介绍了*MO-mahm_E*和十种算法的实验结果（包括二次分配问题文献中的混合方法，超纤维和算法）的实验结果。

关键字杂交·多目标优化·学习自动机·分解

1简介

混合元启发术结合了个体算法的最佳特征。元催化剂杂交已成为单核和多机构共同优化的一种有吸引力的研究领域，因为它具有生产高质量解决方案的潜力。现有的混合元启发术依赖于几种设计技术，其中一些技术由[4]和[46]审查。这些技术通过关注强化和多样化来利用单个算法的潜力。

由于从单个算法中利用最佳功能是一项艰巨的任务，研究人员提出了一项拟议的程序，该程序为促进功能提供了通用的功能

介绍杂交元启发术。这些程序（称为*architectures*）是用于杂交元启发式材料的通用算法，最近获得了研究人员的兴趣[32]。[44]调查并分析了现有的架构。这些研究的大多数都集中在单目标优化和采用的多代理人中，包括代理智能与合作。在这些体系结构中，每个代理都会实现搜索方法（例如元启发式学）来解决问题，并且多个代理可以同时探索搜索空间的不同区域。代理人通过从过去的经验中学习来改善其行为，并通过交换搜索信息来增强元启发互动。尽管多代理系统有益于混合算法的性能，但很少有多目标优化体系结构完全利用此类概念[44]。

[43]和[13]提出了一个多目标杂交结构*MO-MAHM*，灵感来自粒子群的光学化（*PSO*）和多代理概念，其中粒子是智能，自主和合作的代理，这些粒子执行动作以获得接近量的最小解决方案。代理人采用学习策略来改善其行为和

✉ Islame F. C. Fernandes
islame.felipe@ufba.br

¹ Institute of Computing, Federal University of Bahia (UFBA), Ondina, Salvador, Brazil

² Department of Informatics and Applied Mathematics, Federal University of Rio Grande do Norte (UFRN), Campus Universitário, Lagoa Nova, Natal, Brazil

选择适当的执行操作。[13]所提出的代理使用了学习策略中的Hypervolume指标[58], 因此在当前迭代中更有可能在以前的迭代中实现了更高的超音量的动作。但是, [13]观察到MO-MAHM中的学习策略导致粒子执行某些动作并始终如一地忽略了他人。此外, MO-MAHM中的代理执行了一个搜索程序, 该程序模仿PSO的速度运算符以移动搜索空间。[13]提出的速度运算符使用基于帕累托优势的路径链接元启发式, 以探索两组非主导的解决方案之间的搜索空间, 并在它们之间构建轨迹。然而, 作者观察到MO-MAHM中的速度运算符倾向于在与大型帕托前的问题有关的问题上失去选择压力, 从而将试剂排入搜索空间的小区域, 并对解决方案的质量和多样性产生负面影响[6]。尽管MO-MAHM对双目标概率取得的高质量结果, 但其应用于两个以上的目标仍然是一个公开的主题。

本文提出了一个MO-MAHM扩展名为MO-mahm_E, 以处理两个以上的目标。被称为many-objective, 具有两个以上的目标函数的优化问题阻碍了优化者确保在多元化和强度之间保持适当的平衡, 因为非主导溶液的数量随着目标函数的数量而成倍增长[6, 21]。已经开发了几种算法以进行多个目标优化[30、40、51], 包括诸如进化算法[2、27], 群群优化[26、39], 局部搜索[20、33], 路径依次[12]和人工bee bee Clonies [49、55]。尽管以前的作品已经做出了重大的努力, 以将传统的性能能力扩展到多个目标环境中, 但它们都没有提供通用功能来实施混合元尿症以进行多个目标优化。因此, 仍然缺乏多代理体系结构来杂交这些算法。本文没有提出一种新颖的多目标元尿液, 而是提出了一种架构 (MO-mahm_E), 该架构提供了一般过程, 以在多代理系统中杂交自脑的多个多目标元疏疗法。

MO-MAHM_E利用基于分解的速度操作员以及增强学习方案。多目标优化的最新进展具有整体分解和增强学习技术[11, 55]。分解方法主要有利于解决多个目标问题, 因为它们有效地构成和多样化[16]。特定地, MO-mahm_E结合了一个基于分解的速度算子, 源自路径雷神经元数据[12] [12]

口头。增强学习系统具有显著增强的多个目标元启发术[17, 18, 35, 38, 50, 54, 56]。这些系统由与环境相互作用, 执行动作的代理组成, 并接收可能是正面或负面的反馈。重新执行学习的主要目标是训练这些代理, 以最大程度地提高预期的累积积极反馈。在MO-mahm_E中, 采用learning automata (LA)方案来确定每个动作对的过渡概率, 这些概率是根据加固信号 (正或负) 计算的。

这项研究将MO-MAHM_E应用于多目标二次分配问题 (MoQAP), 以评估所提出的体系结构的性能。MoQAP是在许多实际应用中出现的NP-HARD设施解决问题[42]。因为文献中最有效的混合多物体多目标算法结合了审核和局部搜索元启发式学[46], 这项工作研究了两种多种物体的循环算法的杂交杂交[19, 52], a MoQAP localtent transgenten altgen algorten algorithm [1] [1] [1] [1] [1] [1] [1] [1] [1] [1]在最多四个目标和不同级别的基准实例上进行了实验。分析表明了基于分解的速度运行和学习策略的好处。此外, 分析考虑了颗粒合作的影响以及每种算法杂交的贡献。我们将MO-mahm_E的结果与文献中的十种算法获得的结果进行了比较。比较涉及原始体系结构 (MO-MAHM), 三种多目标模因算法 (即, 与局部搜索杂交的进化算法) 和两种混合转化算法[1]。比较包括[29]提出的两个最新的LA基于基于的高纤维术, 因为超纤维是用于杂交算法的框架: HH-LA和HH-RILA。最后, 将MO-mahm_E结果与MoQAP文献的两种算法进行了比较: [28]提出的GRASP和基于分解的局部搜索提出的[5]提出的局部搜索。统计测试表明MO-MAHM_E在有关Hypervolume [58]和倒世代距离指示器[7]的大多数比较上找到了更好的结果。

总之, 本文的主要贡献如下:

1. 一个多代理体系结构, MO-mahm_E, 它提供了通用过程, 以杂交具有三个或更多目标函数的概率。
2. 关于基于分解的速度运算符和基于LA基于架构的学习策略的影响的结果。
3. MoQAP最新的效率混合多代理算法, 可产生与文献的十种算法相结合的竞争结果。

本文的其余部分的组织如下：Section 2介绍MO-mahm_E架构。第3节介绍了MoQAP的应用程序MO-mahm_E。第4节报告并讨论了计算实验。第5节提出了结论和未来的工作。

2 mo-mahm_E：基于分解和学习自动机的多代理架构，用于杂交多目标metaheuristic

本节详细说明MO-mahm_E。第2.1、2.2、2.3和2.4节审查多目标概念，介绍MO-mahm_E一般过程，讨论基于分解的速度操作员，并分别提出一个基于LA基于基于的学习策略。

2.1多目标优化

这项研究认为将多目标问题定义为

$$\min_{x \in X} (f_1(x), \dots, f_q(x)) \quad (1)$$

其中 $q > 1$ 是目标的数量， X 是可行解决方案的集合， $f: X \rightarrow Y$ 是一个分配给每个 $x \in X$ 的函数，目标向量 $f(x) = (f_1(x), \dots, f_q(x)) \in Y$ 和 $Y \subseteq \mathbb{R}^q$ 是目标空间。

“最小化”考虑了帕累托优势关系。一个目标向量 $y = f(x)$ ， $x \in X$ ，主导另一个 $y' = f(x')$ ， $x' \in X$ ，由 $y < y'$ 表示，if and of and of $f_k(x) \leq f_k(x') \forall k \in \{1, \dots, q\}$ and $\exists k \in \{1, \dots, q\}$ 。帕累托优势概念扩展到 X ，因此 $x < x' \Leftrightarrow y < y'$ 。仅当 $\nexists x' \in X$ 时，解决方案 $x \in X$ 是有效的，因此 $x' < x$ 。有效解决方案的集合 $X^* \subseteq X$ 称为帕累托最佳集合。集合 $Y^* = \{f(x) \mid x \in X^*\}$ 称为帕累托（Pareto）最佳前沿。当且仅当 $\forall y, y' \in Y^*$ ， $y \not< y'$ 和 $y' \not< y$ 时，集合 $Y^* \subseteq Y$ 是帕累托（Pareto-Optimal）正面的近似值。

2.2 mo-mahm_E一般过程

MO-mahm_E是MO-MAHM扩展，以处理两个以上的目标函数。MO-MAHM由[13]引入双目标优化，并探索了粒子群优化（PSO）概念，包括合作和代理智能。MO-MAHM维护一组合作的粒子，这些粒子在环境中移动，寻找高质量的位置。每个粒子都是一个自主剂，其位置是一组非主导的解决方案。每个代理都知道其当前位置，这是达到的最佳位置

到目前为止（ $pbest$ ），这是群（ $gbest$ ）实现的最佳位置。

每个代理都可以使用行动，学习和决策策略。动作策略是用于搜索有效解决方案的算法。学习策略使代理人通过学习最佳行动来改善其行为。学习是通过从架构执行过程中从环境中提取信息来进行的。代理使用获得的知识通过称为决策策略的方法选择动作。此外，代理可以在留在原处或使用速度操作员转移到另一个位置之间进行选择。后者是接收两组非主导解决方案（位置）并输出另一组的过程。

Algorithm 1: General MO-MAHM procedure [13]

Input: #numPart : Number of particles

- 1 $AS \leftarrow \text{loadActionStrategies}()$
- 2 $DS \leftarrow \text{loadDecisionStrategies}()$
- 3 $LS \leftarrow \text{loadLearningStrategies}()$
- 4 $gbest \leftarrow \emptyset$
- 5 Initialize a set P with #numPart particles
- 6 **repeat**
- 7 **forall** the $p \in P$ **do**
- 8 runParticles(p)
- 9 **end**
- 10 **until** A stopping criterion is satisfied;
- 11 **return** $gbest$

算法1总结了[13]预先发送的MO-MAHM过程。该算法接收#numPart，这是一个用于粒子数的用户限制参数。第1、2和3行分别代表负载动作，决策和学习策略。第4行初始化 $gbest$ 作为一个空集。第5行使用#numPart粒子创建了一个集合，并初始-izes它们各自的当前位置和 $pbest$ 属性。第6和10行之间的循环执行每个粒子，直到满足用户确定的停止标准为止。第11行输出 $gbest$ 。

Algorithm 2: runParticle procedure [13]

Input: p : Particle

- 1 $l_s \leftarrow p.\text{selectLearningStrategy}()$
- 2 $d_s \leftarrow p.\text{selectDecisionStrategy}()$
- 3 $a_s \leftarrow p.\text{selectActionStrategy}(l_s, d_s)$
- 4 $p.\text{current_position} \leftarrow a_s.\text{runActionStrategy}()$
- 5 update $p.pbest$
- 6 update $gbest$
- 7 $dest \leftarrow \text{chooseDestination}()$
- 8 $p.\text{current_position} \leftarrow \text{velocityOperator}(p.\text{current_position}, dest)$
- 9 $p.\text{runLearningStrategy}()$

算法2总结了[13]提出的粒子程序。第1行和第2行分别选择学习策略 l_s 和决策策略 d_s 。第3行使用 l_s 和 d_s 选择一个动作策略 a_s 。第4行执行 a_s ，而输出的非主导集成为粒子的当前位置。第5行和第6行使用新粒子的当前位置分别更新 $pbest$ 和 $gbest$ 。第8行将部分从目前的位置移至第7行中选择的目的地。第9行更新了学习策略。

MO-MAHM 是一个灵活的框架，因为没有关于动作，学习，决策策略，速度操作员以及所有粒子是否实施相同机制的假设。*MO-mahm_E*继承*MO-MAHM* characteristic，并遵循其一般过程（算法1和2）。如以下各节所述，*MO-mahm_E*中的新颖性是基于分解的速度运算符和基于LA的学习策略。根据[46]提出的分类学，*MO-mahm_E*杂交了自我包含的算法，这些算法像团队合作系统一样，用于找到接近最佳的解决方案。这些特征从标准多个目标优化器[57]差异化*MO-MAHM_E*。

2.3 基于分解的速度运算符

所提出的速度操作员使用基于分解的路径链接过程[12]。路径链接是[14]在单目标上下文中介绍的一种元神经，以探索两个解决方案之间的轨迹 s 和 t 。 $s = x(1), \dots, x(i), \dots, x(r) = t$ 表示从 s 到 t 的轨迹，其中 $x(i)$ ， $1 < i < r$ ，代表中间解决方案和 r 表示轨迹长度。一个路径生成过程计算中间解决方案并从 $x(i)$ 的邻居中获得 $x(i+1)$ 和 $1 \leq i < r$ ，因此 $x(i+1)$ 比 t 比 s 更相似 $x(i)$ 。速度操作员依靠分解客观空间，并在解决方案的多样性和多样性之间取得适当的平衡。令 $N = \{\gamma^1, \dots, \gamma^{|N|}\} \subset \mathbb{R}^q$ ， $q \geq 2$ 为一组 $|N|$ 均匀分布的非阴性方向向量，其中 $|N|$ 代表一个用户定义参数。该方法将目标空间 Y 分解为 $|N|$ 子区域 $Y^1, \dots, Y^{|N|}$ ，其中 Y^j ， $j = 1, \dots, |N|$ ，代表与 γ^j 相关的子区域。无需聚合功能。

令 A 为一组非主导的解决方案。等式(2)将每个目标向量 $f(x)$ ， $x \in A$ 归一化，其中 $LB \in \mathbb{R}^q$ 和 $UB \in \mathbb{R}^q$ 均在较低和上限上，从而使得。公式(3)计算 γ^j 和 $f_{norm}(x)$ 之间的角度的余弦，用 $\Delta(f(x), \gamma^j)$ 表示，其中 $\|\cdot\|$ 是欧几里得的标准。该方法将 A 中的解决方案划分为 $|N|$ 子集 $S^1, \dots, S^{|N|}$ ，其中 S^j ($j = 1, \dots, |N|$)是与子区域 Y^j 相关的解决方案的子集，并包含了该 $\Delta(f(x), \gamma^j)$ 的溶液。有一个

与每个子区域 Y^j 有关的理想点 $I^j \in \mathbb{R}^q$ 。 I^j 是沿方向向量 γ^j [39]的原点距离最小距离的点。

$$f_{norm}(x) = \frac{f(x) - LB}{UB - LB} \quad (2)$$

$$\Delta(f(x), \gamma^j) = \frac{\gamma^j \cdot f_{norm}(x)}{\|\gamma^j\| \|f_{norm}(x)\|}, j = 1, \dots, |N| \quad (3)$$

最小化从 $f_{norm}(x)$ 到 I^j $\|I^j - f_{norm}(x)\|$ 表示 I^j 的欧几里得距离将解决方案在 S^j 中的收敛促进了 S^j 向 I^j 的收敛性。公式(4)计算 $\Delta(f(x), \gamma^j)$ 和 $\|I^j - f_{norm}(x)\|$ 之间的比率，以确保解决方案的质量和多样性，该质量和多样性由 $CAD(x, j)$ [39]表示。 $CAD(x, j)$ 越高，近距离 $f_{norm}(x)$ 对 Y^j 和 I^j ；因此，越好是 $f(x)$ 。

$$CAD(x, j) = \frac{\Delta(f(x), \gamma^j)}{\|I^j - f_{norm}(x)\|}, j = 1, \dots, |N| \quad (4)$$

基于分解的速度运算符在两个输入近似集 A 和 B 的解决方案之间执行路径链接轨迹。一组非阴性导向向量 N 是输入参数。任何创建均匀分布在目标空间上的方向向量的方法都可以计算 N 。理想点 $I^1, \dots, I^{|N|}$ 也是输入参数。该方法第一个将解决方案划分为 A 和 B 中的解决方案 $S^1, \dots, S^{|N|}$ 。对于每个 $j = 1, \dots, |N|$ ，速度操作员选择两个解决方案 $s, t \in S^j$ 并生成一个路径链接轨迹 $s = x(1), \dots, x(r) = t$ ，由 $CAD(x(i), j)$ 指导， $CAD(x(i), j)$ ， $i = 1, \dots, r$ 。子集 $S^1, \dots, S^{|N|}$ 在轨迹中使用非主导的解决方案进行更新。速度运算符输出一个最多包含 $|N|$ 良好传播的解决方案的集合。

算法3概述了基于分解的速度运算符。第1行初始化 S^j ， $j = 1, \dots, |N|$ 。第2行和第3行分别以 A 和 B 分别分配到 S^j ， $j = 1, \dots, |N|$ (过程 $distributeSolutions$)的子集 S^j 。第4行更新理想点 $I^1, \dots, I^{|N|}$ (过程 $computeIdealPoints$)。对于每个 $j = 1, \dots, |N|$ ，该算法会在 S^j 中生成一个向后轨迹[41]连接两个解决方案 x' 和 x'' 。起始解决方案是具有最佳 CAD (第9和11)的最佳解决方案。目的是用最佳的 CAD 来促进解决方案附近的搜索。SET Arc存储通过路径Generation获得的非主导的解决方案。第14行将解决方案以Arc的速度分配到子集 $S^1, \dots, S^{|N|}$ 中。第15行更新理想点。该算法使用二进制锦标赛的变体来选择输出解决方案。第16行将集合 C 初始化为空集。对于每个 $j = 1, \dots, |N|$ ，第18行选择两个解决方案 x' 和 x'' 在 S^j 中随机选择，第19行选择具有最佳 CAD 的一个，然后第20行将其添加到 C 中，而无需验证Pareto Pareto shore。该算法输出 C 。

Algorithm 3: Decomposition-based velocity operator

Input : A, B : approximation sets
 $N = \{\gamma^1, \dots, \gamma^{|N|}\}$: Set of direction vectors
 I^j : Ideal point related to γ^j , for $j = 1, \dots, |N|$

Output: C : Set of solutions

```

1  $S^j \leftarrow \emptyset, \forall j = 1, \dots, |N|$ 
2  $distributeSolutions(A, N, S^1, \dots, S^{|N|})$ 
3  $distributeSolutions(B, N, S^1, \dots, S^{|N|})$ 
4  $computeIdealPoints(N, S^1, \dots, S^{|N|}, I^1, \dots, I^{|N|})$ 
5  $Arc \leftarrow \emptyset$ 
6 foreach  $j = 1, \dots, |N|$  do
7   Let  $x', x''$  be two solutions in  $S^j$ 
8   if  $CAD(x', j) > CAD(x'', j)$  then
9      $path\_generation(x', x'', j, Arc)$ 
10  else
11     $path\_generation(x'', x', j, Arc)$ 
12  end
13 end
14  $distributeSolutions(Arc, N, S^1, \dots, S^{|N|})$ 
15  $computeIdealPoints(N, S^1, \dots, S^{|N|}, I^1, \dots, I^{|N|})$ 
16  $C \leftarrow \emptyset$ 
17 foreach  $j = 1, \dots, |N|$  do
18   Select two solutions randomly,  $x', x''$ , in  $S^j$ 
19    $\hat{x} \leftarrow \arg \max \{CAD(x, j) \mid x \in \{x', x''\}\}$ 
20   Add  $\hat{x}$  to  $C$ 
21 end
22 return  $C$ 

```

Algorithm 4: *distributeSolutions* procedure

Input : A : Approximation set
 $N = \{\gamma^1, \dots, \gamma^{|N|}\}$: Set of direction vectors
 S^j : Subset of solutions related to γ^j , for $j = 1, \dots, |N|$

Output: S^j : Subset of solutions related to γ^j , for $j = 1, \dots, |N|$

```

1  $\forall x \in A, x$  is not marked
2 foreach  $j = 1, \dots, |N|$  do
3    $x' \leftarrow \arg \max \{\Delta(f(x), \gamma^j) \mid x \in A \text{ and } x \text{ not marked}\}$ 
4   mark  $x'$ 
5   add  $x'$  to  $S^j$ 
6 end

```

算法3第2、3和14中的*distributeSolutions*过程接收一组非主导的解决方案（例如， A ），设置 N 和subsets $S^1, \dots, S^{|N|}$ 。该过程将 A 中的解决方案分配到 $S^1, \dots, S^{|N|}$ 中。对于每个 $j = 1, \dots, |N|$ ，它将最大 $\Delta(f(x'), \gamma^j)$ 的解决方案 $x' \in A$ 添加到 S^j 中，因此未选择 x' 。目的是避免在子集中使用重复的解决方案。算法4概述了过程*distributeSolutions*。

[39]提出的方法称为*computeIdealPoints*，计算理想点。 $I^j, j = 1, \dots, |N|$ ，是在 γ^j 上投射的点，与原点的距离很小。公式（5）定义 γ^j 上的 $f_{norm}(x)$ 的标量投影 $\Psi(f(x), \gamma^j)$ ，用于所有 $j = 1, \dots, |N|$ 和 $x \in S^j$ ，其中 $\|\cdot\|$ 是euclidean norm。对于每个 $j = 1, \dots, |N|$ ，程序识别最低 $\Psi(f(x), \gamma^j), x \in S^j$ ，并将其分配给 ψ 。 I^j 设置为 $\psi\gamma^j$ ，如果 $\psi\gamma^j$ 主导 I^j 。算法5

概述*computeIdealPoints*过程。

$$\Psi(f(x), \gamma^j) = \frac{\gamma^j \cdot f_{norm}(x)}{\|\gamma^j\|}, j = 1, \dots, |N| \quad (5)$$

Algorithm 5: *computeIdealPoints* procedure

Input : $N = \{\gamma^1, \dots, \gamma^{|N|}\}$: Set of direction vectors
 S^j : Subset of solutions related to γ^j , for $j = 1, \dots, |N|$
 I^j : Ideal point related to γ^j , for $j = 1, \dots, |N|$

Output: I^j : Ideal point related to γ^j , for $j = 1, \dots, |N|$

```

1 foreach  $j = 1, \dots, |N|$  do
2    $\psi \leftarrow \min \{\Psi(f(x), \gamma^j) \mid x \in S^j\}$ 
3   if  $\psi\gamma^j < I^j$  then
4      $I^j \leftarrow \psi\gamma^j$ 
5   end
6 end

```

Algorithm 6: *path_generation* procedure

Input : s : Starting solution,
 t : Targeting solution,
 j : Sub-problem index,
 Arc : Set of non-dominated solutions

Output: Arc : Set of non-dominated solutions

```

1  $i \leftarrow 1$ 
2  $x(i) \leftarrow s$ 
3 while  $M(x(i), t) \neq \emptyset$  do
4    $m^* \leftarrow \arg \max \{CAD((x(i) \oplus m), j) \mid m \in M(x(i), t)\}$ 
5    $x(i+1) \leftarrow x(i) \oplus m^*$ 
6   Add  $x(i+1)$  to  $Arc$  and filter  $Arc$ , if necessary
7    $i \leftarrow i + 1$ 
8 end

```

*path_generation*过程接收一个启动解决方案 s ，一个目标解决方案 t ，子问题索引 $j \in \{1, \dots, |N|\}$ ，以及存档 Arc 以存储非主导的解决方案。该过程构建轨迹 $s = x(1), \dots, x(r) = t$ 连接 s 和 t 。我们表示可以应用于 $x(i)$ 来生成一个中间解决方案 $x(i+1)$ 的候选日期操作，而不是 $M(x(i), t)$ ， $M(x(i), t), i = 1, \dots, r-1$ 。每个ITERATION， $i = 1, \dots, r-1$ ，过程选择 $m^* \in M(x(i), t)$ ，使得 $CAD(x(i) \oplus m^*, j)$ 是最大的，并获得 $x(i+1) = x(i) \oplus m^*$ 。此步骤可以消耗额外的评估来计算候选解决方案的目标函数和CAD指示器。所有功能评估均在 $\#num_eval$ 中计算。下一步将 $x(i+1)$ 添加到 Arc 中，并在必要时删除主导的解决方案。算法6概述了*path_generation*过程。

2.4 学习策略

MO-mahm_E 使用基于[29]实现的 *LA* 模型的在线学习策略。作者提出了两个基于 *HH-LA* 和 *HH-RILA* 的基于 *LA* 的多目标超透明术，它们维护一组解决方案和一组低级启发式学（动作）。*LA* 模型使用超量卷积改进[58]计算每对动作的过渡概率和奖励/惩罚率[58]。在每次迭代中，*HH-LA* 和 *HH-RILA* 都使用过渡概率选择低级启发式，并将其应用于当前人群。[29]中报道的实验表明，*LA* 有益多物镜选择超毛术。

这项研究改编了[29]提出的模型，以确定 *pbest* 和 *gbest* 上促进的改进。令 $(AS, \phi, \mathbb{P}, \mathbb{U})$ 为四倍，其中 *AS* 是在 *MO-mahm_E* 中实现的有限的动作策略集， ϕ 是增强信号， $\mathbb{P}$ 是一个过渡矩阵， $\mathbb{U}$ 是更新的方案。对于所有 $\hat{a}, a \in AS$ ，矩阵 $\mathbb{P}$ 中都有一个条目。 $\mathbb{P}_{(\hat{a}, a)}(\tau)$ 表示 τ -th 搜索步骤在 $\hat{a}$ 上从 $\hat{a}$ 切换到 a 的过渡概率。 $\phi(\tau)$ 表示 p 在 p 之后从环境中接收的强化信号，该信号在 τ -th step 上应用动作策略后从环境中接收。 $\phi(\tau) = 1$ 如果操作成功改善 *pbest* 或 *gbest*，而 $\phi(\tau) = 0$ 否则。可以使用适合评估非主导集质量的质量指数或技术来衡量改进。对于所有 $\hat{a}, a \in AS$ ， $\xi_{(\hat{a}, a)}(\tau) \in [0, 1]$ 代表 τ -th 步骤，与从 $\hat{a}$ 到 a 的过渡相关的奖励/惩罚率。

以下是我们用 a 和 a' 分别在 $(\tau - 1)$ -th 和 τ 的步骤中使用的动作策略 p 。等式 (6) 更新概率 $\mathbb{P}_{(a, a')}(\tau + 1)$ 。公式 (7) 更新 $\mathbb{P}_{(a, a'')}(\tau + 1)$ ，对于所有 $a'' \in AS, a'' \neq a'$ ，其中 $|AS|$ 是动作策略的数量。

$$\begin{aligned} & \mathbb{P}_{(a, a')}(\tau + 1) \\ &= \begin{cases} \mathbb{P}_{(a, a')}(\tau)(1 - \xi_{(a, a')}(\tau)) + \xi_{(a, a')}(\tau) & \text{if } \phi(\tau) = 1 \\ \mathbb{P}_{(a, a')}(\tau)(1 - \xi_{(a, a')}(\tau)) & \text{if } \phi(\tau) = 0 \end{cases} \end{aligned} \quad (6)$$

$$\begin{aligned} & \mathbb{P}_{(a, a'')}(\tau + 1) \\ &= \begin{cases} \mathbb{P}_{(a, a'')}(\tau)(1 - \xi_{(a, a'')}(\tau)) & \text{if } \phi(\tau) = 1 \\ \mathbb{P}_{(a, a'')}(\tau)(1 - \xi_{(a, a'')}(\tau)) + \frac{\xi_{(a, a'')}(\tau)}{|AS| - 1} & \text{if } \phi(\tau) = 0 \end{cases} \end{aligned} \quad (7)$$

对于所有 $\hat{a}, a \in AS$ ，估计了 *pbest* 和 *gbest* 上产生的改进。 $Pb_{(\hat{a}, a)}(\tau)$ 和 $Gb_{(\hat{a}, a)}(\tau)$ 分别是 τ 的 τ -th 步骤的累积改进，分别在 *pbest* 和 *gbest* 上分别相关。等式 (8) 计算奖励/惩罚率 $\xi_{(\hat{a}, a)}(\tau)$ ， $\forall \hat{a}, a \in AS$ 。

用户定义的系数 v_{pb} 和 v_{gb} 分别放大了 $Pb_{(\hat{a}, a)}(\tau)$ 和 $Gb_{(\hat{a}, a)}(\tau)$ 的效果。如果 $\xi_{(\hat{a}, a)}(\tau) > 1$ ，则将其设置为 1。我们使用的最小固定速率为 0.1，以避免 $\xi_{(\hat{a}, a)}(\tau) = 0$ ，如[29]所建议。

$$\xi_{(\hat{a}, a)}(\tau) = 0.1 + v_{pb} Pb_{(\hat{a}, a)}(\tau) + v_{gb} Gb_{(\hat{a}, a)}(\tau) \quad (8)$$

在 τ -th 步骤执行 a' 之后，粒子 p 测量 *pbest* 和 *gbest* 的质量。我们分别用 $Q_{pb}(\tau)$ 和 $Q_{gb}(\tau)$ 分别表示 *pbest* 和 *gbest* 的质量。随着一般性的损失，更大的 Q_{pb} 和 Q_{gb} 值表示质量更好。如果 $Q_{pb}(\tau) > Q_{pb}(\tau - 1)$ 执行 a' 后，差异 $\delta_{pb}(\tau) = Q_{pb}(\tau) - Q_{pb}(\tau - 1)$ 可以在 *pbest* 上启用 a' 在步骤 τ 结束时 *pbest* 上产生的改进。 $\delta_{gb}(\tau)$ 对 $Q_{gb}(\tau)$ 和 *gbest* 的类似。方程 (9) 和 (10) 计算 $Pb_{(a, a')}(\tau)$ 和 $Gb_{(a, a')}(\tau)$ ，分别是分解的。对于所有 $a'' \in AS, a'' \neq a'$ ，方程 (11) 和 (12) 分别计算 $Pb_{(a, a'')}(\tau)$ 和 $Gb_{(a, a'')}(\tau)$ 。如[29]的建议，以前的 $Pb_{(a, a'')}(\tau - 1)$ 和 $Gb_{(a, a'')}(\tau - 1)$ 以 0.1 的固定速率降低。目标是为过去的改进分配减少重量。

$$\begin{aligned} & Pb_{(a, a')}(\tau) \\ &= \begin{cases} 0.9 Pb_{(a, a')}(\tau - 1) + 0.1 \delta_{pb}(\tau) & \text{if } \delta_{pb}(\tau) > 0 \\ 0.9 Pb_{(a, a')}(\tau - 1) & \text{otherwise} \end{cases} \end{aligned} \quad (9)$$

$$\begin{aligned} & Gb_{(a, a')}(\tau) \\ &= \begin{cases} 0.9 Gb_{(a, a')}(\tau - 1) + 0.1 \delta_{gb}(\tau) & \text{if } \delta_{gb}(\tau) > 0 \\ 0.9 Gb_{(a, a')}(\tau - 1) & \text{otherwise} \end{cases} \end{aligned} \quad (10)$$

$$Pb_{(a, a'')}(\tau) = 0.9 Pb_{(a, a'')}(\tau - 1) \quad (11)$$

$$Gb_{(a, a'')}(\tau) = 0.9 Gb_{(a, a'')}(\tau - 1) \quad (12)$$

3 mo-mahm_E 应用到 MOQAP

多目标二次分配问题 (*MoQAP*) 是用于多目标优化的二次分配问题 (*QAP*) 的扩展。[25] 首先引入，*QAP* 是一个设施问题，考虑到设施之间的位置与流量之间的距离。目的是将设施分配到位置，以使距离和相应流的产品总和最少。*MoQAP* 模型的场景与 $q \geq 2$ 流度之间的场景模型。

令 $\mathbb{A} = (\alpha_{ij})$ 为 n -square 矩阵，其中 α_{ij} 是位置 i 和 j ， $1 \leq i, j \leq n$ 之间的距离。对于每个目标 k ， $1 \leq k \leq q$ ，有一个 n -square 矩阵 $\mathbb{B}^k = (\beta_{ij}^k)$ ，其中 β_{ij}^k 是 k -th flow 设施 i 到 j 。可行的解决方案是集合 $\{1, \dots, n\}$ 的置换 π ，其中 π_i 是 i -th 设施的位置。*MoQAP* 最小化 $f(\pi) = (f_1(\pi), \dots, f_q(\pi)) \in \mathbb{R}^q$ ，其中等式 (13) 定义 $f_k(\pi)$ ， $1 \leq k \leq q$ 。当 $\mathbb{A}$ 和 $\mathbb{B}^k$ 时，问题是对称的

$1 \leq k \leq q$, are symmetric.

$$f_k(\pi) = \sum_{i=1}^n \sum_{j=1}^n \alpha_{ij} \beta_{\pi_i \pi_j}^k, \forall k \in \{1, \dots, q\} \quad (13)$$

*MoQAP*及其单目标对应物是NP-hard问题[42]。现有有关此主题的研究包括基于掌握, 进化算法, 本地搜索和混合方法的启发式方法。有关这些方法的最新研究是[28]和[5]。

第3.1节描述了在体系结构(行动策略)中杂交的算法。第3.2节介绍*MO-mahm E*实现。

3.1次要的行动策略

针对双目标实例实施的动作策略是转化算法(TA) [1], *NSGA-II* [10], *a MOEA/D* [53]和局部搜索(*MPLS*) [20]。对于具有两个以上目标的实例, 动作策略为TA, *A-NSGA-III* [19], *MOEA/D-DU* [52]和*MPLS*。因为*NSGA-II*和*MOEA/D*适用于双向目标问题, 并且在处理越来越多的目标时面对困难[19, 52], 我们实施了其各自的状态, 用于具有三个或多个目标的实例:(*A-NSGA-III*和*MOEA/D-DU*)。

3.1.1转基因算法

TA是模拟水平基因转移和内共生的进化方法[15]。他们采用搜索机制(称为*transgenetic vectors*)在解决方案人群(称为*endosymbionts*)和遗传信息存储库(称为*host cell*)之间交换遗传信息。

TA [1]为*MoQAP*提出的*Pop*维持*#popSize* *endosymbionts*, 其中*#popSize*代表一个用户删除的参数。内共生体是*MoQAP*可行解决方案。TA以随机生成初始*popula*, 并使用*a priori*和*a posteriori*信息初始化主机的存储库。*a priori*存储库存储通过强大的禁忌搜索算法获得的解决方案[45]。抽吸标准是按等式(14)定义的tchebycheff函数, 其中 $y^* = (y_1^*, \dots, y_q^*)$ 是理想的点, $\lambda = (\lambda_1, \dots, \lambda_q) \in \mathbb{R}^q$ 是一个随机的权重向量满足方程(15)。*a posteriori*存储库存储*#sizeRepo*解决方案, 其中*#sizeRepo*是一个用户删除的参数。基于目标之和, *Pop*中的最初*a posteriori*存储库包含*Pop*中的最佳内共生体

值。

$$f_{TCH}(\pi|\lambda) = \max_{1 \leq k \leq q} \{\lambda_k | f_k(\pi) - y_k^* | \} \quad (14)$$

$$\sum_{k=1}^q \lambda_k = 1 \quad (15)$$

TA实现两种类型的转基因载体: 质粒和转座子。质粒包括遗传信息和将其插入内共生膜中的方法。令 π 成为一个随机解决方案, 从主机存储库中统一的概率选择。质粒的遗传信息是一串随机对 (i, π_i) , $i \in \{1, \dots, n\}$ 。遗传信息的长度是随机的, 来自间隔 $[3, 3 + 0.25n]$ 。令 π' 为*Pop*的内孢子虫。对于信息字符串中的每个对 (i, π_i) , 质粒识别索引*j*, 以便 $\pi'_j = \pi_i$ 并交换 π'_i 和 π'_j 。

转座是重新排列内共生术的碎片的规则。在TA中实现的转座子使用鲁棒的禁忌搜索[45]。该方法使用tchebycheff函数探索了内共生膜连续片段的邻域。片段的长度是随机的, 来自间隔 $[\frac{n}{2}, n]$ 。

转基因载体在每种迭代中都操纵内共生体。用户定义参数*#probPlasm*是应用质粒的概率; 施用转座子的概率为 $1 - \#probPlasm$ 。对于*#intGerSet*连续迭代, *#probPlasm*的值保持固定, 然后, 它以*#probFactor*的速度减小。*#intGerSet*和*#probFactor*是用户定义参数。在这项研究中, TA维护非主导解决方案的全局档案*G_A*。如果 $\pi'' < \pi'$ 在 $\pi'' < \pi'$ 中, 或者在*G_A*中, 则由质粒或转座操作产生的内*osymbiont* π'' 替换*Pop*中的原始*endosymbiont* π' 。该过程将 π'' 添加到*G_A*并删除主导的解决方案。如果 π'' 根据目标值的总和更好, 那么*a posteriori*存储库中最坏的内共生膜, 则 π'' 替换它。

3.1.2 NSGA-II和A-NSGA-III

非主导分类遗传算法II (*NSGA-II*) [10]使用*#sizePop*解决方案维护一个总体*Pop*。在每次迭代中, 该算法都应用遗传操作员(对选择, 重组和突变), 以与*#sizePop*个体创建后代人群*Pop*。该过程将解决方案从*Pop* $\cup$ *Pop*分类为非义务的不同列表(前面)。第一个前沿*F*₁包含*Pop* $\cup$ *Pop*的非主导的解决方案, 第二个正面*F*₂来自*Pop* $\cup$ *Pop* - *F*₁的解决方案, 依此类推。

下一个迭代的总体包括*#sizePop*解决方案, 根据序列*F*₁, *F*₂, ...选择。如果*l*-th front (*F*_{*l*}) 插入超过*#sizePop*

然后, *NSGA-II* 选择从 F_l 的拥挤距离度量最大的解决方案来完成下一个总体。解决方案的拥挤距离可以测量其在目标空间中两个最近的邻居之间的距离。

NSGA-II 事实证明对双向目标有效。但是, 由于非主导解决方案的指数数量和计算拥挤距离的昂贵成本, 它为超过两个目标产生了低质量的解决方案[9]。

A-NSGA-III 通过根据[19]引入 $\#sizePop$ 的集合 $W \subseteq \mathbb{R}^q$ 定义的 $W \subseteq \mathbb{R}^q$ 定义的 $W \subseteq \mathbb{R}^q$ 定义的 F_l 方案从[19]引入的参考点来处理这些差异。第一个步骤使观察矢量归一化; 第二步将 $F_1, \dots, F_l$ 的个体与垂直距离有关的最接近的参考点关联。等式 (16) 从解决方案 π 到参考点 $w \in W$ 定义了垂直距离 $d^\perp(\pi|w)$ 。该过程迭代地插入下一个与参考点相关的 F_l 的解决方案与最小关联数量相关的解决方案。最后一步 - 是否存在与没有解决方案相关的参考点。因为这样的“无用”参考点不会促进搜索并恶化算法 performance, 所以 *A-NSGA-III* 将其删除并生成新的。

$$d^\perp(\pi|w) = \|f(\pi) - w \left(\frac{f(\pi)^T w}{\|w\|^2} \right)\| \quad (16)$$

在这项研究中, 我们为 Bi-Objective *MoQAP* 实例实现了一个 *NSGA-II*, 并对 *A-NSGA-III* 实现了两个以上的 objectives。初始人口由随机解决方案组成。在每次迭代中, $\#rateCross$ 和 $\#rateMut$ 参数分别定义分别应用交叉和突变操作员的概率。我们使用了[37]提出的单点交叉和移位突变。交叉选择一个随机点 i , 并将第一个 i 的第一个 i 值复制到后代解决方案。对于第二个父母的每个值, 当值不在后代解决方案中时, 该过程将其复制到孩子。Shift 突变选择解决方案的两个随机位置 π (说 i' 和 i''), 在位置 i'' 中插入 $\pi_{i'}$, 然后将其他元素移至一个位置。

3.1.3 moea/d 和 moea/d-du

[53] 引入的基于分解的多目标进化算法 (*MOEA/D*) 维护了一组解决方案 Pop 和一组权重向量 $\Lambda \subseteq \mathbb{R}^q$ 。用户定义的参数 $\#popSize$ 表示 Pop 和 Λ 中的元素数字。解决方案 $\pi^j \in Pop$, $j = 1, \dots, \#popSize$, 是 $\lambda^j = (\lambda_1^j, \dots, \lambda_q^j) \in \Lambda$ 定义的 j -th 子问题的当前解决方案。 j -子问题最小化 tchebycheff 函数 $f_{TCH}(\pi|\lambda^j)$ 。 $\mathfrak{N}(j)$ 是 $\#neighb$ 的集合, 最接近的权重向量与 λ^j 有关欧几里得距离。在每个迭代中 $j =$

$1, \dots, \#popSize$, 从 $\mathfrak{N}(j)$ 随机选择两个索引 j' 和 j'' , 然后从 $\pi^{j'}$ 和 $\pi^{j''}$ 中选择遗传运算符。

对于每个 $j''' \in \mathfrak{N}(j)$, 如果 $f_{TCH}(\pi|\lambda^{j''}) \leq f_{TCH}(\pi^{j'''}|\lambda^{j''})$, 则 π 在 Pop 中替换 $\pi^{j'''}$ 。尽管 *MOEA/D* 在双目标问题上产生了令人满意的结果, 但它在多个目标的问题上的多样性和收敛之间的平衡很差[52]。*MOEA/D-DU* 是[52]提出的扩展, 用于处理两个以上的目标。该算法计算人群中所有 π 的差异 $\|f(\pi) - y^*\|$, 其中 y^* 是理想的观点。在每个迭代中 $j = 1, \dots, \#popSize$, 遗传操作员从 $\pi^{j'}$ 和 $\pi^{j''}$ 中 create create sustspring 解决方案 π 和 $\pi^{j'}$, 其中 j' 从 $\mathfrak{N}(j)$ 或从 $\mathfrak{N}(j)$ 或 $v73$ 或 $v73$ $v74$ 中选择 j' 。用户定义的参数 $\#probNeighb \in [1, 0]$ 是使用 $\mathfrak{N}(j)$ 的概率。使用 $\{1, \dots, \#popSize\}$ 的可能性为 $1 - \#probNeighb$ 。该算法计算每个 $\lambda \in \Lambda$ 在公式 (16) 中定义的 perpendicular 距离 $d^\perp(\pi|\lambda)$, 并选择 $\#maxReplc$ 的最小距离, 其中 $\#maxReplc \leq \#popSize$ 是一个用户 defined parameter。如果存在 $\lambda^{j''}$, j'' 范围从 1 到 $\#maxReplc$, 则 $f_{TCH}(\pi|\lambda^{j''}) < f_{TCH}(\pi^{j'''}|\lambda^{j''})$, 则 π 在 Pop 中代替 $\pi^{j'''}$ 。

在这项研究中, 我们用两个目标实现了 *MOEA/D* 的 *MOEA/D*, *MOEA/D-DU* 进行了两个以上的 objectives。我们使用了第 3.1.2 节中描述的初始种群, 跨界和突变操作员。

3.1.4 Mpls

Pareto Local Search (*PLS*) 是一种基于多目标组合选择问题的帕累托优势的本地搜索技术。给定一组非主导的解决方案 S , *PLS* 迭代选择了随机解决方案 $\pi \in S$, 探索 π 的邻域, 更新 S 的 S , 并用 π 的非主导邻居 π , 并从 S 中恢复了 π 的邻居。该算法在探索 S 中的所有解决方案后停止。除了需要昂贵的计算工作来探索所有解决方案之外, *PLS* 在执行过程中的任何时候都不会保证任何时间的行为, 即, 它不能保证在执行过程中的任何时间。

[20] (*MPLS*) 提出的 *PLS* 变体处理两个或多个目标, 并随时改进搜索行为。作者介绍了选择 $\pi \in S$, 探索 π 的邻域并更新 S 的邻域。在每次迭代中, *MPLS* 都会生成一个随机的权重向量 $\lambda \in \mathbb{R}^q$ 满足 (15) 并选择 $\pi \in S$, 使得 $f_{TCH}(\pi|\lambda)$ 是最小值。算法探索 $\#maxNeighb$ π 的随机邻居, 其中 $\#maxNeighb$ 是一个参数。我们的 *MPLS* 实现 *MoQAP* 使用 2-*opt* 邻域。 π 的邻居 π' S 如果 π 或 S 的任何解决方案均未占主导地位

π' 。MPLS将解决方案从S递归分为不同的结合子集，这些子集与相互作用的树数据结构的内部节点相关联，以有效地更新S。每个子集都存储与相应子树相关的目标向量的理想点和NADIR点。更新过程通过将 π' 与理想点和Nadir点进行比较，丢弃了树中的许多分支。

3.2 mo-mahm_E实现

在MO-mahm_E算法中，参数 $|N|$ 和 $\#numPart$ 分别表示方向向量集和粒子数的基数。用于计算 N 的方法，由[36]提出，计算 σ (方程 (17))，这是用于计算 q 非负整数 $\varphi_1, \dots, \varphi_q$ (方程的计算组合的参数 (18))。等式 (19) 计算 $\gamma^j = (\gamma_1^j, \dots, \gamma_q^j)$, $j = 1, \dots, |N|$ 。

$$|N| = \frac{\prod_{k=1}^{q-1} (\sigma + k)}{(q-1)!} \quad (17)$$

$$\varphi_1 + \dots + \varphi_q = \sigma, \quad \varphi_k \in \{1, \dots, \sigma\}, k \in \{1, \dots, q\} \quad (18)$$

$$\gamma_k^j = \frac{\varphi_k}{\sigma}, \quad k \in \{1, \dots, q\} \quad (19)$$

P 用 $\#numPart$ 粒子表示集合。粒子的位置是一组非主导的溶液。每个 $p \in P$ 都知道其当前位置，并且是到目前为止所实现的最佳位置，称为 $p.pb_{best}$ 。此外，对于学习策略，过渡概率矩阵 $p.\mathbb{P}$ 和指示矩阵 $p.Pb$ 与 p 关联。对于速度运算符，一组理想点 $p.I^1, \dots, p.I^{|N|} \in \mathbb{R}^q$ 与 p 关联。 $gbest$ 是群体实现的最佳位置，矩阵 Gb 存储LA方案使用的 $gbest$ 上的累积改进。

算法7概述了MO-mahm_E实现MoQAP。第1行计算 N 。第2行初始化动作策略的集合 AS 。对于双向实例， TA ， $NSGA-II$ ， $MOEA/D$ 和 $MPLS$ 是动作策略；对于两个以上的目标， TA ， $A-NSGA-III$ ， $MOEA/D-DU$ 和 $MPLS$ 。第3和4行分别初始化 $gbest$ 和 Gb 。第5行创建 P ，以使 N ， AS ， $gbest$ 和 Gb 是所有粒子可用的全局变量。对于每个 $p \in P$ ，第6和12行之间的循环初始化了粒子的信息： $current_position$ ， $p.pb_{best}$ ， $p.\mathbb{P}$ ， $p.Pb$ 和 $p.I^1, \dots, p.I^{|N|}$ 。第13和17行之间的循环执行颗粒，直到符合停止标准为止。在这项研究中，停止标准是目标函数评估的数量 $\#num_eval$ 。第3.2.1节详细介绍了粒子过程，称为 $runParticle$ 。该算法在末端输出 $gbest$ (第18行)。

Algorithm 7: MO-MAHM_E for the MoQAP

Input: $|N|$: number of direction vectors
 $\#numPart$: number of particles

```

1 Compute set  $N = \{\gamma^1, \dots, \gamma^{|N|}\}$ 
2  $AS \leftarrow loadActionStrategies()$ 
3  $gbest \leftarrow \emptyset$ 
4  $Gb(\hat{a}, \bar{a}) \leftarrow 0.0, \forall \hat{a}, \bar{a} \in AS$ 
5 Create  $P$  with  $\#numPart$  particles
6 forall the  $p \in P$  do
7    $p.current\_position \leftarrow$  random position
8    $p.pb_{best} \leftarrow p.current\_position$ 
9    $p.\mathbb{P}(\hat{a}, \bar{a}) = 0.25, \forall \hat{a}, \bar{a} \in AS$ 
10   $p.Pb(\hat{a}, \bar{a}) \leftarrow 0.0, \forall \hat{a}, \bar{a} \in AS$ 
11   $p.I^j \leftarrow \gamma^j, \forall j = 1, \dots, |N|$ 
12 end
13 repeat
14   forall the  $p \in P$  do
15      $runParticles(p)$ 
16   end
17 until satisfying a stop criterion;
18 return  $gbest$ 
```

3.2.1粒子实现

所有粒子在第2.4节中详细介绍的学习自动机。相关工作中的学习策略[13, 29]使用Hypervolume Unary指标[58]来评估搜索中近似集的质量。高频测量以近似集为主的物镜空间中的体积。这项研究实现了[47]提出的超伏近似值(HV_{apx})，因为超Volume计算的复杂性随目标的数量而增长。 HV_{apx} 评估了粒子当前位置的质量， $pbest$ 和 $gbest$ 。Hypervolume需要一个参考点才能绑定目标空间。我们使用[24]解决的方法来计算它。此方法正常 - 在 $[1, 2]$ 范围内的每个目标，并使用 $(2.1, \dots, 2.1)$ 作为参考点。

粒子实施[29]提出的决策策略。在 $(\tau - 1)$ -th步骤， p 选择一个操作 $a' \in AS$ 以执行 $a' \in AS$ 以执行 τ -thth步骤之后。考虑 $p.\mathbb{P}_{(a,a')}(\tau)$ 值，选择方法可以是贪婪的，也可以基于轮盘赌。在轮盘赌方法中，更有可能选择具有较高 $p.\mathbb{P}_{(a,a')}(\tau)$ 值的动作。贪婪的方法选择最高 $p.\mathbb{P}_{(a,a')}(\tau)$ 的动作。 p 在第一个 $\omega \#num_eval$ 客观函数评估期间使用赌场轮，其中 $\omega \in [0, 1]$ 是一个用户de-e-de-de-e-de-de-e-de-e-ned filed commeter。在此阶段之后，可以使用概率 ϵ 或轮盘赌概率 $1 - \epsilon$ 概率。等式 (20) 计算 ϵ 值，其中 $\#curr_eval$ 是当前的评估数。

$$\epsilon = \omega + (1 - \omega) \frac{\#curr_eval}{\#num_eval} \quad (20)$$

Algorithm 8: *runParticle* procedure for the *MoQAP*

Input: p : Particle

```

1  $a \leftarrow p.\text{decisionStrategy}(p.P)$ 
2  $\text{new\_position} \leftarrow a.\text{runActionStrategy}(p.\text{current\_position})$ 
3 if  $HV_{apx}(\text{new\_position})$  is better than  $HV_{apx}(p.pbest)$  then
4    $p.pbest \leftarrow \text{new\_position}$ 
5 end
6 if  $HV_{apx}(\text{new\_position})$  is better than  $HV_{apx}(gbest)$  then
7    $gbest \leftarrow \text{new\_position}$ 
8 end
9  $p.\text{runLearningStrategy}(p.P, p.Pb, Gb)$ 
10  $\text{dest} \leftarrow \text{chooseDestination}()$ 
11  $p.\text{current\_position} \leftarrow$ 
     $\text{velocityOperator}(\text{new\_position}, \text{dest}, N, p.I^1, \dots, p.I^{|N|})$ 

```

算法8概述了*runParticle*过程。第1行选择一个动作策略 a ，然后第2行执行它，以使 p 的当前位置是 a 的输入。 TA ， $NSGA-II$ ， $A-NSGA-III$ ， $MOEA/D$ 和 $MOEA/D-DU$ 迭代至 $\#maxGen$ 世代。 $MPLS$ 执行 $\#maxIter$ iterations。 $\#maxGen$ 和 $\#maxIter$ 是用户定义的参数。 a 的集合输出称为 new_position 。如果 new_position 对于 HV_{apx} 指示器比 $p.pbest$ ($gbest$)更好，则第4行（第7行）更新 $p.pbest$ ($gbest$)。第9行执行学习策略。在第10行中，程序 $\text{chooseDestination}()$ 随机选择 $gbest$ 之间的速度运算符的第二组，并通过任何粒子 ($p'.pbest$) 在迄今为止达到的最佳位置。在第一次迭代中，选择 $gbest$ 的概率为1.0。如果 new_position 比 $gbest$ 好，则 $\text{chooseDestination}()$ 过程中选择 $gbest$ 的概率增加了0.1（限制为1.0）。否则，它减少了相同的量（限制为0.0）。选择 $p'.pbest$ 的概率是补充。在这种情况下，过程 $\text{chooseDestination}()$ 的过程 $p'.pbest$ 的任何 $p'.pbest$ $p' \in P$ 的概率均匀。在第11行中，基于分解的速度运算符从 new_position 移动 p 向 $\text{chooseDestination}()$ 过程中选择的位置移动。第3.2.2节详细介绍了*MoQAP*的路径生成。速度运算符的输出成为 p 的当前位置。

3.2.2 路径生成

速度运算符使用[12]实现的路径生成。令 π^t 为路径链接轨迹的靶向解决方案， π 在轨迹中的任意解决方案。 π 和 π^t 之间的差异度量是 $\pi_j \neq \pi_j^t$, $j = 1, \dots, n$ 的元素数量，其中 π_j 和 π_j^t 和 π_j^t 代表 j - the π - then emplort π 和 π^t 的位置。操作 $m \in M(\pi, \pi^t)$ 通过在置换 π 中换两个元素，例如 π_i 和 π_j , $1 \leq i, j \leq n$ ，从而生成一个间介质 $\pi'' = \pi \oplus m$ ，以便 $\pi_i \neq \pi_i^t$ and $\pi_i \neq \pi_i^t$ and $\pi_i = \pi_j^t$ 。因此， $\pi_j'' = \pi_j^t$ ，即 π'' 是

与 π^t 相比 π 更相似。公式 (21) 计算 $f_k(\pi'')$ ，其中 $\delta(\pi, k, i, j)$ 是由等式 (22) [28]计算的 $f_k(\pi)$ 的区别。

$$f_k(\pi'') = f_k(\pi) + \delta(\pi, k, i, j), \forall k \in \{1, \dots, q\} \quad (21)$$

$$\begin{aligned} \delta(\pi, k, i, j) = & (\alpha_{jj} - \alpha_{ii})(\beta_{\pi_i \pi_i}^k - \beta_{\pi_j \pi_j}^k) \\ & + (\alpha_{ji} - \alpha_{ij})(\beta_{\pi_i \pi_j}^k - \beta_{\pi_j \pi_i}^k) \\ & + \sum_{o=1, o \neq i, j}^n ((\alpha_{oj} - \alpha_{oi})(\beta_{\pi_o \pi_i}^k - \beta_{\pi_o \pi_j}^k) \\ & + (\alpha_{jo} - \alpha_{io})(\beta_{\pi_i \pi_o}^k - \beta_{\pi_j \pi_o}^k)) \end{aligned} \quad (22)$$

3.2.3 颗粒合作

如[13]所指出的那样，代理之间的合作可以带来更好的解决方案。在这项研究中，粒子通过共享有关搜索的一些信息来合作。变量 $gbest$ 和 Gb 可用于群，任何粒子都可以更新它们。在 $\text{chooseDestination}()$ 过程中选择 $gbest$ 的概率可用于群。粒子 p 可以为任何 $p' \in P$ 读取 $p'.pbest$ ；但是，它只能更新其 $p.pbest$ 。

4 个计算实验和结果

在本节中报道的计算实验是在Intel Xeon处理器E5-2698 V3的核心上进行的，每个核心具有2.3 GHz和4 GB的RAM，运行CentOS 6.5，64位，由UFRN (NPAD/UFRN) 提供了高性能稳定中心。用C++和GNU g++ 7.1编译器实现算法。

第4.1节描述了测试和评估方法。第4.2-4.8节报告并讨论结果。

4.1 测试和评估方法

第一次测试旨在调查行动策略对搜索的贡献。该分析考虑了成功，失败，过渡概率和平均 HV_{apx} 改进统计。成功（失败）意味着 HV_{apx} 指示器的粒子的当前位置提高（恶化）。由操作 a 进行的平均 HV_{apx} 改进代表 a 产生的总 HV_{apx} 改进，除以 a executions的 a 。

此外，研究与学习策略，速度操作员和粒子合作的有关。第4.3节比较了两个*MO-mahm_E* versions的结果，这些version仅在学习策略中有所不同：一种使用*LA*方案，另一个使用[13]实现的学习策略。第4.4节比较了三个*MO-mahm_E*版本的结果，该版本仅在速度运算符中不同：

表1与Mo-Mahm_E相比

Hybridization technique	Section 4.6	MO-MAHM HMOEA MOTA	HTA HNSGA NSTA
Hyper- heuristic	Section 4.7	HH-LA	HH-RILA
MoQAP literature	Section 4.8	CoMOLS/D	GRASP

称为VO/D的版本使用基于分解的速度操作员VOI使用[13]实现的速度运算符，VOO是一个没有速度运算符的版本。第4.5节比较了并行和顺序MO-mahm_E版本的结果，因为预计粒子合作在并行性[13]中更有望更强。并行版本将每个粒子分配给虚拟线程。

在第4.6-4.8节中报告的调查旨在验证MO-mahm_E产生的结果是否与文献中的十种算法获得的研究相当。表1列出了比较的算法并将其列为杂交技术，超高术和MoQAP文献。杂交技术涉及在体系结构中实现的算法。表2详细介绍了Algorithm column中的杂交技术，并在q-obigntive实例中杂交Algorithms Hybridized column中的q-obigntive实例。杂交涉及适用于处理目标数量的算法版本。Bi-Objective实例的杂交涉及TA, NSGA-II, MOEA/D和MPLS。使用TA, A-NSGA-III, MOEA/D-DU和MPLS的两个目标。MO-MAHM是[13]提出的架构版本。HTA是一种模因算法，该算法是由MPLS与TA的杂交产生的。HNSGA对于Bi-Objementive实例是一个模因算法，涉及MPLS的NSGA-II。HNSGA杂交MPLS和A-NSGA-III的两个以上目标是因为A-NSGA-III是NSGA-II的多个目标。HMOEA定义与MPLS, MOEA/D和MOEA/D-DU相似。在每次迭代中应用进化的运算符后，HTA, HMOEA和HNSGA将MPLS执行MPLS，将总体作为其输入存档。NSTA和MOTA是[1]提出的混合算法，它们将第3.1.1节中详述的转基因运算符与NSGA-II (A-NSGA-III)和MOEA/D (MOEA/D-DU)分别结合在一起。

第4.7节将MO-Mahm_E产生的结果与{29} (HH-LA)和HH-RILA)提出的基于LA基于基于LA基于基于的超启发术获得的结果。为了进行公平的比较，HH-LA和HH-RILA的低级启发式方法是在体系结构中杂交的算法。最后，第4.8节将MO-mahm_E与来自MoQAP文献的两个算法_E进行了比较：[28]提出的GRASP和基于分解的共同进化多目标本地搜索 (CoMOLS/D) 的建议。GRASP

表2杂交技术的摘要与MO-mahm_E相比

Algorithm	q	Algorithms hybridized
MO-MAHM	2	TA, NSGA-II, MOEA/D, MPLS
	> 2	TA, A-NSGA-III, MOEA/D-DU, MPLS
HTA	≥ 2	TA, MPLS
HMOEA	2	MOEA/D, MPLS
	> 2	MOEA/D-DU, MPLS
HNSGA	2	NSGA-II, MPLS
	> 2	A-NSGA-III, MPLS
MOTA	2	TA, MOEA/D
	> 2	TA, MOEA/D-DU
NSTA	2	TA, NSGA-II
	> 2	TA, A-NSGA-III

被包括在比较中，因为它是一种传统的元启发式方法，成功地考虑了多目标的选择，包括杂交[34]和设施解决问题[48]。CoMOLS/D是一种最近的算法，该算法采用了类似于MO-Mahm_E的分解技术。

4.1.1实例

基准集包含27个MoQAP对称实例，并由[22]呈现的生成器构建。有15个现实的(KRL)实例，还有12个均匀的随机案例(KUNI)。三重(n, q, ID)识别一个实例，其中n ∈ {20, 30, 40, 50}代表locations/设施的数量，q ∈ {2, 2, 3, 3, 4} ID ∈ {1, 2, 3, 4, 5}。

KRL 距离矩阵条目是平面对点之间的欧几里得距离。表达式 (23) computes KRL流矩阵条目，其中 $\mu_1 \in \mathbb{Z}$, $\mu_2 \in \mathbb{Z}^+$, $\mu_1 < \mu_2$ 和 χ 代表一个随机值均匀地分布在[0, 1, 1)中。k - th流矩阵 (1 < k ≤ q) 中的一小部分条目与第一个KRL流量矩阵中的相应条目相关。一个overlap参数 (ov) 控制此分数， $cf_k \in [-1, 1]$ 是相关因子con- k - th flow atrix。表3列出了KRL实例的参数。

$$\lfloor 10^{((\mu_2 - \mu_1) * \chi + \mu_1)} \rfloor \quad (23)$$

KRL实例的表3参数

ID	1	2	3	4	5	1	2	3	1	2	3	1	1	2	3
n	20	20	20	20	20	30	30	30	40	40	40	50	50	50	50
q	2	2	2	2	2	3	3	3	3	3	3	3	4	4	4
cf ₂	0.0	0.4	-0.4	0.4	0.4	0.4	0.7	-0.4	0.4	0.7	-0.4	0.4	-0.6	0.6	0.8
cf ₃	-	-	-	-	-	0.0	-0.5	-0.4	0.0	-0.5	-0.4	-0.8	0.4	0.0	-0.2
cf ₄	-	-	-	-	-	-	-	-	-	-	-	-	-0.2	0.0	0.7
ov	1.0	1.0	1.0	1.0	0.5	0.7	0.7	0.2	0.7	0.7	0.2	0.7	0.7	0.7	0.7
μ ₁	-2	-	-2	-5	-5	-2	-2	-2	-2	-2	-2	-2	-2	-2	-2
μ ₂	4	4	4	5	5	4	4	4	4	4	4	4	4	4	4

表4 KUN实例的参数

ID	1	2	3	1	2	3	1	2	3	1	2	3
n	20	20	20	30	30	30	40	40	40	50	50	50
q	2	2	2	3	3	3	3	3	3	4	4	4
cf	0.0	0.7	-0.7	0.0	0.4	-0.4	0.0	0.6	-0.6	0.0	0.8	-0.8

表5决策和学习策略的参数设置

Procedure	Parameter	Procedure	Parameter
<i>Decision strategy</i>	$\omega = 0.44$	<i>Learning strategy</i>	$v_{pb} = 0.3 \quad v_{gb} = 0.7$

KUN实例的距离和流矩阵条目是随机整数均匀分布在 $[1, 100]$ 范围内。参数 $cf \in [-1, 1]$ 将第一个KUN流矩阵中的条目与其他流矩阵中的相应条目相关联。表4列出了KUN实例的参数。

4.1.2 质量指标和统计测试

每种实例的结果涉及每种算法的30个独立的研究。HyperVolume (HV) [58]和倒世代距离 (IGD) [7]评估算法产生的近似集质量。对于每个实例，计算这些指标都需要参考集 R 。我们通过从所有测试算法产生的所有近似集的联合中填充非主导的向量来计算 R 。HV结果由算法和 R 产生的近似集之间的差异组成。如[24]所建议的，我们将目标向量归一化 $[1, 2]$ 的范围，并使用了 $(2.1, \dots, 2.1)$ 作为HV的参考点。IGD在近似集 Y^* 中呈现目标向量之间的多样性。公式(24)计算IGD，其中 $ds(r, Y^*)$ 表示 $r \in R$ 和 Y^* 中最近的目标向量之间的距离。HV和IGD值越低，结果越好。附录A介绍质量指标值。

$$IGD(Y^*, R) = \frac{\sum_{r \in R} ds(r, Y^*)}{|R|} \quad (24)$$

统计测试验证结果之间的显著差异。对于涉及两种算法（第4.3、4.5节）的实验，Mann – Whitney测试[8]进行了单尾比较。对于两个以上的算法（第4.2、4.4、4.6、4.7、4.8节），Kruskal – Wallis测试[8]应用了两个比较阶段。第一阶段检查算法的多个独立结果之间的统计差异。如果第一阶段表示显著差异，则第二阶段形成了MO-mahm_E的结果与其他算法的结果之间的一尾成对比较。Mann – Whitney和Kruskal – Wallis测试都认为是0.05的显著性水平，并由PISA框架[3]提供。

4.1.3 参数设置

IRACE软件包[31]调整了所有算法的参数。MO-mahm_E使用 $\#numPart = 4$ 个粒子。基于分解的速度运算符使用 $|N| = 55$ 个方向向量。表5列出了决策和学习策略的参数设置。

表6展示了动作策略的参数。除 $\#maxGen$ 外，表6还展示了表2中显示的混合算法参数的值。学习策略HH-LA和HH-RILA所需的乘数为0.75。GRASP和CoMOLS/D分别通过[28]和[5]定义的参数。停止标准为MO-mahm_E的目标函数的 10^6 评估，并比较了algo--

表6行动策略的参数设置

Algorithm	Parameter	Algorithm	Parameter	Algorithm	Parameter
TA	#maxGen = 9	NSGA-II	#popSize = 55	MOEA/D	#popSize = 55
	#popSize = 55		#maxGen = 10		#maxGen = 9
MPLS	#probPlasm = 0.95	A-NSGA-III	#rateCross = 0.92	MOEA/D-DU	#rateCross = 0.96
	#probFactor = 0.1		#rateMut = 0.10		#rateMut = 0.09
	#intGerSet = 3				#neigh = 20
	#sizeRepo = 5				
MPLS	#maxIter = 10	A-NSGA-III	#popSize = 55	MOEA/D-DU	#popSize = 55
	#maxNeigh = 10		#maxGen = 10		#maxGen = 9
		A-NSGA-III	#rateCross = 0.91	MOEA/D-DU	#rateCross = 0.91
			#rateMut = 0.02		#rateMut = 0.08
				MOEA/D-DU	#neigh = 21
					#probNeigh = 0.34
					#maxReplc = 41

表1中的rith。评估的数量在粒子之间平均分布。我们使用[23]提出的自适应网格归档技术，限制为300个溶液，以实施算法要求的非主导解决方案的档案。

4.2行动策略的影响

所有行动策略均表现出所有实例的成功，失败和平均 HV_{apx} 的平均改进率。除了20.2 2个目标 *KUNI* 实例外，平均提出的动作大于失败。20.2 2个目标 *KUNI* 实例是小型且高度相关的（0.7）。这些功能将其与一个小的帕累托最佳套件相关联，使其变得容易。因此，动作策略倾向于在这种情况下找到小近似集。

这些结果证实了在 *MO-mahm_E* 中杂交的所有启发式方法都有助于所有实例的搜索。这些结果之间的结果相似。图1为50.1 4-Objective *KRL* 和40.1 3-目标 *KUNI* 说明了它们。这些实例仅用于说明目的，因为它们代表了每个组。X轴显示了动作策略。该图具有两个y轴。第一个（左）与条有关，并显示了在改善粒子当前位置的行动策略成功或失败的平均执行次数。第二个（右）y轴与该行有关，并显示了平均 HV_{apx} 改进。在这两种情况下，行动策略的成功率都大于失败和非零 HV_{apx} 的改进。

Kruskal – Wallis测试检查了与成功率和平均 HV_{apx} 改进有关的动作策略之间的统计差异。图2 – 5显示了每个实例(n, q, ID)的 4×4 矩阵，其主对角线由·符号标记以汇总这些结果。结果

成功率和平均 HV_{apx} 的改进分别出现在主角和上方。 $> (<)$ 符号表明，比相应的column中的 $> (<)$ 符号最终（较少）成功或产生的（较差）平均 HV_{apx} 的改进要多得有（较少）。~符号表示不确定的结果。

第一个Kruskal – Wallis检验并未表明 HV_{apx} 改进的动作策略之间的显著差异，从15（26.67%）*KRL* 实例和8个实例和8个（66.67%）*KUNI* Instances。在图2-5中，这样的实例对应于矩阵，其中~符号出现在主角上方的所有条目中。对于第一个Kruskal – Wallis通过的2项实例，成对测试表明TA的改进比其他算法的改进相似或更差（图2和4）。对于3和4项实例，TA提出了相似或更好的改进（图3和5）。唯一的例外是（40,3,2）*KUNI* 实例，*MOEA/D-DU* 呈现了最佳的 HV_{apx} 改进。*MPLS*，*NSGA-II* 和 *MOEA/D*（*A-NSGA-III* 和 *MOEA/D*（*A-NSGA-III* 和 *MOEA/D-DU*）的 HV_{apx} 改进的成对比较，对于3-和4- objection）而言，在大多数情况下都是不确定的。这些结果表明TA的趋势是在两个以上的目标函数中产生杂交中的明显良好的溶液。

第一次克鲁斯卡尔 - 瓦利斯测试表明，所有情况下的成功率都显著。成对测试表明TA是*KRL* 和 *KUNI* sets（分别为图2和4）的2-客观实例上最成功的，然后是 *MPLS*。除了（30,3,3），（40,3,3）和（50,4,3）实例外，3-和4项*KUNI* 实例发生了类似的结果（图5），其中 *MPLS* 是最成功的。此外，*MPLS* 在大多数3和4个目标 *KRL* 实例上取得了成功（图3）。

在大多数情况下，成功的平均数量与平均 HV_{apx} 的改进无直接相关，即行动策略可以更加成功







图1成功，失败和平均超量改善的平均数量

图2 Kruskal-Wallis关于成功数量和2个目标*KRL*实例的平均*HV*改进的结果图3 KRUSKAL-WALLIS关于3和4瞄准*KRL*实例的成功次数和平均*HV*改进的结果。图4 Kruskal-Wallis关于成功数量和2个目标*KUNI*实例的平均*HV*改进的结果

但是，比另一个更差或类似的平均 HV_{apx} 改进。例如，在 $(30, 3, 2)$ 和 $(50, 3, 1)$ *KRL* instances (v16) instances (图3)，图3)，*MPLS* 是更成功的，*MPLS* and {v19 and} v19

MOEA/D-DU; 在 $(50, 4, 1)$ *KRL* (图3) 和 $(30, 3, 3, 3)$ *KUNI* (*KUNI* (*KUNI* (图5), v31}, v32}, 以及 v32}，*MOEA/D-DU*, $\{HV_{apx}$ 比前者。这归因于 HV_{apx} 改进的变化，而 *MO-mahm_E* 执行过程中的动作策略会产生。动作策略在初始迭代时实现了显著的 HV_{apx} 贡献，并在随后的迭代中产生减少的贡献。尽管最初的贡献会导致粒子在此搜索点更喜欢这种动作，但随后的失败（或无签名的贡献）导致粒子在将来的迭代中执行成功的动作。

图6和7分别列出了 *KRL* 和 *KUNI* 实例的 *LA* 方案计算的过渡矩阵。矩阵显示了从命名的动作策略切换的平均过渡概率（以百分比为单位）

图5 KRUSKAL-WALLIS关于3和4瞄准KUNI实例的成功数量和平均HV改进的结果






图6 KRL实例LA方案产生的平均过渡概率矩阵（以百分比编写）



(a) 2-objective KRL



(b) 3 and 4-objective KRL

相应列中的行。颜色越深，过渡概率越高。这些发现表明颗粒更喜欢成功的行动策略。例如，对于KUNI set（图7）和2个目标KRL实例（图6），粒子首选TA。（40, 3, 1），（40, 3, 3, 2）2），和（50, 50, 3, 1, 1）之所以发生，是因为LA方案为过去 HV_{apx} 贡献分配了更少的权重。未成功的行动策略（即使在过去的迭代中实现了显著的 HV_{apx} 贡献）也会降低其奖励率。更频繁地贡献的行动倾向于提高或维持其奖励率；因此，成功的行动策略更有可能执行。

4.3有关学习策略的实验

除了20.3 2个目标KRL实例外，Mann-Whitney One-Tailed测试中的所有 p -值均小于0.05。LA基于MO-mahm_E版本最终产生了Better HV和IGD值，而不是使用[13]实现的学习策略的版本。对于20.3 2个目标KRL实例，统计测试未指示HV的显著差异（ p -value = 0.055）；但是，对于MO-mahm_E版本的IGD IGD（ p -value = 0.002 0.002），这是有利的。图8中的框图说明了HV和IGD的分布来自两个算法。20.3 2个目标KRL实例的结果可以归因于目标的尺寸和数量。




图7 KUNI实例LA方案产生的平均过渡概率矩阵（以百分比编写）

这些结果表明LA方案对搜索是有益的。LA结构特征可以解释这种好处。过渡矩阵允许代理考虑在上一步中执行的操作，以在当前步骤中选择一个。LA充分更新了过渡概率，并阻止了任何行动策略被群体“忘记”。

4.4 有关速度运算符的实验

对于HV的所有实例，第一个Kruskal – Wallis测试指示VO/D, VOI和VOO之间的显著差异。对于IGD的大多数情况，也会发生同样的情况。有关IGD的例外是20.1和20.2 2-目标KRL实例以及20.2 2-Objective KUNI实例。这些结果可能是小尺寸（20个位置/设施）和目标数量的结果，这些目标不会在算法中造成足够的困难。此外，随着相关因素的增加而产生的实例往往是easier，因为它们与帕累托最佳的集合有关。生成这些实例的相关因子（0.0, 0.4和0.7）可能会影响此类结果。

除了在20.2 2-Objective KUNI实例上的IGD值之外，未通过第一个统计测试，获得的成对测试 p -值 $\{0.0, 0.05\}$ 对于所有2-objective KUNI INSTANCES castences castisance woss Instance castences castences woss Instance woss Instance与V24} and HV and HV。这些结果最终表明VO/D表现出了2个目标KUNI实例的最佳性能。表7列出了2个目标KRL实例的成对测试中的 p -值。 P -values < 0.05 指示VO/D的最佳结果； p -values > 0.95 表示最佳结果

列中的版本； p - 0.05和0.95之间的值表示不确定的结果。H0符号表示第一个Kruskal – Wallis检验并未表示显著的分歧。表7显示了VO/D在大多数2个目标KRL实例上具有竞争力，主要与VOO相对。VOI仅在HV的20.1实例上更好地表现出更好的态度。结果有两个不确定的HV，它们与20.2和20.5实例上的VOI的比较有关。如前所述，小规模，少量目标和关系因子0.4对这些实例的结果影响。

成对测试表明，VO/D在所有3和4个目标实例上，VO/D的表现更好（ p -values < 0.05 ），这两个集合和两个质量指示灯都来自所有3和4个目标实例。除了50.2 4-Objective KUNI实例外，与VOO进行比较也发生了同样的情况。对于50.2 4个4个实例，成对测试表示VO/D和VOO之间的紧密相似性，IGD结果（ p -value = 0 = 0.082），并指出了v59}} = 0.035)最终。原因是用于生成这种实例的高相关因子（0.8）。图9说明了50.2 4-Objective KUNI实例的HV和IGD值的分布。

本节中报道的结果证实，基于分解的速度操作员对搜索过程有益。好处在于将群体移动到高质量和多样的解决方案，这会导致颗粒从局部最佳选择中逃脱。此外，随着目标的数量和小小的关系因素，优势增加了。这一事实表明，分解方法可以充分处理复杂的帕累托 - 弗朗特，并且呈指数尺寸的帕累托最佳套件。

4.5 有关粒子合作的实验

表8和9展示了 p - 来自Mann-Whitney一尾测试的值KRL和KUNI实例。 P -values < 0.05 是有利于并行version的结论。那些在0.05到0.95之间的人尚无定论。没有结论性的 p 值支持顺序版本。

并行版本在大多数KRL实例上具有三个和四个目标的顺序表现更好。 P - 值在大多数2个目标KRL实例上是尚无定论的，并且在IGD方面是40.2 3-目标。从2个目标KRL实例中，HV和IGD最终同意仅在20.4实例上平行版。

统计检验表明，并行版本从12 KUNI实例（66.67%）上产生了8个最佳HV值，而最佳IGD值从12（41.66%）上获得了5（41.66%）。其余的 p 值尚无定论。

本节中提出的结果强化了合作倾向于利用搜索。正如[13]所解释的那样，合作在并行性中更为强大，因为各个代理人更迅速地访问群体共享的信息。在

图8有关HV和IGD的值的框图
8 2-对象KRL实例




表7 Kruskal-Wallis成对 p - 关于速度操作员对2个目标KRL实例的影响的值

n.ID	VO1		VO0	
	HV	IGD	HV	IGD
20.1	0.992	H0	0.016	H0
20.2	0.338	H0	0.005	H0
20.3	0.034	0.002	0.000	0.000
20.4	0.048	0.000	0.000	0.000
20.5	0.149	0.001	0.000	0.000

图9有关HV和IGD值的盒子图
50.2 4-Objective KUNI实例




表8 Mann-Whitney p - 关于KRL实例上的平行性的值

q	2					3							4		
n.ID	20.1	20.2	20.3	20.4	20.5	30.1	30.2	30.3	40.1	40.2	40.3	50.1	50.1	50.2	50.3
HV	0.104	0.230	0.599	0.004	0.121	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000
IGD	0.068	0.500	0.225	0.000	0.110	0.000	0.021	0.000	0.000	0.094	0.001	0.002	0.019	0.009	0.004

表9 Mann-Whitney p - 关于KUNI实例上的平行性的值

q	2			3						4		
n.ID	20.1	20.2	20.3	30.1	30.2	30.3	40.1	40.2	40.3	50.1	50.2	50.3
HV	0.074	0.315	0.000	0.000	0.002	0.000	0.015	0.356	0.000	0.000	0.407	0.000
IGD	0.253	0.782	0.001	0.000	0.000	0.000	0.076	0.356	0.021	0.225	0.323	0.389

Trast, 代理倾向于在顺序版本中饿死此类信息。

4.6与Mo-Mahm_E中实现的算法的混合版本进行比较

第一个Kruskal – Wallis检验表明所有比较都有显著差异。成对测试表明, *MO - mahm_E*在最终的*HV*和*IGD*结果 (p -values < 0.05) 中比*MO-MAHM*, *HMOEA*, *HMOEA*, 以及*HNSGA* {v1 anst anst anst anst} 这些结果确认*MO -mahm_E*的假设比*MO-MAHM*表现更好, 因此, 它更适合2-, 3和4对象实例。此外, 这些结果证实了所提出的体系结构比最先进的多个目标元启发式学更好, 更多样化的解决方案, 并与本地搜索 (*HNSGA*和*HMOEA*) 杂交。

*MO -mahm_E*算法显著产生的superior *HV*和*IGD*结果 (p - values < 0.05) 与*MOTA* 05) 和*MOTA*和v27} v27和*NSTA*相比。 Table 10 lists the p -values for comparison s with *HTA* on *KRL* instances, indicating that most p -values favor *MO-MAHM_E* (p -values < 0.05) in terms of both quality indicators. *HTA*对于*HV*和*IGD*结果 (p -values > 0 > 0 > 0.95), 仅超过*MO -mahm_E*。有五个实例, 具有 p - 值: 一个用于*HV* (20.2 2-目标), 四个用于*IGD* (30.3 3-Objective和三个50尺寸的4-Objective)。

图10说明了50.1 4-Objective *KRL*实例的*HV*和*IGD*结果。Boxplots揭示, 在这种情况下, *MO -MAHM_E*获得的*HV*值比其他算法更好。*IGD*也发生了同样的情况, 除了*MO -mahm_E*和*HTA*之间的相似性。尽管没有统计差异, 但附录A中的表19表明*MO -mahm_E*对50.1 4-Objective *KRL*实例的*E*产生了比*HTA*更好的平均值*IGD*结果。

表11显示了*MO -mahm_E*与*HTA*, *MOTA*和*NSTA* on *KUNI*实例的成对 p 值。 *MO -mahm_E*在7 (58 *MOTA*), *MOTA*和*NSTA*上, 产生的结果更好*HV*结果, 在7 (58.33%) 上, 11 (91.67%), 和10 (v77} 33%), 以及12% (83%} v83} ., *MO -mahm_E*在3 (25.00%), 6 (50.00%) 和8 (66.67%) 实例上产生了更好的*IGD*结果。因此, *MO -mahm_E*对大多数*KUNI*实例产生了最佳*HV*值; 但是, *IGD*不会发生同样的情况。表11中显示的结果源于*KUNI*集合的构造。与*KRL*实例不同, *KUNI*实例由用单个相关因子参数生成的均匀随机值组成。随着相关因素的增加, *KUNI*实例变得更加容易, 使*HTA*, *MOTA*和*NSTA*更具竞争力。为了进行检查, 这些混合算法在50.2 4-Objective *KUNI*实例中最终产生了更好, 更多样化的解决方案

(相关因子0.8)。相反, *MO -mahm_E*达到了最佳*HV*和*IGD*的结果, 在20.3 2-objective中, 40.3 3-对象和50.3 4-objective Instances (具有-0-0.7, v10} 7, v10 6, v106} v10 {-0.8)。唯一的例外是30.3 3-对象实例 (相关因子-0.4), 其中*HTA*和*MOTA*的产生的*IGD*值比*MO -mahm_E*的值更好*IGD*值。

*HTA*是*KUNI*实例的第二大竞争算法, 因为*TA*和*MPLS*是提出最佳改进和成功率的动作策略。此外, 我们观察到, 转基因运算符导致在本研究中测试的多个客观优化器 (*A-NSGA-III*和*MOEA/D-DU*) 在*KUNI*实例上具有竞争力。例如, 对于40.2 3个目标*KUNI*实例就是这种情况, 如图11所示。

4.7与超高术的比较

MO -mahm_E, *HH-LA*和*HH-RILA*的第一个kruskal – wallis测试识别*MO -mahm_E*之间的显著差异。成对测试指出*MO -MAHM_E*始终达到了所有实例的最佳*HV*和*IGD*结果, 包括具有三个和四个目标的结果。附录A详细信息*HV*和*IGD*结果。

尽管*MO -mahm_E*, *HH-LA*和*HH-RILA*使用相同的学习, 决策和行动策略, 但*MO -mahm_E*利用*PSO*和多级式Paradigms的概念。例如, 多代理范式使搜索空间的不同区域的同时探索。*MO -MAHM_E*可以同时探索不同的解决方案, 因为每个代理 (粒子) 维护其当前的非主导解决方案 (当前位置), 而到目前为止达到了最好的解决方案 (*pbest*)。速度运算符, 另一个基本*PSO*概念, 显著构成了结果。


4.8与MOQAP文献的算法进行比较

第一个Kruskal – Wallis检验表明, 在所有情况下, 这两个指标都有显著差异。根据成对测试, *MO -mahm_E*在最终更好地产生了*HV*和*IGD*结果 (p -values < 0 < 0.05) 05} 05} and *GRASP* and *GRASP* v1 and} v1 and} v1 and} v1 and}。例外是50.3 4-Objective *KUNI*实例, 对*HV*的成对测试尚无定论 (p -value = 0 = 0.629)。

表12在*MO -mahm_E*和*CoMOLS/D*的*KUNI*实例之间展示了*MO - mahm_E*和*CoMOLS/D*之间的成对 p - 值。*MO -mahm_E*最终产生的*HV*和*IGD*结果 (p - 值 < 0 < 0.05) 比*CoMOLS/D* 05}, v173} 的最多*CoMOLS/D*。*CoMOLS/D*仅针对两个.95) 产生了更好的结果 (p -value > 0.95), 对于两个*KUNI*实例: 50.1 4-objective for 这两个*HV*和*HV*和*IGD*和*IGD*和*IGD*, and *IGD*, and *IGD*, 和50.3 4-objective。

表10 kr MO -mahm_E和HTA in KRL i

q	instances														
	2					3					4				
n.ID	20.1	20.2	20.3	20.4	20.5	30.1	30.2	30.3	40.1	40.2	40.3	50.1	50.1	50.2	50.3
HV	1.000	0.088	0.000	0.000	0.001	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000
IGD	0.989	0.000	0.000	0.000	0.001	0.000	0.000	0.862	0.000	0.000	0.000	0.000	0.183	0.349	0.919

图10有关HV和IGD的值的框图，50.1 4-Objective KRL 实例。表11 MO -mahm_E和hta, mota和nsta on $KUNI$ Instances之间的 MO -mahm_E之间的kruskal-wallis pairwise p -值

q	n.ID	HTA		MOTA		NSTA	
		HV	IGD	HV	IGD	HV	IGD
2	20.1	0.999	0.988	0.000	0.071	0.005	0.114
	20.2	0.347	0.982	0.000	0.000	0.000	0.057
	20.3	0.000	0.000	0.000	0.000	0.000	0.000
3	30.1	0.000	0.990	0.000	0.303	0.000	0.000
	30.2	0.982	1.000	0.000	0.009	0.000	0.000
	30.3	0.000	1.000	0.000	1.000	0.000	0.000
	40.1	0.000	1.000	0.000	0.853	0.000	0.000
	40.2	0.996	0.999	0.002	0.069	0.878	0.507
4	40.3	0.000	0.000	0.000	0.000	0.000	0.000
	50.1	0.000	1.000	0.024	0.041	0.000	0.000
	50.2	1.000	1.000	0.991	0.996	1.000	1.000
	50.3	0.000	0.000	0.000	0.000	0.000	0.000

表13显示了 KRL 实例的结果。对于HV指示器， MO -mahm_E产生了最佳结果 (p -value < 0.05)，从15个实例 (53.33%)， $CoMOLS/D$ ， $CoMOLS/D$ ($CoMOLS/D$ $CoMOLS/D$ 0.95) 在5 (33.33%) 上，两个结果是不可接受的 (13.33%)。 MO -mahm_E从15 (80.00%) 上产生了最好的IGD，.00%)， $CoMOLS/D$ 在2 (13.33%) 上产生了 $CoMOLS/D$ ，并且比较在一个实例上是不确定的 (6.67%)。图12说明了40.1 3-obignive KRL 实例的结果，其中 MO -mahm_E和HTA产生了相似的HV结果，而 MO -mahm_E实现了最佳的 E_o 。

5结论和未来工作

本文提出了一个多代理体系结构 MO -MAHM_E来设计混合元启发式学，以解决两个或多个客观功能的问题。 MO -MAHM，这是一种先前针对双目标问题的架构，在本研究中扩展了。 MO -MAHM和 MO -mahm_E之间的相似性在于PSO框架和多代理范式的灵感。它们在速度操作和学习策略方面有所不同。这种新颖的体系结构采用基于分解的速度运算符，以确保多样化和强化之间的适当平衡，

图11有关HV和40.2 3个目标KUN实例的IGD值的框图。




表12 MO -mahm_E和CoMOLS/D in KUN实例之间的kruskal-wallis pairwise p -值

q	2	3			4							
n.ID	20.1	20.2	20.3	30.1	30.2	30.3	40.1	40.2	40.3	50.1	50.2	50.3
HV	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.003	1.000	0.000	1.000
IGD	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	1.000	0.000	0.000

表13 MO -mahm_E和CoMOLS/D之间的kruskal-wallis pairwise p -值

q	2					3				4					
n.ID	20.1	20.2	20.3	20.4	20.5	30.1	30.2	30.3	40.1	40.2	40.3	50.1	50.1	50.2	50.3
HV	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.999	0.400	0.446	0.974	0.000	1.000	1.000	1.000
IGD	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.001	0.000	0.772	0.000	0.000	0.000	0.998	1.000

并加强学习自动机以支持颗粒的决策。


我们介绍了MoQAP的应用程序，该应用程序杂交了两个多型进化算法（A-NSGA-III和MOEA/D-DU），这是一种来自MoQAP文献的转化算法，以及一个多个目标的本地搜索，以调查MO-mahmmahmmahm_E。实验分析表明，这些算法对杂交的贡献显着贡献，即MO-mahm_E在结合和利用个体算法的潜力方面做得很好。

这项研究表明，MO-mahm_E成功地采用了分解和强化学习，以通过两个或多个客观功能解决问题。统计测试结果表明，速度运算符和学习自动机对搜索过程有益于两个以上的目标和实例，与呈指数尺寸的帕累托最佳设置有关。这些实验包括最多四个目标的实例，分析确定了近似集（通过超量测量）和溶液多样性（通过倒世代的倒数距离）的质量。

我们将MO-mahm_E与十算法进行了比较。MO-mahm_E在大多数情况下，与MO-MAHM和多个目标的模因算法相比，产生的结果更好。MO-mahm_E的表现要比两个基于两个LA - 基于两个LA - 基于两个MoQAP算法。这些结果表明，所提出的架构在处理两个以上的目标方面具有竞争力。此外，本文提出的实施是一种新颖的MoQAP最新算法（表14、15、16、17、18和19）。

未来的工作将包括对一些剩下的公开主题的调查。例如，我们打算研究MO-mahm_E性能，以增加目标函数的数字（超过四个）。此外，MO-mahm_E将使用其他机器学习技术（例如武装强盗模型和元学习）增强。最后，我们还打算调查同时采用不同学习策略的好处。

图12关于HV和IGD值的盒子图40.1 3-objective KRL实例



补充结果

下表，粗体条目是相应行中算法中的最低值。

本附录介绍了有关HV和IGD质量指标的含义结果，用于在第4.3-4.8节中进行比较。在

表14均值HV学习策略，速度操作员和合作的结果

q	n.ID	MO- MAHME	Without LA	With VO1	Without Velocity Operator	Without Cooperation
KRL						
2	20.1	5.92E-02	9.69E-02	4.83E-02	7.74E-02	6.12E-02
	20.2	3.63E-02	9.16E-02	3.51E-02	4.32E-02	3.96E-02
	20.3	2.25E-02	4.44E-02	2.95E-02	4.28E-02	2.28E-02
	20.4	3.62E-02	7.18E-02	3.76E-02	4.62E-02	4.42E-02
	20.5	3.28E-02	8.88E-02	3.76E-02	5.11E-02	3.77E-02
3	30.1	1.34E-01	2.40E-01	2.52E-01	2.30E-01	1.87E-01
	30.2	1.13E-01	1.67E-01	2.27E-01	1.95E-01	1.46E-01
	30.3	1.15E-01	1.97E-01	2.27E-01	2.01E-01	1.47E-01
	40.1	1.39E-01	2.07E-01	2.79E-01	2.42E-01	1.56E-01
	40.2	1.34E-01	1.86E-01	2.67E-01	2.12E-01	1.80E-01
	40.3	1.48E-01	2.04E-01	2.62E-01	2.23E-01	1.54E-01
	50.1	1.56E-01	2.58E-01	3.30E-01	2.63E-01	1.70E-01
4	50.1	2.58E-01	2.99E-01	4.05E-01	3.31E-01	2.81E-01
	50.2	2.60E-01	3.45E-01	3.63E-01	2.97E-01	2.77E-01
	50.3	2.64E-01	3.69E-01	4.03E-01	3.01E-01	2.73E-01
KUNI						
2	20.1	6.44E-02	1.31E-01	9.19E-02	8.18E-02	6.97E-02
	20.2	1.25E-01	3.44E-01	2.24E-01	1.80E-01	1.26E-01
	20.3	3.37E-02	6.24E-02	4.79E-02	5.94E-02	3.98E-02
3	30.1	1.63E-01	2.48E-01	2.44E-01	2.47E-01	1.75E-01
	30.2	2.15E-01	2.98E-01	2.83E-01	3.06E-01	2.27E-01
	30.3	1.30E-01	1.88E-01	2.24E-01	2.14E-01	1.40E-01
	40.1	1.88E-01	2.69E-01	2.92E-01	2.83E-01	2.78E-01

表14继续

q	n.ID	MO- MAHM _E	Without LA	With VO1	Without Velocity Operator	Without Cooperation
4	40.2	3.37E-01	4.88E-01	5.38E-01	3.95E-01	3.40E-01
	40.3	1.03E-01	1.34E-01	2.22E-01	1.75E-01	1.07E-01
	50.1	2.89E-01	3.08E-01	3.58E-01	3.05E-01	2.90E-01
	50.2	7.42E-01	9.00E-01	1.04E+00	8.18E-01	7.43E-01
	50.3	1.31E-01	1.64E-01	2.90E-01	2.49E-01	1.53E-01

表15均值IGD学习策略，速度操作员和合作的结果

q	n.ID	MO- MAHM _E	Without LA	With VO1	Without velocity operator	Without cooperation
KRL						
2	20.1	3.97E-03	5.81E-03	4.43E-03	4.76E-03	4.30E-03
	20.2	2.51E-03	4.77E-03	2.84E-03	3.46E-03	2.54E-03
	20.3	9.54E-04	1.95E-03	1.25E-03	1.89E-03	9.77E-04
	20.4	2.78E-03	5.63E-03	3.06E-03	3.94E-03	3.95E-03
	20.5	1.59E-03	4.09E-03	2.33E-03	3.62E-03	1.72E-03
3	30.1	1.48E-03	3.33E-03	2.61E-03	2.45E-03	2.23E-03
	30.2	1.33E-03	2.50E-03	1.88E-03	1.71E-03	1.81E-03
	30.3	1.50E-03	2.62E-03	2.02E-03	1.88E-03	1.77E-03
	40.1	2.03E-03	3.20E-03	3.01E-03	2.72E-03	2.10E-03
	40.2	1.92E-03	3.00E-03	2.80E-03	2.26E-03	1.86E-03
4	40.3	2.05E-03	2.74E-03	2.65E-03	2.38E-03	2.34E-03
	50.1	2.09E-03	3.67E-03	3.34E-03	2.88E-03	2.49E-03
	50.1	2.33E-03	2.46E-03	3.05E-03	2.65E-03	2.91E-03
	50.2	2.47E-03	3.39E-03	3.00E-03	2.78E-03	2.78E-03
	50.3	2.37E-03	3.97E-03	3.39E-03	3.06E-03	2.64E-03
KUNI						
2	20.1	4.11E-03	8.36E-03	5.66E-03	5.43E-03	4.25E-03
	20.2	5.76E-02	9.02E-02	6.35E-02	7.36E-02	5.79E-02
	20.3	1.34E-03	2.65E-03	1.71E-03	2.25E-03	1.66E-03
3	30.1	2.63E-03	4.46E-03	3.32E-03	3.31E-03	2.69E-03
	30.2	4.86E-03	7.46E-03	5.50E-03	5.96E-03	4.87E-03
	30.3	1.94E-03	2.96E-03	2.72E-03	2.57E-03	1.96E-03
4	40.1	3.11E-03	5.10E-03	3.87E-03	3.56E-03	2.81E-03
	40.2	1.08E-02	2.00E-02	2.07E-02	1.60E-02	1.09E-02
	40.3	1.50E-03	1.58E-03	2.04E-03	1.52E-03	1.66E-03
	50.1	3.39E-03	4.09E-03	3.89E-03	3.62E-03	2.41E-03
	50.2	3.21E-02	7.19E-02	6.73E-02	4.53E-02	3.23E-02
	50.3	8.39E-04	1.24E-03	1.67E-03	1.46E-03	9.86E-04

表16表示MO -mahm_E,
HH-LA和HH-RILA的IGD结
果IGD结果

q	n.ID	HV			IGD		
		MO- MAHM _E	HH-LA	HH-RILA	MO- MAHM _E	HH-LA	HH-RILA
KRL							
2	20.1	5.92E-02	2.06E-01	1.84E-01	3.97E-03	1.23E-02	1.06E-02
	20.2	3.63E-02	1.41E-01	1.97E-01	2.51E-03	8.38E-03	1.08E-02
	20.3	2.25E-02	1.25E-01	1.68E-01	9.54E-04	5.52E-03	6.93E-03
	20.4	3.62E-02	1.42E-01	1.79E-01	2.78E-03	9.13E-03	1.17E-02
	20.5	3.28E-02	1.38E-01	1.40E-01	1.59E-03	8.67E-03	7.30E-03
3	30.1	1.34E-01	3.58E-01	4.07E-01	1.48E-03	5.23E-03	6.00E-03
	30.2	1.13E-01	2.98E-01	3.05E-01	1.33E-03	4.38E-03	4.40E-03
	30.3	1.15E-01	3.58E-01	3.38E-01	1.50E-03	4.58E-03	4.24E-03
	40.1	1.39E-01	3.47E-01	3.36E-01	2.03E-03	4.79E-03	4.62E-03
	40.2	1.34E-01	3.35E-01	3.11E-01	1.92E-03	4.98E-03	4.90E-03
	40.3	1.48E-01	3.45E-01	3.32E-01	2.05E-03	5.07E-03	5.07E-03
	50.1	1.56E-01	3.63E-01	3.72E-01	2.09E-03	5.11E-03	5.25E-03
4	50.1	2.58E-01	4.67E-01	4.44E-01	2.33E-03	4.66E-03	4.43E-03
	50.2	2.60E-01	4.39E-01	3.95E-01	2.47E-03	5.07E-03	5.25E-03
	50.3	2.64E-01	4.27E-01	4.02E-01	2.37E-03	5.03E-03	5.08E-03
KUNI							
2	20.1	6.44E-02	2.47E-01	2.32E-01	4.11E-03	1.77E-02	1.50E-02
	20.2	1.25E-01	6.19E-01	5.73E-01	5.76E-02	1.39E-01	1.30E-01
	20.3	3.37E-02	1.45E-01	1.39E-01	1.34E-03	6.63E-03	6.41E-03
3	30.1	1.63E-01	4.22E-01	4.14E-01	2.63E-03	7.73E-03	7.49E-03
	30.2	2.15E-01	4.38E-01	5.23E-01	4.86E-03	9.63E-03	1.26E-02
	30.3	1.30E-01	3.40E-01	3.30E-01	1.94E-03	5.21E-03	4.58E-03
	40.1	1.88E-01	4.54E-01	4.72E-01	3.11E-03	8.59E-03	8.56E-03
	40.2	3.37E-01	7.72E-01	5.80E-01	1.08E-02	3.58E-02	2.29E-02
	40.3	1.03E-01	2.32E-01	2.31E-01	1.50E-03	2.80E-03	2.62E-03
	50.1	2.89E-01	5.11E-01	4.87E-01	3.39E-03	5.66E-03	5.11E-03
4	50.2	7.42E-01	1.31E+00	1.26E+00	3.21E-02	1.24E-01	1.11E-01
	50.3	1.31E-01	2.24E-01	2.34E-01	8.39E-04	1.55E-03	2.50E-03

表17表示MO -mahm_E, GRASP和CoMOLD/D的均值HV和IGD结果

q	n.ID	HV			IGD		
		MO- MAHM _E	GRASP	CoMOLS/D	MO- MAHM _E	GRASP	CoMOLS/D
KRL							
2	20.1	5.92E-02	7.23E-02	1.99E-01	3.97E-03	4.86E-03	1.02E-02
	20.2	3.63E-02	5.93E-02	1.96E-01	2.51E-03	5.62E-03	8.93E-03
	20.3	2.25E-02	4.48E-02	1.29E-01	9.54E-04	2.02E-03	5.35E-03
	20.4	3.62E-02	7.11E-02	1.33E-01	2.78E-03	5.25E-03	8.83E-03
	20.5	3.28E-02	5.32E-02	1.71E-01	1.59E-03	3.79E-03	7.82E-03
3	30.1	1.34E-01	1.79E-01	1.41E-01	1.48E-03	2.22E-03	2.65E-03
	30.2	1.13E-01	1.67E-01	1.62E-01	1.33E-03	2.22E-03	2.94E-03
	30.3	1.15E-01	1.68E-01	1.07E-01	1.50E-03	1.95E-03	1.85E-03
	40.1	1.39E-01	2.30E-01	1.41E-01	2.03E-03	2.75E-03	2.45E-03
	40.2	1.34E-01	2.13E-01	1.29E-01	1.92E-03	2.62E-03	2.17E-03
	40.3	1.48E-01	2.00E-01	1.43E-01	2.05E-03	2.55E-03	2.53E-03
	50.1	1.56E-01	2.12E-01	1.61E-01	2.09E-03	2.68E-03	3.08E-03
	50.2	2.58E-01	3.73E-01	2.18E-01	2.33E-03	3.23E-03	2.70E-03
50.3	2.60E-01	3.58E-01	1.94E-01	2.47E-03	3.28E-03	2.28E-03	
50.3	2.64E-01	3.39E-01	2.15E-01	2.37E-03	3.00E-03	2.23E-03	
KUNI							
2	20.1	6.44E-02	1.25E-01	2.17E-01	4.11E-03	8.11E-03	1.43E-02
	20.2	1.25E-01	3.26E-01	7.39E-01	5.76E-02	7.44E-02	1.77E-01
	20.3	3.37E-02	5.52E-02	1.18E-01	1.34E-03	1.84E-03	4.48E-03
3	30.1	1.63E-01	2.90E-01	2.01E-01	2.63E-03	4.51E-03	4.25E-03
	30.2	2.15E-01	5.16E-01	3.95E-01	4.86E-03	1.14E-02	8.60E-03
	30.3	1.30E-01	2.21E-01	1.46E-01	1.94E-03	3.40E-03	3.30E-03
	40.1	1.88E-01	3.50E-01	2.03E-01	3.11E-03	5.74E-03	4.51E-03
	40.2	3.37E-01	8.76E-01	6.86E-01	1.08E-02	4.15E-02	2.63E-02
	40.3	1.03E-01	1.71E-01	1.13E-01	1.50E-03	2.89E-03	2.79E-03
	50.1	2.89E-01	4.12E-01	2.03E-01	3.39E-03	3.85E-03	3.08E-03
4	50.2	7.42E-01	1.38E+00	1.25E+00	3.21E-02	1.80E-01	1.28E-01
	50.3	1.31E-01	1.65E-01	1.26E-01	8.39E-04	1.75E-03	2.94E-03

表18表示MO -mahm_E, MO-MAHM, HTA, HMOEA, HNSGA, HNSGA, MOTA和NSTA和NSTA

q	n.ID	MO- MAHM _E	MO- MAHM	HTA	HMOEA	HNSGA	MOTA	NSTA
KRL								
2	20.1	5.92E-02	1.40E-01	2.31E-02	2.54E-01	1.26E-01	1.03E-01	9.61E-02
	20.2	3.63E-02	1.01E-01	4.22E-02	1.76E-01	1.30E-01	7.37E-02	5.94E-02
	20.3	2.25E-02	5.97E-02	5.78E-02	1.28E-01	9.10E-02	7.84E-02	6.78E-02
	20.4	3.62E-02	7.11E-02	7.04E-02	1.71E-01	9.07E-02	1.16E-01	1.01E-01
	20.5	3.28E-02	8.30E-02	5.31E-02	2.14E-01	1.32E-01	8.49E-02	7.91E-02
3	30.1	1.34E-01	3.40E-01	2.98E-01	2.51E-01	4.62E-01	3.23E-01	3.12E-01
	30.2	1.13E-01	2.61E-01	2.63E-01	2.96E-01	4.88E-01	2.87E-01	2.57E-01
	30.3	1.15E-01	2.98E-01	2.45E-01	2.29E-01	4.37E-01	2.84E-01	2.94E-01
	40.1	1.39E-01	3.72E-01	3.20E-01	2.50E-01	4.61E-01	3.52E-01	3.56E-01
	40.2	1.34E-01	3.87E-01	2.99E-01	2.57E-01	4.78E-01	3.33E-01	3.33E-01
	40.3	1.48E-01	3.61E-01	3.22E-01	2.55E-01	4.66E-01	3.43E-01	3.50E-01
	50.1	1.56E-01	4.71E-01	3.72E-01	3.00E-01	5.01E-01	3.94E-01	3.83E-01
4	50.1	2.58E-01	4.76E-01	4.33E-01	4.21E-01	6.54E-01	4.14E-01	4.23E-01
	50.2	2.60E-01	5.47E-01	3.84E-01	4.09E-01	6.33E-01	3.88E-01	3.94E-01
	50.3	2.64E-01	5.38E-01	3.90E-01	4.89E-01	6.80E-01	4.07E-01	4.14E-01
KUNI								
2	20.1	6.44E-02	1.15E-01	5.42E-02	2.40E-01	1.42E-01	7.63E-02	7.26E-02
	20.2	1.25E-01	3.79E-01	1.25E-01	6.56E-01	6.33E-01	3.59E-01	2.80E-01
	20.3	3.37E-02	8.84E-02	4.40E-02	1.41E-01	8.63E-02	5.84E-02	6.09E-02
3	30.1	1.63E-01	3.25E-01	2.31E-01	2.21E-01	4.60E-01	2.44E-01	2.88E-01
	30.2	2.15E-01	4.28E-01	2.01E-01	3.72E-01	4.00E-01	2.68E-01	2.80E-01
	30.3	1.30E-01	3.05E-01	1.96E-01	2.31E-01	4.86E-01	1.95E-01	2.60E-01
	40.1	1.88E-01	4.09E-01	2.45E-01	2.82E-01	5.32E-01	2.59E-01	2.84E-01
	40.2	3.37E-01	4.86E-01	3.03E-01	6.60E-01	6.49E-01	3.77E-01	3.18E-01
	40.3	1.03E-01	2.92E-01	1.93E-01	2.83E-01	5.02E-01	1.83E-01	2.41E-01
	50.1	2.89E-01	5.56E-01	3.47E-01	5.28E-01	7.97E-01	2.98E-01	3.83E-01
4	50.2	7.42E-01	6.50E-01	5.85E-01	1.27E+00	1.24E+00	6.70E-01	5.65E-01
	50.3	1.31E-01	4.25E-01	3.18E-01	3.63E-01	4.31E-01	3.21E-01	3.09E-01

表19表示MO-mahm_E,
MO-MAHM, HTA, HMOEA
, HNSGA, HNSGA, MOTA
和NSTA和NSTA

q	n.ID	MO- MAHM _E	MO- MAHM	HTA	HMOEA	HNSGA	MOTA	NSTA
KRL								
2	20.1	3.97E-03	9.10E-03	2.81E-03	1.27E-02	7.43E-03	7.46E-03	7.49E-03
	20.2	2.51E-03	5.36E-03	3.80E-03	7.84E-03	5.69E-03	5.38E-03	4.55E-03
	20.3	9.54E-04	3.40E-03	3.46E-03	5.57E-03	4.94E-03	4.41E-03	4.22E-03
	20.4	2.78E-03	4.94E-03	7.97E-03	1.03E-02	6.24E-03	1.02E-02	9.31E-03
	20.5	1.59E-03	4.47E-03	2.79E-03	1.02E-02	6.66E-03	6.31E-03	6.75E-03
3	30.1	1.48E-03	3.78E-03	2.05E-03	2.02E-03	3.98E-03	2.19E-03	2.21E-03
	30.2	1.33E-03	2.68E-03	1.75E-03	2.35E-03	4.27E-03	1.89E-03	1.98E-03
	30.3	1.50E-03	2.89E-03	1.47E-03	1.99E-03	4.68E-03	1.70E-03	1.97E-03
	40.1	2.03E-03	4.65E-03	2.69E-03	2.77E-03	5.31E-03	3.18E-03	3.18E-03
	40.2	1.92E-03	4.42E-03	2.34E-03	2.62E-03	5.37E-03	2.90E-03	2.83E-03
	40.3	2.05E-03	4.46E-03	2.55E-03	3.28E-03	6.02E-03	2.95E-03	2.97E-03
	50.1	2.09E-03	5.87E-03	2.89E-03	3.40E-03	5.62E-03	3.47E-03	3.37E-03
4	50.1	2.33E-03	4.21E-03	2.37E-03	2.99E-03	4.61E-03	2.68E-03	2.40E-03
	50.2	2.47E-03	5.68E-03	2.51E-03	3.01E-03	4.92E-03	2.85E-03	2.65E-03
	50.3	2.37E-03	5.53E-03	2.34E-03	3.53E-03	5.41E-03	2.74E-03	2.72E-03
KUNI								
2	20.1	4.11E-03	7.07E-03	3.74E-03	1.60E-02	8.75E-03	4.45E-03	4.33E-03
	20.2	5.76E-02	1.00E-01	4.97E-02	1.48E-01	1.45E-01	8.38E-02	6.55E-02
	20.3	1.34E-03	4.13E-03	1.93E-03	5.69E-03	4.03E-03	2.60E-03	2.70E-03
3	30.1	2.63E-03	4.51E-03	2.55E-03	2.83E-03	6.68E-03	2.67E-03	4.06E-03
	30.2	4.86E-03	1.03E-02	4.31E-03	8.40E-03	9.45E-03	5.20E-03	6.83E-03
	30.3	1.94E-03	3.78E-03	1.70E-03	2.36E-03	6.06E-03	1.80E-03	3.01E-03
	40.1	3.11E-03	5.88E-03	2.77E-03	3.98E-03	7.97E-03	3.04E-03	4.09E-03
	40.2	1.08E-02	2.42E-02	9.28E-03	2.55E-02	2.62E-02	1.11E-02	1.07E-02
	40.3	1.50E-03	2.82E-03	1.79E-03	2.98E-03	9.18E-03	1.79E-03	2.33E-03
4	50.1	3.39E-03	5.94E-03	3.21E-03	4.80E-03	8.03E-03	3.48E-03	3.86E-03
	50.2	3.21E-02	5.32E-02	2.33E-02	1.15E-01	1.01E-01	2.76E-02	2.35E-02
	50.3	8.39E-04	2.54E-03	1.67E-03	1.86E-03	3.60E-03	1.79E-03	1.55E-03

30. Liu SC, Zhan ZH, Tan KC, Zhang J (2021) 多物体优化的多目标框架. *IEEE Trans网络网络* 52 (12) : 13654 – 1366831.
- López-ibáñez M, Dubois-Lacoste J, Cáceres LP, Birattari M, Stützle T (2016) IRACE包装: IRACE套件: IRACE套件: 迭代赛车, 用于自动Algorithm Algorithm conformation. 操作镜头观点3 : 43–58. <https://doi.org/10.1016/j.orp.2016.09.00232>. MACHADO MO, FERNANDES IFC, MAIA SMDM, GOLDBARG EFG (2024) 一种用于离岸风电场电缆路由问题的混合多代理元神经. 专家Syst Appl 255 : 12466833. Mao Z, Liu M (2022) 基于本地搜索的多个元素周期优化算法. *Swarm and Evolut Comput* 68 : 10100934. Martí R, Campos V, Resende MG, Duarte A (2015) Multiobjective tith Path Relinking. *EURO J Operat Res* 240 (1) : 54 – 71. <https://doi.org/10.1016/j.ejor.2014.06.04235>. Morteza H, Jameii SM, Sohrabi MK (2023) 一种改进的基于基于多门象的多门象投资组合构造的基于多目标的多目标鲸鱼优化方法. 专家Syst Appl 224 : 119970 36. Murata T, Ishibuchi H, Gen M (2001) 细胞多目标遗传算法中遗传搜索方向的规范. 在: E. Zitzler, L. Thiele, K. Deb, C. A. C. Coello和D. Corne (编辑), 《进化多准则优化》。Emo 2001, 《计算机科学讲义》1993年, 柏林, 海德堡, 第82–95页. Springer 37. Murata T, Ishibuchi H, Tanaka H (1996) 用于花店调度问题的遗传算法. *Comput Indust Eng* 30 (4) : 1061 – 1071. [https://doi.org/10.1016/0360-8352\(96\)00053-8](https://doi.org/10.1016/0360-8352(96)00053-8) 38. Oliveira Alc, Britto A, Gusmão R (2023) 机器学习增强的Metaheuristics: A MACHENAHERISTICAL: A SAMYTATIC REVICE: 一项系统审查. 软计算27 : 1–28. <https://doi.org/10.1007/s00500-023-08886-339>. Qin S, Sun C, Zhang G, He X, Tan Y (2020) 基于与不同理想点的分解点, 用于许多理想点, 用于许多 - 粒子的颗粒优化. 复杂的Intell Syst 6 : 263 – 274. <https://doi.org/10.1007/s40747-020-00134-7> 40. Reddy S, Dulikravich GS (2022) 多个目标优化的自我适应算法. *Appl Soft Comput* 129 : 10948441. Ribeiro CC, Resende MGC (2012) 随机局部搜索算法的路径 - 链接增强方法. *J Heuristics* 18 (2) : 193 – 214. <https://doi.org/10.1007/s10732-011-9167-142>. Sahni S, Gonzalez T (1976) P-Complete近似问题. *J ACM* 23 (3) : 555 – 565. <https://doi.org/10.1145/321958.321975> 43. Silva Irm, Goldbarg EFG, De Carvalho EB, Goldbarg MC (2017) Mo-Mahm: Mo-Mahm的平行多阶段型结构, 用于多型元眼镜的杂种杂交. 在: 2017年IEEE进化计算大会 (CEC), 第580–587页. IEEE 44. Silva Mal, de Souza SR, Souza MJF, França Filho MF (2018) 混合元启发式和用于解决光学化问题的多代理系统: 框架的综述和比较分析. 应用软计算71 : 433 – 459. <https://doi.org/10.1016/j.asoc.2018.06.05045>. Taillardé (1991) 强大的禁忌搜索二次分配问题. 并行计算17 (4–5) : 443 – 455. [https://doi.org/10.1016/s0167-8191\(05\)80147-4](https://doi.org/10.1016/s0167-8191(05)80147-4) 46. J算法计算技术9 (1) : 41 – 63. <https://doi.org/10.1260/1748-3018.9.1.4147>. Tang W, Liu H, Chen L, Tan K C, Cheung Y (2020) 基于分割策略的快速超体积近似方案. 告知SCI 509 : 320 – 342. <https://doi.org/10.1016/j.ins.2019.02.05448>. 应用软计算163 : 111897. <https://doi.org/10.1016/j.asoc.2024.111897>
49. Wang H, Wang S, Wei Z, Zeng T, Ye T, Ye T (2023) 改进了用于级联回归操作的多个目标人工蜜蜂菌落算法. *Neural Comput Appl* 35 (18) : 13613 – 13629 50. Xu J, Li K, Abusara M (2022) 基于智能网格中多微晶系统优化问题的基于偏好的多目标增强学习. 模因计算14 (2) : 225 – 235. <https://doi.org/10.1007/s12293-022-00357-W51>. Yang L, Cao J, Li K, Zhang Y, Xu R, Li K (2024) 基于相互作用力和杂交光学化机械的多个目标进化算法. *Swarm and Evolut Comput* 90 : 101667 52. Yuan Y, Xu H, Wang B, Zhang B, Yao X (2016) 基于分解的多种主体优化器的平衡和多样性. *IEEE Trans Evolut Comput* 20 (2) : 180 – 198. <https://doi.org/10.1109/tevc.2015.244300153>. Zhang Q, Li H (2007) Moea/d: 基于分解的多目标进化算法. *IEEE Trans Evolut Comput* 11 (6) : 712 – 731. <https://doi.org/10.1109/tevc.2007.89275954>. Zhang Y, Zhou K, Tang J (2024) 利用协作自动机, 以指导基于多目标优化的基于多目标优化的逆分析, 以实现结构性损害识别. 应用软计算160 : 111697. <https://doi.org/10.1016/j.asoc.2024.111697> 55. 应用软计算86 : 105879. <https://doi.org/10.1016/j.asoc.2019.105879> 56. 告知SCI 509 : 1–21. <https://doi.org/10.1016/j.ins.2019.08.06957>. Zhao H, Zhang C, Ning J, Zhang B, Sun P, Sun P, Feng Y (2019) 对进化的多个目标算法的比较研究. 人工智能8 (1) : 15 – 43的进展. <https://doi.org/10.1007/s13748-019-00174-2> 58. 在: A. E. Eiben, T. Bäck, M. Schoenauer和H. Schwefel (编辑), 《从自然界解决的平行问题》。PPSN 1998, 第1498卷, 《计算机科学讲义》, 柏林, 海德堡, 第292 – 301页. 施普林格

出版商的注释Springer自然在已发表的地图和机构之后的法律要求方面仍然保持中立。

Springer Nature或其许可人(例如, 社会或其他合作伙伴) 根据与作者或其他权利归属人的出版协议享有本文的独家权利; 本文接受的手稿版本的作者自我构造仅受此类出版协议和适用法律的条款的约束。