



基于多模式差异演化和极端学习机器的合奏学习算法

jie ma¹ · hong li¹ · weifeng gao¹ · jin xie¹

收到：2024年9月28日 /接受：2025年4月12日©作者，根据Springer-Verlag GmbH德国的独家许可，Springer Nature 2025

抽象的

神经网络合奏（NNE）是一种广泛认可且有效的分类方法。必须同时优化NNE中所有基础神经网络（NNS）的拓扑结构和权重参数。这种同时优化对于平衡基础NN的准确性和多样性至关重要，从而导致了出色的分类性能。极限学习机器（ELM）是一种快速的非著作学习策略，由于其强大的概括能力，最近引起了显著关注，尽管仅对固定结构NNS有效。因此，为了应对这些复杂的挑战，本文介绍了一种基于多模式差分进化（MMDE）和ELM的新颖集合学习算法，称为MMDE-ELM-NNE。所提出的算法在一项运行中优化了NNE内所有基本NN的结构和权重参数。MMDE-ELM-NNE采用独特的编码方案来优化基本NNS的结构和输入参数，而ELM的输出参数是直接计算的。此外，MMDE算法已经更好地增强了NNE任务的高维优化需求，最终提高了分类精度。进行了20个多模式优化问题的实验，并将其与现有的11种算法进行了比较，以验证所提出的MMDE的有效性。此外，依靠弗里德曼测试的分类基准数据集的实验结果表明，MMDE-NNE显著胜过MMDE或ELM的合并，从而在概括性实力方面表现出色。此外，提出的算法与其他最新的分类算法相比，展示了竞争能力。

关键字神经网络集合·集合学习·微分进化·多模式优化·极限学习机·分类

List of symbols

$\vec{t}_i$	Individual i (neural network structure and parameters)	$mean_A(\cdot)$	Arithmetic mean
$\vec{v}_i$	Mutant vector of individual i	$\vec{w}_i$	Input weight vector of hidden node i
$\vec{u}_i$	Trial vector of individual i	b_i	Bias of hidden node i
$\vec{t}_{best}$	Best individual in the population	$\vec{\beta}_i$	Output weight vector of hidden node i
F_i	Scaling factor of individual i	$\vec{o}_i$	Output value of the network
CR_i	Crossover rate of individual i	$g(\cdot)$	Activation function (sigmoid function by convention)
μ_F	Mean of successful F_i values	$\mathbf{H}$	Output matrix of the hidden layer
μ_{CR}	Mean of successful CR_i values	β	Output weight matrix
S_F	Set of successful F_i	$\mathbf{Y}$	Desired output matrix
S_{CR}	Set of successful CR_i	$\mathbf{H}^\dagger$	Moore-Penrose pseudo-inverse of $\mathbf{H}$
b	Constant, typically set to 0.1	δ	State parameters of hidden layer neurons
$mean_L(\cdot)$	Lehmer mean	s_i	Activation status of neuron i in the hidden layer
Hong Li lihong@mail.xidian.edu.cn		D	Dimension of the solution space
		N	Number of training samples
		m	Number of classes
		y_{ij}	Actual output of class j for sample i
¹ School of Mathematics and Statistics, Xidian University, Xi'an 710071, Shaanxi, China			

o_{ij} 样品 $j \in \omega_i$ 的类 j 的所需输出, 用于亚群的亚群停滞 θ 阈值, 用于亚群收敛 St stagnation Tolerance η 的数量

1简介

在实际情况下, 存在需要识别多个全局最佳解决方案 (GOSS) 的优化问题, 该解决方案 (GOSS) 是一种被称为多模式化性问题 (MMOPS) 的特征。在过去的二十年中, MMOP 引起了很大的关注和研究兴趣。在解决 MMOPS 时, 基于人群的元神经算法进化算法 (EA) 已成为一种有效的工具。但是, 他们通常在捕捉问题特定知识和本地搜索启发式的细微差别方面差不多。常规 EAS 不适合 MMOP, 因为它们通常是设计出在优化过程中仅找到一个 GO 的。

在这种背景下, 记忆计算的领域以有效的范式出现。模因计算将进化计算的原理与局部搜索方法集成在一起, 已经证明了其在增强优化算法的性能方面的效率。这种方法的灵感来自于模因的文化演变, 在该模因的文化演变中, 在人群中复制和重新定义了戈斯或“模因”, 导致出现了更有效的策略。因此, 传统的 EA 已通过富裕技术增强, 以增强人口多样性, 并探索更广泛的戈斯。各种方法, 包括拥挤[49], 聚类[58], 物种形成[32], 局部敏感的哈希[15], 贴合性共享[9]和清除[41]等[41]等, 已与不同类型的 EAS 合并以解决 MMOP [23、35、56、57]。在这些方法中, 将细分技术变为差异发展 (DES), 用于求解 MMOP (称为多模式 DES (MMDE)), 即使在存在嘈杂或不完整的数据的情况下, 它们的快速收敛速度, 直接的实现和稳健的性能也脱颖而出。

可以将训练多个基本神经网络 (NNS) 插入 MMOP, 其中 NN 的结构和参数被视为优化问题中的变量, 目的是最大程度地减少实际 NN 输出之间的误差。因此, 也可以利用 MMDE 的实际方法进行优化。与简单地汇总了通过常规 EAS 或反向传播培训的特定数量的基本 NN, 可以解释为解决几个单模式优化问题, MMDES

通过考虑将其视为 MMOP, 提供了一种更有效的方法来训练 NNE 的方法。这主要是因为传统的 EAS 和反向传播一次只能获得一个最佳基础网络, 需要多次重复来训练多个 NN 的 NNE, 这既费时, 且不可避免地会导致冗余或同质 NN。另一方面, 使用 MMDE 训练 NNE, 同时在单个运行中通过将整个人群划分为多个子菜单, 从而产生多种不同的 NN, 每个人都要求寻求一个 GOS。因此, 使用 MMDE 可以显着促进 NNE 培训并提供计算资源。

近年来, 对 MMDES 的著名补充之一是一种创新的方法, 称为自适应元素 De (Ande) [22]。该算法有效地导航了开发和开发, 以发现 MMOP 的多种精确戈斯范围。但是, 当应用于确定平衡多样性和分类准确性平衡的模拟基础 nn 时, 将限制安德的效率, 而特定的组成部分无法按预期运行, 就会受到限制。这种差异可能源于在测试套件中发现功能的戈斯和在 NNE 内优化 NN 之间的巨大差异。该主题将在教派中详细阐述。3. 考虑到安德在 MMOP 中的优越性以及 NNE 优化任务的独特需求, 本研究将 Ande 作为基线模型, 并提出了一些显着的改进来满足 NNE 优化要求。这项研究的显着限制如下:

1. 一种针对高维数据量身定制的改进的启发式聚类方法;
2. 旨在以最少的计算资源的方式来阐明各种各样的档案选择方案;
3. 重新设计的亚群适应策略, 在依靠更少的计算机资源的同时有效地增加了人口的多样性。

使用增强的 MMDE 算法, 可以同时优化多个 PLE NN S, 并具有可行性。与常规的反向传播 NNS 相反, 本研究采用了非著作《极限学习机器》(ELM) 算法。ELM 是一种机器学习算法, 近年来一直在广受欢迎。该算法随机分配输入权重并在分析上计算输出权重, 这会导致加速学习, 并使 ELM 不容易过度插入, 并允许对高维数据进行效率培训。因此, 将 ELM 纳入所提出的算法, 因此赋予了几个优势, 包括快速学习的步伐, 直接的 -

病房实施以及熟练处理大型数据集的能力。

尽管与ELM相关的所有优点，但缺乏确定隐藏神经元数量的系统方法对ELM构成挑战[2]。此外，ELM中固有的随机性可能会表现出学习表现。因此，本文设计了一种新颖的编码策略，以优化ELM的重量参数和同时隐藏的神经元的数量，而整体策略有效地减轻了随机性的影响。这最终在基于MMDE和ELM的NNE优化算法的建议中，称为MMDE-ELM-NNE。MMDE-ELM-NNE算法中MMDE和ELM的组合是协同的。MMDE识别多个最佳结构的能力可以使有效的合奏所需的多样性，而ELM的快速学习能力可确保每个结构都可以优化精度。他们一起为神经网络合奏优化提供了强大的方法，在一个统一的框架中解决了结构和重量优化的挑战。在基准数据集上进行了广泛的实验，以解决分类问题，以备MMDE-ELM-NNE的可行性和有效性。实验结果表明，与MMDE，ELM和其他元启发式算法相比，提出的MMDE-NNE提出了优质的竞争力。

这项研究通过四个关键方面进行了神经网络合奏的优化：

1. MMDE中的创新：我们引入了一个改进的MMDE框架，该框架具有高维簇方法，用于不同NNS的有效的档案选择方案以及一种亚群适应策略，以最小的计算资源来增强多样性。
2. nne转换为MMOP：通过将神经网络集合构建为多模式优化概率（MMOP），我们可以使用高级MMDE技术可以同时优化多个基础神经网络，从而在单个运行中识别多个全局优化。
3. ELM对反向传播的整合：我们将ELM算法集成到MMDE过程中，利用其非辅助学习来加快培训并提高分类准确性，从而提供了更有效的替代方案。
4. 同时进行优化编码：解决最佳神经网络结构的挑战，我们提出了一种新颖的编码策略，该策略可以很好地优化ELM的重量参数和隐藏的神经元，从而通过缓解ELM的固有随机性来简化集合的开发。

本文的其余部分的结构如下。第2节概述DE，MMDE和ELM。第3节概述了拟议增强的MMDE算法的特定。第4节介绍了拟议的MMDE-ELM-NNE算法的动机和工作流。第5节介绍了实验的结果及其分析，并确定了在各节中讨论的评论和未来的工作。

2 背景

本节对DE中的关键操作进行了全面概述，并探讨了自适应参数机械主义，例如Jade。它还引入了各种MMDES，并阐明了ELM的原理。此外，本节提供了网络体系结构搜索和超参数优化的全面检查，概述了他们在机器学习领域中的重要性和相互作用。

2.1 差分进化

DE是Storn和Price在1995年提出的一种流行的房地产随机搜索算法[47]。DE：突变，交叉和选择中有三个基本操作，如下所示。DE反复地形成了迭代产生新种群的三个步骤，直到满足终止条件为止。

在两个关键控制参数的配置中，DE铰链的性能显著：缩放系数 F 和交叉速率 CR 。但是，在不同的问题土地下确定这些参数的最佳值是一项艰巨的任务。为了解决这个问题，已经提出了DE的几种自适应参数机制，如先前的研究[6, 26, 34, 43]。这些机制涉及根据搜索过程的反馈动态调整控制参数。在这些方法中，Jade [26]以其出色的表现而脱颖而出，并被选为本文中的参数更新方法。与传统DE相反，Jade用自己的缩放系数 F_i 和交叉速率 CR_i 分配了每个人 $\vec{i}$ 。在每一代中， F_i 通过cauchy distribution $F_i \sim \text{Cauchy}(\mu_F, 0.1)$ 和 CR_i 进行更新，根据正常分布 $CR_i \sim N(\mu_{CR}, 0.1.1)$ 。在0.5初始化，相应的平均值 μ_F 和 μ_{CR} 的每个一代都如下更新：

$$\mu_F = (1 - b) \cdot \mu_F + b \cdot \text{mean}_L(S_F), \quad (1)$$

$$\mu_{CR} = (1 - b) \cdot \mu_{CR} + b \cdot \text{mean}_A(S_{CR}), \quad (2)$$

其中 b 是一个常数，通常设置为0.1； S_F 和 S_{CR} 表示成功增强的所有 F_i 和 CR_i 的集合

试验向量分别； $mean_L(\cdot)$ 和 $mean_A(\cdot)$ 分别是Lehmer的均值和算术均值。

2.1.1 突变

在每一代中，通过向基本个体之间添加其他个体之间的可扩展差异来为每个个体 $\vec{t}_i$ 生成一个突变矢量 $\vec{v}_i$ 。在本文中，采用了DE/BEST/1策略[46]来产生突变矢量：

$$\vec{v}_i = \vec{t}_{best} + F_i \cdot (\vec{t}_{r1} - \vec{t}_{r2}), \quad (3)$$

其中 $\vec{t}_{best}$ 是具有最高拟合度的人群中最好的个体，而 $\vec{t}_{r1}$ 和 $\vec{t}_{r2}$ 是从当前人群中随机选择的不同个体，这两者都与个人 $\vec{t}_i$ 不同。

2.1.2 跨界

使用生成的突变向量 $\vec{v}_i$ ，当前向量 $\vec{t}_i$ 与它结合在一起，以获取新的试验向量 $\vec{u}_i$ ，该向量由以下方式给出：

$$u_{i,j} = \begin{cases} v_{i,j}, & \text{if } rand(0, 1) \leq CR_i, \text{ or } j = I \\ t_{i,j}, & \text{otherwise} \end{cases}, \quad (4)$$

其中 CR_i 表示确定试验向量 $\vec{u}_i$ 与当前向量 $\vec{t}_i$ 的截然不同的交叉速率； $rand(0, 1)$ 是 $(0, 1, 1)$ ， I 之间的随机数， I 是从 $[1, D]$ 的随机整数生成的随机数，并且肯定是一个 $ement\ j = I$ ，至少是一个 $element\ element\ element\ element\ element$ 。

2.1.3 选择

在选择阶段，进行了比较，在试验矢量 $\vec{u}_i$ 的拟合度值和当前的vector $\vec{t}_i$ 之间进行了比较，以使用精英策略生成后代。在最大化优化问题的情况下，具有优势值的个人将被指定为下一代的后代。值得注意的是，高级控制议员的趋势倾向于产生具有较高生存可能性的个体，因此可以维持这些价值，并进一步传播到更多的后代。选择向量由：

$$\vec{t}_i = \begin{cases} \vec{u}_i, & \text{if } f(\vec{u}_i) > f(\vec{t}_i) \\ \vec{t}_i, & \text{otherwise} \end{cases}, \quad (5)$$

其中 $f(\cdot)$ 是要优化的目标函数。

2.2 多模式差分进化

已经开发了许多DE变体来解决MMOP，通常分类为基于Niching技术的方法和基于多目标优化的方法。与基于多个客观优化的方法相反，基于新技术的方法更简单地促进和要求更少的计算资源，从而使它们更适合MMOP。这些技术受生物学原理的启发，旨在通过将人口隔离为多个壁ni，探索多样化的戈斯。Niching de算法的显着例子包括DE (CDE) [49]和形成DE (SDE) [32]。然而，这些算法涉及复杂的细分参数，例如人群大小和物种半径。为了应对这一挑战，Qu等。引入了基于邻里的拥挤DE (NCDE) 和基于邻里的物种形成DE (NSDE)，它们在每个欧几里得社区内进行突变以保持多样化的戈斯[44]。为了扩展这个概念，Gao等人。采用了一种聚类技术来划分子呼吸，导致self_ccde和self_csde [14]。张等。提出了一种使用对局部敏感的散列方法来绕过成对距离计算的快速壁画方法[62]。

近年来，出现了新型的多模式策略，例如Loicde中基于局部信息的突变策略和Biswas等人的Loisde。[5]以及Hui等人SDE中的集合邻里突变策略。[23]。此外，Wang等人。引入了MMDESS，结合了轮廓预测方法[52]，自适应估计分布[53]，以及基于距离和基于距离的本地搜索[54]。Wei等人。采用了具有动态惩罚半径的惩罚策略来设计基于罚款的多模式优化DE (PMODE) [55]。江等。将基于NCD的DE (NCD-DE) [25]处理为优化问题 (NCD) 问题作为优化问题。对MMDE的研究已取得了显着的进步，增强了他们在解决MMOP上的效率。

2.3 极限学习机器

众所周知，由于他们采用的基于迭代梯度的学习算法，传统的前馈NN经常表现出缓慢的学习率。为了解决这一限制，黄[19-21]提出了一种用于训练单层喂食电神经网络 (SLFNS) 的名为ELM的学习算法。ELM通过随机选择隐藏节点并分析计算SLFN的输出权重来采用独特的方法。这种方法以非常快速的学习率提供了出色的一般性表现，通常比传统的进食速度快数千倍[19]。

给定一个包含 N 任意不同样本 $(\vec{x}_i, \vec{y}_i)_{i=1}^N$ 的培训数据集，其中 $\vec{x}_i = [x_{i1}, x_{i2}, \dots, x_{in}]^T \in \mathbb{R}^n$

由 n 输入属性和 $\vec{y}_i = [y_{i1}, y_{i2}, \dots, y_{im}]^T \in \mathbb{R}^m$ 组成, 由 m 输出标签组成。具有 L 隐藏节点的标准SLFN的输出可以计算为:

$$\vec{o}_j = \sum_{i=1}^L \vec{\beta}_i g(\vec{w}_i^T \vec{x}_j + b_i), \quad j = 1, \dots, N, \quad (6)$$

其中 $\vec{w}_i = [w_{i1}, w_{i2}, \dots, w_{in}]^T \in \mathbb{R}^n, i = 1, 2, \dots, L$ 表示 n 输入节点与 i th隐藏节点之间的输入权重向量; b_i 是 i th隐藏节点的偏见; $\vec{\beta}_i = [\beta_{i1}, \beta_{i2}, \dots, \beta_{im}]^T \in \mathbb{R}^m$ 是 i th隐藏节点和 m 输出节点之间的输出权重向量; $\vec{o}_i = [o_{i1}, o_{i2}, \dots, o_{im}]^T \in \mathbb{R}^m$ 是网络的输出值; $g(\cdot)$ 是激活函数, 在本文中, Sigmoid函数是通过约定选择的:

$$g(\vec{w}_i, \vec{x}_j, b_i) = \frac{1}{1 + \exp[-(\vec{w}_i \cdot \vec{x}_j + b_i)]}. \quad (7)$$

有了 β 的合适值, ACTRUAL和RISIRED输出之间的L2距离 $\sum_{j=1}^N \|\vec{o}_j - \vec{y}_j\|$ 可以以概率为一(在[21]中证明)达到零。在这种情况下, 等式。(6)可以转变为

$$\vec{y}_j = \sum_{i=1}^L \vec{\beta}_i g(\vec{w}_i^T \vec{x}_j + b_i), \quad j = 1, \dots, N. \quad (8)$$

因此, 可以将这些 N 方程组合在一起并以矩阵形式写入

$$\mathbf{H}\beta = \mathbf{Y}, \quad (9)$$

在哪里

$$\mathbf{H} = \begin{pmatrix} g(\vec{w}_1, \vec{x}_1, b_1) & \dots & g(\vec{w}_L, \vec{x}_1, b_L) \\ \vdots & \ddots & \vdots \\ g(\vec{w}_1, \vec{x}_N, b_1) & \dots & g(\vec{w}_L, \vec{x}_N, b_L) \end{pmatrix}_{N \times L}, \quad (10)$$

$$\beta = \begin{pmatrix} \vec{\beta}_1^T \\ \vdots \\ \vec{\beta}_L^T \end{pmatrix}_{L \times m}, \quad (11)$$

$$\mathbf{Y} = \begin{pmatrix} \vec{y}_1^T \\ \vdots \\ \vec{y}_N^T \end{pmatrix}_{N \times m}. \quad (12)$$

矩阵 $\mathbf{H}$ 是隐藏层的输出矩阵。 $\mathbf{y}$ 是所需的输出矩阵; β 是可以通过解决线性最小二乘问题来计算的输出权重矩阵

$$\beta = \mathbf{H}^\dagger \mathbf{Y}, \quad (13)$$

其中 $\mathbf{h}^\dagger$ 是 $\mathbf{H}$ 的摩尔-柔骨(MP)概括的 $\mathbf{H}$ 。ELM训练所涉及的步骤在算法1中显示。

Algorithm 1 Extreme learning machine (ELM)

Input: A training dataset $\{(\vec{x}_j, \vec{y}_j) | \vec{x}_j \in \mathbb{R}^n, \vec{y}_j \in \mathbb{R}^m\}_{j=1}^N$, an activation function $g(\cdot)$, and the number of hidden nodes L .

Output: The output weights β .

- 1: Initialize hidden biases and input weights randomly in the range $[-1, 1]$.
- 2: Compute the hidden layer output matrix $\mathbf{H}$ using Eq. (10).
- 3: Calculate the output weights $\beta = \mathbf{H}^\dagger \mathbf{Y}$ using the MP generalized inverse.

2.4网络体系结构搜索和超参数优化

神经网络体系结构搜索(NAS)和参数优化是神经网络(NN)设计领域中的关键组件, 对模型的学习能力和复杂性产生了重大影响。NNS的结构配置, 包括深度(层数)和宽度(每层神经元的数量), 因为它直接影响了该模型的学习能力及其整体组合。深度和宽度的不同组合会导致实质性的性能差异。因此, 识别最佳体系结构对于增强模型性能至关重要。对最佳体系结构的追求涉及探索可能配置的巨大搜索空间, 以找到最能符合给定数据集和任务的搜索空间, 并在拟合不足和过度拟合之间保持平衡。

参数优化是NNS内的另一个关键研究领域。它涵盖了权重和偏见的初始化, 激活功能的选择以及学习率的调整。采用优化算法, 例如随机梯度下降(SGD), 均方根传播(RMSPROP) [50]和自适应力矩估计(ADAM) [30]来更新网络权重, 旨在最小化损耗函数。为了防止过度拟合, 通常使用正则化技术, 例如L1和L2正则化以及辍学。这些方法通过降低学习表示的复杂性并防止模型在训练数据中拟合噪声来帮助概括模型。

随着NNS的研究加深, 已经出现了许多用于结构和参数优化的高级方法。例如, EA用于架构搜索, 模拟自然选择的过程以优化网络结构[1, 8, 10, 38]。这些进化方法通过应用遗传操作员(例如选择, 交叉和突变)迭代地重新阐述了体系结构, 从而导致更有效和有效的NN结构的演变。

此外,已经提出了多目标遗传算法(MOGAS) [40],以发现最佳的结构参数集[3, 7, 7, 39, 42]。这些方法解决了NN优化问题的多方面性质,在这种情况下,必须平衡准确性,复杂性和概括等目标。MOGA方法提供了一系列帕累托最佳解决方案,使研究人员可以根据不同的objectives之间的权衡选择最佳体系结构。

总之,建筑搜索和参数优化的领域正在迅速发展,研究人员不断开发创新的方法来自动化和增强NNS的设计过程。随着NNS的复杂性的增加,需要复杂的选择技术来导航复杂的可能性景观并发现给定任务的最有效模型。

3增强的MMDE算法用于NNE优化

本节详细概述了增强的MMDE算法及其量身定制的旨在优化NNE的组件。

3.1增强的MMDE集成及其组件

该小节详细介绍了增强的MMDE算法的集成,其创新策略以及有效地优化神经网络结合四个关键增强功能,从而解决了高维NNE优化的独特挑战。

3.1.1 Ande及其策略简介

已经开发了许多复杂的方法来解决MMOP, Ande [22]是一种特别有效的方法。安德介绍了三种创新策略:

1. 一种启发式聚类方法,基于该问题的特定格局的总体分布,可自适应地识别非重叠的亚群; 2. 一种动态参数适应机制,可通过消除重叠的子诉讼来增强停滞不前的人群中的多样性并减少综合开销; 3. 一种辅助运动计划,有助于停滞亚群,以逃避当地的最佳选择,并指导人口将人口转向更有前途的地区。

这些新颖的技术在MMOP上具有高水平的优化能力,协同增强了ANDE。Huang对CEC2013的20种多模式测试函数的实验[33]表明,Ande的表现优于跨各种评估协议,包括峰值比,成功率和融合速度,优于最可比的元素算法。此外,对三个组成部分的效能的分析表明,尽管每个组成部分在安德内都起着不明显的作用,但它们统称为其有效的优化性能做出了贡献。

3.1.2 优化挑战

尽管有这些优势,但在NNE优化中的应用并没有表现出与测试功能中观察到的相同的性能水平。这种差异可能归因于NNE优化和MMOPS之间的固有差异:

1. nne优化,尽管为方便起见,虽然被归类为MMOP,但在问题范围内有很大不同。尽管CEC2013测试套件中的大多数功能是1-D到3-D,但NNE优化问题可能跨越数百个维度。 2. 优化的目标在两种问题类型之间也有所不同。MMOP评估方案典型地集中于在有限的拟合度评估中最大化全球最佳选择的大小,而NNE Optimization强调发现具有高度多样性和准确性的合适数量的NNS,而不是全球最佳解决方案空间的完整性。

3.1.3 NNE的MMDE增强功能

为了解决上面说明的这些区别,提出了增强的MMDE,以更好地满足NNE优化的要求。该增强算法包含四个关键增强功能:

1. 通过对两个亚群之间的距离计算标准进行改进,从而改善了启发式聚类方法,从而导致人群的更连贯分区。这一改进在解决诸如NNE之类的高维优化问题方面尤其有利,这为随后的壁nikes进化进展提供了更强大的基础。
2. 提出了一种档案选择策略,以确定最有希望的非重叠解决方案,从而在存档中保存的有希望的NNS的多样性和准确性之间达到了平衡。 3. 通过消除其排除分并重新发现的,提出了改进的亚群适应策略

增强组件。在排除方面，这种变化的目标是在实验过程中观察到的高维情况下排除策略的有限效率。洞察强调了排除策略在效率上消除毫无意义的亚群中所面临的挑战，从而导致了将整个进化过程分配给距离的40%的大量部分。在另一个方面，在增强阶段对关键算法的修改着重于增强人群内部的多样性。重新设计的策略有效地提高了停滞不前的人群的多样性，同时需要更少的计算资源。

4. 此外，为了更好地适应NNE优化问题的区别，调整了特定的阈值和边界条件。

3.2改进的启发式聚类方法

聚类是DE中的主要构造技术。但是，现有的基于群集的利基算法通常将整个群体分为一组亚种群，亚种群的数量通常由被称为群集大小的超参数预先确定。建立最佳簇大小会带来挑战，因为它取决于手头的特定任务。为了减轻这一挑战，引入了一种启发式聚类方法，旨在在不引入任何超参数的情况下产生非重叠的亚群[22]。该方法采用了一种策略，其中人口中的每个人都被视为独特的亚群。逐渐地，基于接近度合并了成对的亚群，直到满足构成条件为止。最后，删除了少于四个人的亚群，因为DE必须至少每个亚群以进行有效操作。

尽管这种聚类方法可以在低维情况下有效地将人群置于非重叠的亚群中，但在高维问题空间涉及优化NNE的结构和权重时，会出现挑战，其中包含数百个维度。在这种情况下，原始的启发式聚类方法倾向于将一部分人口合并为一个单一的亚群，这偏离了奈奇技术的目标，并为后续进化过程提供了贫困的基础。性能的差异可以归因于原始方法中使用的距离度量，其中两个亚群（表示为 $D(p_k, p_s)$ ）之间的距离定义为与每一集的任何两个点之间的最小距离：

$$D(\mathbf{P}_k, \mathbf{P}_s) = \min_{\vec{t}_i \in \mathbf{P}_k, \vec{t}_r \in \mathbf{P}_s} d(\vec{t}_i, \vec{t}_r), \quad (14)$$

其中 $d(\vec{t}_i, \vec{t}_r)$ 是个人 $\vec{t}_i$ 和 $\vec{t}_r$ 之间的欧几里得距离。

该计算标准仅关注从给定亚群到另一个亚种群中任何点的最接近点。因此，一个包括越来越多个人的亚种群自然增加了建立其他亚群较短距离的可能性，从而促进了更高的吸收其他个体的趋势。因此，在集群过程开始时，一个亚种群纳入了更多个体，从本质上讲，逐渐逐渐体验了大量扩张。结果，随后在Sect中进行了测试。5.4.3，在高维问题空间（超过10个维度）中，最大的子人口可能包含聚类结束时整个人群的一半。

在改进的聚类方法（如算法2中所示）中，将两个子 p_k 和 p_s 之间的距离测量定义为集合 p_k 中任何点之间的任何平均距离与集合 $p_s : v12 : v12 : v12 : v12 : v12$ ：

$$D(\mathbf{P}_k, \mathbf{P}_s) = \frac{1}{|\mathbf{P}_k||\mathbf{P}_s|} \sum_{\vec{t}_i \in \mathbf{P}_k, \vec{t}_r \in \mathbf{P}_s} d(\vec{t}_i, \vec{t}_r), \quad (15)$$

其中 $d(\vec{t}_i, \vec{t}_r)$ 是个体 $\vec{t}_i$ 和 $\vec{t}_r$ ， $|\mathbf{P}_k|$ 和 $|\mathbf{P}_s|$ 之间的欧几里得距离，是子群体的个体 p_k 和 p_s 。

Algorithm 2 Improved heuristic clustering

Input: Initial population $\mathbf{P}_0$.

Output: Subpopulations $\{\mathbf{P}_1, \mathbf{P}_2, \dots, \mathbf{P}_m\}$.

1: **for** $k = 1$ to $|\mathbf{P}_0|$ **do**

2: $\mathbf{P}_k \leftarrow \mathbf{P}_0[k]$;

3: **end for**

4: Calculate the inter-cluster distance d_{inter} and intra-cluster distance d_{intra} for $\mathbf{P}$;

$\mathbf{P} = \{\mathbf{P}_1, \mathbf{P}_2, \dots, \mathbf{P}_n\}$

$d_{inter} = \sum_{\mathbf{P}_k, \mathbf{P}_s \in \mathbf{P}} D(\mathbf{P}_k, \mathbf{P}_s)$

$d_{intra} = \sum_{\mathbf{P}_k \in \mathbf{P}} \sum_{\vec{t}_i, \vec{t}_r \in \mathbf{P}_k} d(\vec{t}_i, \vec{t}_r)$

5: **while** $d_{inter} > d_{intra}$ **do**

6: Merge clusters $\mathbf{P}_k$ and $\mathbf{P}_s$ where $D(\mathbf{P}_k, \mathbf{P}_s) = \min_{k \neq s} D(\mathbf{P}_k, \mathbf{P}_s)$;

7: Update d_{inter} and d_{intra} ;

8: **end while**

如后来所示。5.4.3，改进的方法可以很好地处理高尺寸，这使其成为适合NNE优化的工具。

3.3亚群运动和档案方案

DES虽然强大，但通常会遭受过早的逆转和搜索停滞。为了应对这一挑战，请从Ande [22]中的方法中汲取课程，

如算法3所示, 提出了iLiary运动和归档技术。该技术将子种群分为三个状态: 停滞, 融合和融合。

Algorithm 3 Auxiliary movement and archive

Input: $\mathbf{P}_k^q$ (the k th subpopulation in its q th generation), $\vec{t}_k^q$ and $\vec{t}_k^{q-1}$ (the best solutions of the k th subpopulation in its q th and $(q-1)$ th generation), $f(\cdot)$ (the fitness function), ϵ_0 and θ (small given numbers), St (a given integer), η (the count of generations that the best individual of $\mathbf{P}_k$ stops updating).

Output: The new subpopulation $\mathbf{P}_k^q$ and the updated archive of promising solutions.

```

1: Initialize Status as None;
2: Calculate  $R(\mathbf{P}_k^q)$  by Eq. (19);
3: if  $f(\vec{t}_{best}^q) - f(\vec{t}_{best}^{q-1}) \leq \epsilon_0$  then
4:    $\eta++$ 
5:   if  $R(\mathbf{P}_k^q) \leq \theta$  then
6:     Status = Converged;
7:   else if  $\eta == St$  then
8:     Status = Stagnating;
9:   end if
10: else
11:   Status = Converging;
12: end if
13: if Status  $\neq$  None then
14:    $\eta = 0$ ;
15: end if
16: if Status = Converging then
17:   Apply Brownian movement by Eq. (18);
18: else if Status = Stagnating then
19:   Apply uniform random movement by Eq. (16);
20: else if Status = Converged then
21:   Add  $\vec{t}_k^q$  to the external archive;
22:   Reinitialize  $\mathbf{P}_k^q$ ;
23: end if

```

对于 q 世代中的亚群 $\mathbf{p}_k$, 其最好的个体表示为 $\vec{t}_{best}^{\mathbf{p}_k^q}$ 。如果其最佳个体的贴合值更新为 St 连续的世代, 则将亚群 $\mathbf{p}_k^q$ 识别为停滞。参数 St 确定算法对临时停滞的公差, 影响收敛速度。在此艺术中, St 设置为六个, 以平衡收敛和停滞耐受性。特别是, 如果连续六代连续六代, $f(\vec{t}_{best}^{\mathbf{p}_k^q}) - f(\vec{t}_{best}^{\mathbf{p}_k^{q-1}}) \leq \epsilon_0$, 亚群 $\mathbf{p}_k^q$ 被分类为停滞, $\epsilon_0 = 0.001$ 。为了减轻停滞, 一个均匀的随机运动

$$\vec{t}_{best}^{\mathbf{p}_k^q} = U[\vec{t}_{min}, \vec{t}_{max}] \quad (16)$$

应用于 $\mathbf{p}_k^q$, 其中 $\vec{t}_{min}$ 和 $\vec{t}_{max}$ 是每个人的预授予的下限和上限, $U[\vec{t}_{min}, \vec{t}_{max}]$ rep-从 $\vec{t}_{min}$ 到 $\vec{t}_{max}$ 的均衡性分布。如果 $\vec{t}_{best}^{\mathbf{p}_k^q}$ 的某些尺寸在 $[\vec{t}_{min}, \vec{t}_{max}]$ 之外, 它们将

重置为可行的边界。运动后, $\vec{t}_k^q$ 和 $\vec{t}_{best}^{\mathbf{p}_k^q}$ 之间做出了贪婪的选择

$$\vec{t}_{best}^{\mathbf{p}_k^q} = \begin{cases} \vec{t}_{best}^{\mathbf{p}_k^q}, & \text{if } f(\vec{t}_{best}^{\mathbf{p}_k^q}) > f(\vec{t}_{best}^{\mathbf{p}_k^{q-1}}) \\ \vec{t}_{best}^{\mathbf{p}_k^{q-1}}, & \text{otherwise} \end{cases} \quad (17)$$

在此运动之后, 停滞的亚群能够掉落到一些更有前途的区域并转化为收敛的亚群。

相反, 如果其最佳解决方案超过先前的最佳解决方案, 即 $f(\vec{t}_{best}^{\mathbf{p}_k^q}) - f(\vec{t}_{best}^{\mathbf{p}_k^{q-1}}) > \epsilon_0$, 则将亚群 $\mathbf{p}_k^q$ 视为收敛。为了防止过早融合并增强多样性, 最好的个体 $\vec{t}_k^q$ 经历了布朗运动

$$\vec{t}_{best}^{\mathbf{p}_k^q} = N(\vec{t}_{best}^{\mathbf{p}_k^q}, R(\mathbf{P}_k^q)), \quad (18)$$

其中 $R(\mathbf{p}_k^q)$ 是 $\mathbf{p}_k^q$ 的半径, 由

$$R(\mathbf{P}_k^q) = \frac{1}{|\mathbf{P}_k^q| - 1} \sqrt{\sum_{i=1}^{|\mathbf{P}_k^q|} (\vec{t}_{best}^{\mathbf{p}_k^q} - \vec{t}_i^{\mathbf{p}_k^q})^2}. \quad (19)$$

随后的步骤, 包括离群值的重置和贪婪的选择, 反映出那些用于停滞亚群的措施。

当其最佳解决方案停止更新并且其半径降至阈值 θ 时, 该子群被认为是收敛的, 该解决方案设置为0.01。为了保护光学解决方案免于融合的亚群, 它将存储到外部存档以进行后续选择。同时, 亚群经历了整个重新定性过程, 保持其原始大小, 所有个体随机再生在 $[\vec{t}_{min}, \vec{t}_{max}]$ 的范围内。在亚种群融合的情况下, 这表明所有个人都集中在峰值解决方案周围, 对该局部区域的持续开发可能是不合理的。为了减轻这种亚种群中的冗余搜索并增强人群的总体多样性, 从而加强了算法在问题空间内探索未知领域的的能力, 因此认为, 对融合的亚种群进行了完全重新定义。

在进化过程结束并用潜在的解决方案填充档案之后, 采用算法4中概述的选择策略被用来确定最后一个人群和档案馆中最有希望的解决方案。首先, 将上一代人的每个子呼吸中的最好的人提取并合并到档案中。在整个存档中表现出最高拟合度值的解决方案表示为 $\vec{t}_{best}$ 。然后, 在受控的解决方案范围内 (3至15之间),

较低的拟合值（即 $\vec{t}_i$ s, 其中 $f(\vec{t}_{best}) - f(\vec{t}_i) > \epsilon_1$ ）被排除以提高最终精度。之后，计算每对解决方案之间的距离。如果两个解决方案 $\vec{t}_i$ 和 $\vec{t}_j$ 之间的距离低于阈值（即 $d_{ij} < \epsilon_2 \cdot D$, 其中 D 代表解决方案空间的尺寸），则消除了具有较低效果值的解决方案。此步骤旨在保留解决方案多样性，并防止在随后的过程中纳入类似的基本网络。在本文中， ϵ_1 和 ϵ_2 的值分别设置为0.05和0.01。

Algorithm 4 Archive selection

Input: $\mathbf{P}_1$ (set of solutions in the archive), $\mathbf{P}_2$ (set of solutions in the last population), $f(\cdot)$ (the fitness function), ϵ_1 and ϵ_2 (small predefined values), D (dimension of the solution space).

Output: Selected candidate NN sets $\mathbf{P}_c$.

```

1: Initialize  $i = 0$ ;
2: Merge  $\mathbf{P}_c \leftarrow \mathbf{P}_1 \cup \mathbf{P}_2$ ;
3: Sort  $\mathbf{P}_c$  in ascending order and set  $\vec{t}_{best}$  as the best individual in  $\mathbf{P}_c$ ;
4: for  $i = 1$  to  $|\mathbf{P}_c|$  do
5:   if  $|\mathbf{P}_c| \leq 3$  then
6:     break;
7:   end if
8:   if  $f(\vec{t}_{best}) - f(\vec{t}_i) > \epsilon_1$  then
9:     Remove  $\vec{t}_i$  from  $\mathbf{P}_c$ ;
10:  end if
11: end for
12: Sort  $\mathbf{P}_c$  in descending order;
13: while  $|\mathbf{P}_c| > 3$  do
14:   for  $i = 1$  to  $|\mathbf{P}_c|$  do
15:     for  $j = i + 1$  to  $|\mathbf{P}_c|$  do
16:       Calculate the Euclidean distance  $d_{ij}$ ;
17:       if  $d_{ij} < \epsilon_2 \cdot D$  then
18:         Remove  $\vec{t}_j$  from  $\mathbf{P}_c$ ;
19:       end if
20:     end for
21:   end for
22: end while
23: if  $|\mathbf{P}_c| > 15$  then
24:   for  $i = 16$  to  $|\mathbf{P}_c|$  do
25:     Remove  $\vec{t}_i$  from  $\mathbf{P}_c$ ;
26:   end for
27: end if

```

如果 G_q 的值在连续 St 的连续世代保持恒定，则认为这是停滞的。为了使人口恢复活力并增强其多样性，生成了另一个亚群 $\mathbf{P}'$ ，并与现有人群合并。 $\mathbf{P}'$ 的大小匹配了库生成的平均亚群尺寸。在增强策略中，将阈值的参数设置定义为 $\epsilon_0 = 0.001$ 和 $St = 6$ ，与用于子流动的参数对齐，如章节所述。3.3。这种增强过程旨在将新鲜的遗传个体引入人群中，从而减轻停滞并促进进步。

Algorithm 5 Population augmentation

Input: $\mathbf{P}^q$ (the population in its q th generation), $f(\cdot)$ (the fitness function), $\vec{t}_{best}^{\mathbf{P}^q}$ and $\vec{t}_{best}^{\mathbf{P}^{q-1}}$ (the best solutions of the population in its q th and $(q-1)$ th generation), ϵ_0 (a small given number), η (the count of generations that the best individual of $\mathbf{P}^q$ stops updating), St (a given integer).

Output: The augmented population $\mathbf{P}^{q+1}$.

```

1: Initialize  $G_t = 0$ ;
2: if  $f(\vec{t}_{best}^{\mathbf{P}^q}) - f(\vec{t}_{best}^{\mathbf{P}^{q-1}}) \leq \epsilon_0$  then
3:   for  $j = 1$  to  $|\mathbf{P}^q|$  do
4:     if  $f(\vec{t}_{best}^{\mathbf{P}^q}) - f(\vec{t}_j^{\mathbf{P}^q}) \leq \epsilon_0$  then
5:        $G_t++$ ;
6:     end if
7:   end for
8:   if  $G_t == G_{q-1}$  then
9:      $\eta++$ ;
10:  else
11:     $\eta = 0$ ;
12:  end if
13: end if
14: if  $\eta == St$  then
15:   create a random subpopulation  $\mathbf{P}'$ ;
16:    $\mathbf{P}^{q+1} = \mathbf{P}^q \cup \mathbf{P}'$ ;
17:    $\eta = 0$ ;
18: end if

```

3.4 人口增强

为了解决人口停滞，如算法5所述，向停滞的人口引入了一个新的亚种群。最初，算法评估该算法是否在当前人口中最好的最佳解决方案的实质价值有所提高，以前表示为 $f(\vec{t}_{best}^{\mathbf{P}^q})$ ，如果是 $f(\vec{t}_{best}^{\mathbf{P}^{q-1}})$ ，I.v14, I.
 $f(\vec{t}_{best}^{\mathbf{P}^q}) - f(\vec{t}_{best}^{\mathbf{P}^{q-1}}) > \epsilon_0$ 。如果不是，则该算法通过监视变量 G_q 来跟踪所有子群体的最佳发现。如果 G_q 匹配 G_{q-1} 的值，则计数器 η 会增加。人口

4 基于增强的MMDE和ELM的合奏学习算法

本节概述了拟议的MMDE-ELM-NNE Algo-Rithm背后的动机和工作流程。它深入研究了MMOP转换为NNE优化问题，并解决了关键方面，例如功能以及编码和解码策略。

4.1 动机

(1) 由于可以将NNE问题视为MMOP，因此提出了增强的MMDE，以将高维数据集的分类问题完全插入

。

(2) 增强的MMDE算法可以同时优化SLFN的结构和输入参数。随后，其输出参数是通过ELM中采用的MP伪内方法计算的。以这种方式，可以在给定的分类问题上进行多个具有不同数量的隐藏神经元数的基本NN，以便可以保持基础NN的多样性并确保NNE的概括能力确保强大。

(3) 将ELM算法集成到MMDE的优化过程中，提高了由于其非读图学习性质而导致的计算效率和分类精度。

4.2 编码和解码策略

长期以来，确定NN的最佳结构一直是一项艰巨的任务。过于简单的网络可能缺乏有效地模拟当前问题的能力，而过于复杂的网络可能会导致过度拟合和次要概括性能。选择适当的网络拓扑是至关重要的，因为网络处理信息的能力本质上与其结构相关。已经设计了两种主要的策略来调整网络的结构：修剪算法[51, 59]和建设性算法[31, 60]。但是，通过这些方法生成的NN结构通常会融合到局部优点。在这项工作中，提出了一种创新的编码策略，以实现基础NN拓扑和权重参数的同时选择。此外，还合并了ELM体系结构，以增强网络的计算能力。

4.2.1 编码策略

在提出的MMDE-ELM-NNE框架中，每个SLFN的拓扑和权重信息都在同一个人中编码，从而可以同时进行优化。每个人都表示为实数矢量，包括隐藏层神经元的状态参数，输入和隐藏层之间的权重以及隐藏的层偏见。

对于输入层中 n 神经元的SLFN， L 神经元在隐藏层中，而输出层中的 m 神经元，一个人表示为 $\vec{t} = [\vec{\delta}^T, \vec{w}_1^T, \vec{w}_2^T, \dots, \vec{w}_L^T, \vec{b}^T]$ ，其中 $\vec{\delta} \in \mathbb{R}^L$ ， $\vec{w}_1, \vec{w}_2, \dots, \vec{w}_L \in \mathbb{R}^n$ ， $\vec{b} \in \mathbb{R}^1$ 。该编码向量的维度可以为 $D = (n + 2) \times L$ 。每个向量的元素在 $[-1, 1]$ 范围内浮点号。

图1说明了一个带有两个神经元的输入层的SLFN的示例，一个带有五个神经元的隐藏层以及带有两个神经元的输出层。网络的参数配置在表1中列出




图1具有三层的SLFN模型

表1在图1所示的SLFN模型中要优化的参数。

$\vec{\delta}^T$	δ_1	δ_2	δ_3	δ_4	δ_5
$\mathbf{W}$	w_{11}	w_{21}	w_{31}	w_{41}	w_{51}
	w_{12}	w_{22}	w_{32}	w_{42}	w_{52}
$\vec{b}^T$	b_1	b_2	b_3	b_4	b_5

诸如 $\vec{\delta}$ 表示的隐藏层中神经元的激活状态，链接输入的重量矩阵和表示为 $\mathbf{w} = [\vec{w}_1, \vec{w}_2, \vec{w}_3, \vec{w}_4, \vec{w}_5]$ 的隐藏层，以及偏置向量到隐藏层，称为 $\vec{b}$ 。这些参数依次编码为21维矢量 $\vec{t} = [\vec{\delta}^T, \vec{w}_1^T, \vec{w}_2^T, \vec{w}_3^T, \vec{w}_4^T, \vec{w}_5^T, \vec{b}^T]$ 。

4.2.2 解码策略

i th隐藏层神经元的激活状态可以从状态参数 δ_i 获得。

$$s_i = \begin{cases} 0, & \text{if } \text{sigmoid}(\delta_i) < \text{rand}(0, 1) \\ 1, & \text{otherwise} \end{cases}, \quad (20)$$

其中 $\text{rand}(0, 1)$ 是 $(0, 1)$ 之间的随机数，而

$$\text{sigmoid}(\delta_i) = \frac{1}{1 + \exp(-\delta_i)}. \quad (21)$$

这样，对于 $[-1, 1]$ 范围内的每个流量点号 δ_i ，都有一个相应的二进制值 s_i (以0或1)的值为单位，其中 s_i 指示激活状态

表2 CEC2013基准函数的特征和参数设置

Function	Dimension	Number of global optima	<i>NP</i>	<i>max FEs</i>
F1	1	2	100	5.00E+04
F2	1	5	100	5.00E+04
F3	1	1	100	5.00E+04
F4	2	4	100	5.00E+04
F5	2	2	100	5.00E+04
F6	2	18	100	2.00E+05
F7	2	36	300	2.00E+05
F8	3	81	300	4.00E+05
F9	3	216	300	4.00E+05
F10	2	12	100	2.00E+05
F11	2	6	200	2.00E+05
F12	2	8	200	2.00E+05
F13	2	6	200	2.00E+05
F14	3	6	200	4.00E+05
F15	3	8	200	4.00E+05
F16	5	6	200	4.00E+05
F17	5	8	200	4.00E+05
F18	10	6	200	4.00E+05
F19	10	8	200	4.00E+05
F20	20	8	200	4.00E+05

被指定为最终分类结果，这是一种通常被称为“赢家全部”方法的策略。

5个实验

为了证明MMDE-NNE的优势和有效性，进行了比较实验，以评估其针对其他最先进的算法。此外，进行了其他实验，以深入研究MMDE-ELM-NNE的性能。这些实验的重点是研究各种因素的影响，包括NNE中的基本NN的数量，隐藏神经元的数量，人口大小，最大世代数以及改善的启发式聚类方法的有效性。

5.1 MMOP上的实验螺柱

在此部分中，通过使用CEC2013基准套件来精心评估所提出的MMDE算法的性能[33]。该套件传递了20个多模式测试功能，它们被绝对地分为三个不同的组。最初的十种功能是众所周知的低维基本功能，可作为算法评估的基本测试床。随后的五个函数是低维函数，其特征是存在众多

本地Optima，从而对选择算法提出了重大挑战。其余的五个函数是高维复合函数，由于维度的诅咒，增加了另一层复杂性。表2详细介绍了这些功能的尺寸和全局优势的数量。

MMDE的实验结果与11个经典和最先进的多模式优化算法进行了比较，如下所示。

- CDE [49]：基于拥挤的差异进化；
- SDE [32]：基于物种形成的差异进化；
- NCDE [44]：基于拥挤的差异进化，邻里突变；
- NSDE [44]：基于邻域突变的基于物种形成的差异进化；
- dade/nrand/1 [11]：具有自适应参数的动态档案构成不同的演变；
- Anlde [45]：自适应邻居突变和局部搜索的差异进化；
- PRMDE [61]：基于接近度排名的多模式差异进化；
- LBPADE [64]：基于局部二元模式的自适应差异进化；
- AED-DDE [53]：自适应估计分布分布分离的差异演化；
- VNCDE [63]：无参数的Voronoi邻域差异进化；

表3 MMDE的PR和SR在20个基准功能上

ϵ	F1		F2		F3		F4		F5	
	PR	SR	PR	SR	PR	SR	PR	SR	PR	SR
1.0E-01	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
1.0E-02	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
1.0E-03	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
1.0E-04	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
1.0E-05	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
ϵ	F6		F7		F8		F9		F10	
	PR	SR	PR	SR	PR	SR	PR	SR	PR	SR
1.0E-01	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
1.0E-02	1.000	1.000	1.000	1.000	1.000	1.000	0.712	0.000	1.000	1.000
1.0E-03	1.000	1.000	0.964	0.800	1.000	1.000	0.646	0.000	1.000	1.000
1.0E-04	1.000	1.000	0.964	0.360	1.000	1.000	0.646	0.000	1.000	1.000
1.0E-05	0.980	0.960	0.950	0.293	1.000	1.000	0.624	0.000	1.000	1.000
ϵ	F11		F12		F13		F14		F15	
	PR	SR	PR	SR	PR	SR	PR	SR	PR	SR
1.0E-01	1.000	1.000	0.863	0.000	1.000	1.000	1.000	1.000	1.000	1.000
1.0E-02	1.000	1.000	0.863	0.000	0.816	0.000	0.716	0.000	0.735	0.000
1.0E-03	1.000	1.000	0.863	0.000	0.816	0.000	0.716	0.000	0.701	0.000
1.0E-04	1.000	1.000	0.834	0.000	0.816	0.000	0.714	0.000	0.701	0.000
1.0E-05	1.000	1.000	0.747	0.000	0.766	0.000	0.704	0.000	0.623	0.000
ϵ	F16		F17		F18		F19		F20	
	PR	SR	PR	SR	PR	SR	PR	SR	PR	SR
1.0E-01	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	0.454	0.400
1.0E-02	0.667	0.000	0.667	0.000	0.670	0.000	0.731	0.000	0.301	0.000
1.0E-03	0.667	0.000	0.667	0.000	0.667	0.000	0.463	0.000	0.267	0.000
1.0E-04	0.667	0.000	0.667	0.000	0.667	0.000	0.463	0.000	0.242	0.000
1.0E-05	0.667	0.000	0.413	0.000	0.633	0.000	0.298	0.000	0.061	0.000

- 安德[52]：使用轮廓预测方法自动差异演变。

当最大功能评估数量 (MAXFE) 耗尽时, 所有算法终止。对于每个测试功能, 表2中提供了MAXFE和人口大小 (NP) 的特定值。此外, 由于算法的随机性质, 每个算法都独立执行了30次。将两个评估指标峰值比 (PR) 和成功率 (SR) 与其他奈基算法进行比较。峰值比 (PR) 定义为鉴定为已知全局最佳Optima的全局优化的平均百分比, 给定固定的MAXFE和特定的精度级别 ϵ 。成功率 (SR) 是成功运行的百分比, 在该运行中, 成功的运行定义为确定所有已知的全球最佳OPTA。在实验中, 五个精度级别 ($\epsilon = 1.0e - 01, 1.0e - 02, 1.0e - 03, 1.0e - 04$ 和 $1.0e - 05$)

Optima。由于空间约束, 除非另有说明, 否则主要报告 $\epsilon = 1.0E - 04$ 的结果。表3列出了MMDE在F1-F20的所有五个精度水平上的PR和SR的结果。如表所示, MMD E成功地识别了 $\epsilon = 1.0E - 01$ 的18个功能的所有全局最佳功能, 证明了其在求解MMMOP的有效性。为了进一步将MMDE的性能与其他多模式优化算法进行比较, 表4提供了PR和SR的比较分析, 以精确级别 $\epsilon = 1.0E - 04$ 提供了对PR和SR的比较分析。为了清楚起见, 表现最佳的PR以粗体突出显示。如表4所示, Proped的MM DE算法达到了20个测试功能中14个最佳PR, 并成功地找到了20个测试功能中9个已知的Optima。总而言之, 在相同的MAXFE下, MMDE在评估指标 (例如PR和SR) 中的大多数比较算法的表现优于大多数比较算法。这证明了MMDE在多模式优化任务中的优势。

表4 PR和SR 在精确度L的20个基准函数上比较算法的十二个 $\text{level } \varepsilon = 1.0 \times 10^{-4}$

	MMDE		CDE		SDE		NCDE		NSDE		dADE/nrand/1	
	PR	SR	PR	SR	PR	SR	PR	SR	PR	SR	PR	SR
F1	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
F2	1.000	1.000	1.000	1.000	0.920	0.800	1.000	1.000	0.856	0.544	1.000	1.000
F3	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
F4	1.000	1.000	1.000	1.000	0.366	0.000	1.000	1.000	0.822	0.436	1.000	1.000
F5	1.000	1.000	1.000	1.000	0.910	0.824	1.000	1.000	0.865	0.632	1.000	1.000
F6	1.000	1.000	0.988	0.920	0.129	0.000	0.455	0.000	0.176	0.000	0.976	0.760
F7	0.964	0.360	0.754	0.000	0.122	0.000	0.882	0.000	0.238	0.000	0.827	0.000
F8	1.000	1.000	0.010	0.000	0.176	0.000	0.020	0.000	0.204	0.000	0.962	0.360
F9	0.646	0.000	0.467	0.000	0.231	0.000	0.539	0.000	0.166	0.000	0.422	0.000
F10	1.000	1.000	1.000	1.000	0.158	0.000	0.856	0.720	0.357	0.000	1.000	1.000
F11	1.000	1.000	0.322	0.000	0.334	0.000	0.788	0.045	0.482	0.000	0.667	0.000
F12	0.834	0.000	0.060	0.000	0.306	0.000	0.179	0.000	0.364	0.000	0.700	0.000
F13	0.816	0.000	0.134	0.000	0.312	0.000	0.667	0.000	0.276	0.000	0.667	0.000
F14	0.714	0.000	0.018	0.000	0.233	0.000	0.667	0.000	0.258	0.000	0.667	0.000
F15	0.701	0.000	0.007	0.000	0.025	0.000	0.325	0.000	0.189	0.000	0.619	0.000
F16	0.667	0.000	0.000	0.000	0.124	0.000	0.667	0.000	0.184	0.000	0.667	0.000
F17	0.667	0.000	0.000	0.000	0.128	0.000	0.187	0.000	0.176	0.000	0.370	0.000
F18	0.667	0.000	0.188	0.000	0.057	0.000	0.503	0.000	0.377	0.000	0.623	0.000
F19	0.463	0.000	0.000	0.000	0.209	0.000	0.346	0.000	0.089	0.000	0.029	0.000
F20	0.242	0.000	0.000	0.000	0.000	0.000	0.220	0.000	0.139	0.000	0.002	0.000
Mean	0.819	0.468	0.447	0.346	0.337	0.181	0.615	0.288	0.411	0.181	0.710	0.356

	ANLDE		PRMDE		LBPADE		AED-DDE		VNCDE		ANDE	
	PR	SR	PR	SR	PR	SR	PR	SR	PR	SR	PR	SR
F1	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
F2	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
F3	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
F4	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
F5	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
F6	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	0.967	0.540	1.000	1.000
F7	0.886	0.000	0.988	0.686	0.889	0.000	0.838	0.039	0.746	0.000	0.933	0.176
F8	0.999	0.902	1.000	0.980	0.575	0.000	0.747	0.000	0.558	0.000	0.944	0.078
F9	0.454	0.000	0.706	0.000	0.476	0.000	0.384	0.000	0.298	0.000	0.512	0.000
F10	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
F11	1.000	1.000	0.997	0.980	0.674	0.000	1.000	1.000	1.000	1.000	1.000	1.000
F12	0.993	0.961	1.000	1.000	0.750	0.000	1.000	1.000	0.993	0.940	0.868	0.940
F13	1.000	1.000	0.667	0.000	0.667	0.000	0.686	0.000	0.687	0.000	0.687	0.000
F14	0.667	0.000	0.667	0.000	0.667	0.000	0.667	0.000	0.667	0.000	0.667	0.000
F15	0.667	0.000	0.615	0.000	0.654	0.000	0.637	0.000	0.748	0.000	0.632	0.000
F16	0.618	0.000	0.667	0.000	0.667	0.000	0.667	0.000	0.667	0.000	0.667	0.000
F17	0.667	0.000	0.507	0.000	0.532	0.000	0.375	0.000	0.593	0.000	0.397	0.000
F18	0.660	0.000	0.667	0.000	0.667	0.000	0.654	0.000	0.667	0.000	0.654	0.000
F19	0.463	0.000	0.453	0.000	0.475	0.000	0.375	0.000	0.475	0.000	0.363	0.000
F20	0.255	0.000	0.252	0.000	0.275	0.000	0.250	0.000	0.290	0.000	0.248	0.000
Mean	0.816	0.543	0.809	0.532	0.748	0.350	0.764	0.452	0.768	0.424	0.779	0.460

表5基准分类问题的特征

Datasets	Samples	Features	Classes
Heart	270	13	2
Pima	768	8	2
Wine	178	13	3
Balance	625	4	3
Iris	150	4	3
Seeds	210	7	3
Breast	699	9	2
Haberman	306	3	2
Blood	748	4	2
Australian	690	14	2
Liver	345	6	2
Hepatitis	155	19	2
Diabetic	1151	19	2

5.2分类实验设置

从UCI机器学习存储库[4]中，总共选择了13个基准分类数据集用于实验。这些数据集涵盖了不同的领域。表5提供了有关数据集的概述，介绍了数据集的概述，详细介绍了各种样本量，输入属性尺寸和输出类尺寸。对于数据预处理，使用Min-Max归一化方法将所有功能归一化为[0, 0, 1]范围。

为了准确估算概括性能，实验中采用了十倍越差验证。此方法将数据集随机分为十个相等的子集，其中9个用于训练，每次用于测试。所有实验结果的平均值是在30个独立运行中计算的。

表6展示了所提出算法中使用的关键参数值和比较参数值，包括人口大小 NP ，最大拟合度评估 $max FEs$ ，最大隐藏节点数量以及参与最佳投票的NN的数字。在提出的算法中要结合的NN都是SLFN。分别由 n 和 m 表示的输入和输出层中的节点数量由数据集中的功能和类确定。由于MMDE在确定其最佳价值方面的适应能力，因此手动设置隐藏神经元的数量并不是强制性的，但必须考虑尺寸的显著增加，而随后计算成本的上升则随着 L 的增长而增长。因此，在这项研究中，我们为所有参与算法指定了隐藏神经元 $L = 5$ 的最大数量，以确保公平竞争。此外，为了维持比较中所有算法的公平性，每种算法最多提供20个基本NN。

表6表7中所有比较算法的关键控制参数设置

Control parameter	Value
Population size NP	100
Maximum fitness evaluations $max FEs$	13000
Maximum base NNs for NNE	20
Maximum hidden nodes L	5

该算法的实现是在硬件上使用Python 3.9进行的，其中包含AMD Ryzen 5 4600 G，Radeon图形在3.70 GHz下运行。

5.3与其他关于分类问题的算法的比较

The MMDE-ELM-NNE algorithm has been rigorously compared with thirteen other algorithms, including variations of the MMDE and ELM frameworks such as MMDE-NN, which combines the enhanced MMDE method with a traditional SLFN, and MMDE-NNE, which creates multiple SLFNs in a single run and consolidates them into an ensemble learning framework.此外，还考虑了应用ELM算法来训练单个神经网络的ELM-NN，并且还考虑了由独立训练的ELM-NN模型组成的Elm-Nne。The comparison also encompasses well-regarded metaheuristic algorithms like the Genetic Algorithm (GA) [16, 18], Particle Swarm Optimization (PSO) [29], and Artificial Bee Colony (ABC) [27, 28], as well as cutting-edge metaheuristic training algorithms from the literature, including PSO variants such as LFPSO [17], PSOLF [24]和LPSON [48], 以及龙的算法 (DA) [36], 正弦余弦算法 (SCA) [37]和Gray Wolf Optimizer (GWO) [38]. Table 7 examines the best, average, and standard deviation of classification accuracy for MMDE-ELM-NNE and seven other algorithms, including MMDE-NN, MMDE-NNE, ELM-NN, ELM-NNE, LFPSO, PSOLF, and LPSONs, across thirteen datasets, while Table 8 focuses on the same metrics for MMDE-ELM-NNE and six well-regarded跨九个数据集的元启发式算法，包括GA, PSO和ABC, DA, SCA和GWO。在这两个表中，优越的结果都以粗体突出显示。

为了确定统计学意义，这些算法在所有数据集上的性能进行了严格的评估[13]。该测试基于排名，比较了各种数据集的多种算法的性能，以识别显著差异。分类准确性的平均排名结果，包括最佳和平均值，对于十四个算法，详细介绍了

表7比较八种算法的性能：MMDE-ELM-NNE, MMDE-NN, MMDE-NNE, ELM-NN, ELM-NNE, ELM-NNE, LFPSO, PSOLF, LPSONS f, 在测试准确性方面(%)的13个基准分类问题和lpsn

Dataset		MMDE-ELM-NNE	MMDE-NN	MMDE-NNE	ELM-NN	ELM-NNE	PSOLF	LFPSO	LPSONS
Heart	Best	100.00	92.59	92.59	88.89	92.59	83.14	87.64	85.39
	Mean	83.46	81.98	70.74	74.07	82.72	80.24	82.58	81.12
	Std	8.06	8.79	14.27	9.73	6.18	1.83	3.48	2.64
Pima	Best	84.21	68.42	73.68	85.53	81.58	78.23	76.95	78.26
	Mean	77.11	65.13	65.26	72.54	72.68	73.69	67.33	74.26
	Std	4.23	2.89	7.67	5.83	4.23	4.12	7.51	3.90
Wine	Best	100.00	82.35	88.24	100.00	100.00	98.11	98.11	100.00
	Mean	98.04	57.25	55.88	83.73	97.25	93.77	94.13	95.09
	Std	2.82	19.04	18.59	10.09	4.01	4.27	3.46	3.28
Balance	Best	96.77	93.55	90.32	90.32	95.16	90.90	90.37	91.44
	Mean	89.89	85.27	78.66	80.86	87.96	88.83	87.16	88.83
	Std	2.57	4.06	8.58	8.99	3.71	1.73	2.32	2.00
Iris	Best	100.00	80.00	93.33	100.00	100.00	97.77	100.00	100.00
	Mean	96.89	60.00	60.00	85.78	90.00	91.55	97.11	97.55
	Std	5.63	11.07	14.75	10.61	8.35	7.01	2.98	2.86
Seeds	Best	100.00	95.24	95.24	100.00	100.00	100.00	98.33	100.00
	Mean	96.51	71.27	67.62	91.43	92.86	94.16	92.50	92.50
	Std	3.52	14.87	18.90	7.12	5.83	3.45	3.26	4.79
Breast	Best	100.00	98.55	98.55	98.55	100.00	97.56	97.07	97.56
	Mean	96.71	95.41	82.32	93.96	96.14	95.90	95.90	96.48
	Std	2.15	2.85	12.57	3.30	1.76	1.16	0.76	0.72
Haberman	Best	90.00	86.67	83.33	86.67	83.33	78.26	78.26	80.43
	Mean	74.78	73.33	73.00	72.56	73.89	73.47	73.60	75.00
	Std	7.02	9.71	6.15	7.04	6.50	3.70	4.55	2.51
Blood	Best	86.49	82.43	85.14	85.14	83.78	79.91	82.14	81.25
	Mean	78.02	76.08	76.49	77.07	76.80	77.13	77.46	77.99
	Std	4.18	3.69	5.22	6.70	4.14	2.48	3.39	2.44
Australian	Best	94.20	89.86	89.86	88.41	91.30	89.85	88.88	89.85
	Mean	85.80	82.37	74.88	77.63	85.36	86.04	86.23	86.35
	Std	4.36	5.22	13.24	7.90	3.72	2.63	1.84	2.23
Liver	Best	79.41	73.53	70.59	73.53	73.53	73.23	70.58	73.53
	Mean	69.71	58.53	58.24	60.00	62.16	64.69	65.39	66.38
	Std	5.36	10.05	7.78	8.30	7.56	4.48	6.47	4.50
Hepatitis	Best	100.00	100.00	100.00	93.33	100.00	91.17	85.29	91.18
	Mean	86.44	80.00	79.33	80.00	79.33	79.13	79.11	79.41
	Std	9.51	10.93	13.03	5.25	10.55	8.01	4.26	3.99
Diabetic	Best	75.65	66.09	66.96	66.96	69.57	70.43	67.95	70.92
	Mean	69.74	61.65	58.41	57.65	60.90	63.92	60.78	63.83
	Std	3.22	3.21	4.92	5.29	4.84	2.33	4.02	2.21

表9, 10。与其他算法相比, 排名值较低的高度绩效。

从两个表7、8中, 很明显, 与其他算法相比, MMD E-Elmnne始终达到多个数据集的最高测试精度。表9, 10表示MMDE-ELM-NNE首先排名

最佳和平均准确性的术语。同时, 表7突出了MMDE-ELM-NNE在13个数据集上的10个基于平均精度的优势。关于最佳准确性, MMDE-ELM-NNE在每个数据集上的所有其他算法都优于所有其他算法, 在13个数据集上的6个数据集上有6个最大分类精度为100%。在运行时, 包括

表8比较七种算法的性能：MMDE-ELM-NNE, GA, PSO, ABC, DA, SCA, SCA, GWO, 在九个基准分类问题上都在测试准确性方面(%)

Dataset		MMDE-ELM-NNE	GA	PSO	ABC	DA	SCA	GWO
Heart	Best	100.00	85.87	85.87	86.96	90.22	86.96	88.04
	Mean	83.46	83.19	80.40	83.19	82.43	81.88	83.99
	Std	8.06	2.40	2.65	2.61	3.31	2.54	2.19
Pima	Best	84.21	77.10	79.39	77.48	79.01	78.63	78.24
	Mean	77.11	74.11	73.12	73.16	75.22	73.66	76.58
	Std	4.23	2.16	2.45	2.76	1.81	2.22	0.79
Wine	Best	100.00	95.46	84.85	89.39	92.42	90.91	100.00
	Mean	98.04	89.39	75.96	75.35	83.38	81.67	95.00
	Std	2.82	4.54	5.23	7.00	5.58	4.81	2.82
Iris	Best	100.00	98.04	92.16	98.04	98.04	92.16	98.04
	Mean	96.89	86.93	70.98	90.07	88.30	77.97	85.49
	Std	5.63	7.32	10.32	5.98	7.90	9.87	11.18
Seeds	Best	100.00	93.06	90.28	93.06	93.06	91.67	91.67
	Mean	96.51	90.37	78.80	82.08	88.47	82.78	90.42
	Std	3.52	1.86	7.57	7.09	2.63	4.62	1.17
Breast	Best	100.00	97.90	97.90	97.90	98.32	98.32	98.32
	Mean	96.71	97.10	96.75	96.48	97.09	96.74	97.13
	Std	2.15	0.56	0.72	0.68	0.59	0.86	0.43
Haberman	Best	90.00	75.24	74.29	78.1	75.24	75.24	74.29
	Mean	74.78	72.76	72.38	73.68	73.05	72.76	72.83
	Std	7.02	0.96	0.94	2.08	0.97	1.02	0.70
Australian	Best	94.20	88.16	85.53	85.96	87.28	87.72	84.65
	Mean	85.80	83.77	82.50	82.35	83.99	83.52	83.07
	Std	4.36	1.73	1.95	2.20	1.172	2.04	1.04
Liver	Best	79.41	76.27	74.58	75.42	77.97	74.58	77.12
	Mean	69.71	67.71	65.79	63.33	70.20	66.44	72.94
	Std	5.36	4.55	4.49	5.37	3.84	4.84	2.75

表9八种算法的平均排名：MMDE-ELM-NNE, MMDE-NN, MMDE-NNE, ELM-NN, ELM-NNE, ELM-NNE, LFPSO, PSOLF和LPSOLS和LPSOLS和LPSONS的最佳准确性

Algorithm	Best	Mean
MMDE-ELM-NNE	1.65	1.46
MMDE-NN	5.12	6.08
MMDE-NNE	5.35	7.46
ELM-NN	4.15	6.19
ELM-NNE	2.96	4.04
PSOLF	5.85	4.00
LFPSO	6.31	4.23
LPSONS	4.62	2.54

MMDE框架中的ELM sion显着减少了所需的时间。MMDE-ELM-NNE的平均运行时间是所有数据集中MMDE-NNE的平均运行时间。这种实质性的减少归因于ELM的非著作性，这可以更快地训练基础神经网络。

表10七种算法的平均排名：MMDE-Elm-NNE, GA, PSO, ABC, DA, SCA, GWO, GWO和平均精度

Algorithm	Best	Mean
MMDE-ELM-NNE	1.06	1.89
GA	4.33	3.56
PSO	6.00	6.33
ABC	4.56	5.28
DA	3.17	3.22
SCA	4.67	5.17
GWO	4.22	2.56

如表9、10中报道的弗里德曼测试，跨算法的性能明显差异。对于表9中的平均精度，测试统计量为60.43，p值为 1.24×10^{-10} ；为了获得最佳准确性，测试统计量为39.61，p值为 1.49×10^{-6} 。在表10中，平均准确性测试统计量为30.56，p值为 3.07×10^{-5} ，为了获得最佳准确性，测试统计量为29.46




图2 MMDE-ELM-NNE获得的每个数据集的NNE平均数量（数据集：1-心，2- PIMA，3-葡萄酒，4-平衡，4-平衡，5- iris，6-种子，6-种子，7-乳房，8-乳房，8- Haberman，8- Haberman，8- Haberman，9-血液，9-血液，10-澳大利亚，11-澳大利亚，11- liver，12-二世，13-二世，13-二世，13-二世，13-二世）

p值为 4.97×10^{-5} 。在0.05的显著性水平上，算法中均等等级的零假设被拒绝，表示统计上显著的性能差异。

此外，已经观察到，MMDE-NN优于MMDE-NNE，而ELM-NN与Elm-NNE相比在测试准确性方面比Elm-NNE相比表现不佳。该观察结果表明，NN的简单聚合而没有考虑其多样性，并且特定的任务可能并不总是有利的，可能会阻碍其NNE方法的生成能力。

相比之下，MMDE-ELM-NNE凭借其增强的启发式聚类方法有效地保留了多样性及其档案选择策略，以自适应地选择最佳的NNS进行结合，并显示出巨大的希望。

5.4 MMDE-ELM-NNE的进一步分析

在本小节中，对mmde-elm-nne的全面分析是

通过旨在探索影响模型性能的因素进行的其他实验进行的，包括基本NN的数量，隐藏的神经元，人口大小，最大世代和增强症状方法的效果。

5.4.1研究基本NN和隐藏神经元的数量

图2证明了MMDE-ELM-NNE在13个数据集中获得的NNE基础NN的平均数量。由于存档选择方案，MMDE-ELM-NNE实现的NNE基本NNS数量的变化是显而易见的。该方案调整了基于数据集的最佳解决方案的数量




图3 MMDE-ELM-NNE获得的每个数据集的隐藏神经元的平均数量（数据集：1-心，2-心，2- PIMA，3-葡萄酒，4-平衡，5-虹膜，5-虹膜，6-种子，7-乳腺癌，8- HABERMAN，8- HABERMAN，8- HABERMAN，9-血液，9-血液，10-澳大利亚，10-澳大利亚人，11-肝脏，12-肝炎，13-二世二世，13-二世纪，13-二世纪）

特征是不适当数量的NNS的关键方面可能会损害整体的整体效率。数量过多的NN可以引入冗余，而不足的数字可能会限制合奏的概括能力。例如，与MMDE-NNE和MMDE-NNE和Elm-NNE相比，MMDE-ELM-NNE比较葡萄酒或肝炎等数据集时，使用固定的NN尺寸为20，但它比每个数据集上的这些竞争对手NNE都胜过20个。该性能可以归因于MMDE-ELM-NNE和ELM的优质结构的强大mul-timodal优化能力。

图3显示了所有数据集中MMDE-ELM-NNE中隐藏神经元的平均数量。每个数据集自适应地采用不同数量的隐藏神经元，展示了模型根据问题复杂性自定义NN结构的能力。对于所有数据集，所有网络的隐藏神经元少于5个，与其他算法相比，计数较低。这证明了MMDE-ELM-NNE的优势，因为它具有较不复杂的网络结构，可以达到更高的能力。

5.4.2人口规模和最大世代数量的影响

人口大小NP在EA中充当关键的超参数，显著影响了它们的收敛性和效率。为了研究人口大小对MMDE-ELM-NNE平均准确性的影响，在六个基准数据集对30次迭代进行了30次迭代的实验，并保持了与前实验设置的一致性。该实验旨在通过测试各种人口大小（25、50、75、100、150、200、300）来评估人口大小对MMDE-ELM-NNE的影响。图4说明了六个基准数据集的平均分类精度随着人口大小的不同而变化。结果表明表现




图4 MMDE-ELM-NNE获得的六个数据集的平均分类精度，人口不同

MMDE-ELM-NNE在不同人口规模的情况下保持相对稳定。每个数据集上的平均分类精度没有显示不同人口大小的显著性波动。因此，为了进行公平的比较，人口大小为100，适合所有实验。

5.4.3改进的启发式聚类方法的效果

表11比较了原始聚类方法[22]的效果和跨各种维度的改进聚类方法。为了普遍性，我们考虑目标维度 $n = 2, 10, 20, 200, 1000$ ，具有初始的population size为100。目标的下限和上边界设置为 $\vec{t}_{min} = [0, 0, 0]$ 和 $\vec{t}_{max} = [1, 1, \dots, 1]$ 。对于20个独立运行，重复随机初始化和聚类过程。在平均这些试验的结果之后，我们评估了三个方案：副本的数量，最大的亚人群的大小以及最大亚群规模与整个人口规模的比率。应该注意的是，最大的亚种群的比例不仅是（最大的亚群尺寸）/NP，因为在聚类后删除了小于4个个体的亚群。

在对表11的详细检查后，出现了几种趋势和关键发现。在这两种方法中，我们都观察到

随着维度的增加，亚种群数量的趋势减少了最大亚群的大小和比例的趋势。这表明，在高维数据中，最大的亚群可能包含更多数据点，这可能是由于稀疏的数据分布所致，导致更多数据点被分配给了同一亚群。值得注意的是，在三种评估方案方面，改进的聚类方法在所有维度上表现出更一致的性能。该方法有效地区分了高维数据中的亚群，从而导致较少占主导地位 and 均匀分配的亚群，从而准确地捕获了数据分布特征。

5.4.4计算复杂性分析

在元素性EAS的背景下，材料评估和差异测量是积分组成部分。为了简单起见，我们假设这两个过程具有恒定的时间复杂性，称为 $O(1)$ 。现在，我们深入研究了每一代MMDE的关键组件的计算复杂性分析。重要的是要注意，在进化过程中，亚群的大小和亚群的数量可能会发生变化。为了解释这种可变性，我们在计算中使用他们的预期值。特异地，预期的亚群的大小由NP表示。算法2中描述的改进的启发式聚类方法需要 $O(NP^2)$ 计算距离指标的计算工作，即 d_{inter} 和 d_{intra} 。在涉及辅助运动和存档方法的算法3中，最密集的步骤是计算亚群的半径，该过程也具有 $O(NP^2)$ 的复杂性。算法4在存档中添加了解决方案，具有 $O(NP)$ 的复杂性。理想情况下，最需要计算的组件具有 $O(NP^2)$ 的复杂性。因此，MMDE的总体计算复合度为 $O(NP^2)$ ，与在大多数Niching EAS中观察到的复杂性保持一致。

表11比较 n在[22]中原始聚类方法的效果与改进之间

Dimension Method		D聚类方法				
		2	10	20	200	1000
Original clustering	Number of subpopulations	7.6	2.55	1.75	1.45	1.25
	Size of the largest subpopulation	26.95	43.1	48.25	48.9	49.4
	Proportion of the largest subpopulation (%)	36.50	81.03	93.56	95.87	98.01
Improved clustering	Number of subpopulations	11.45	10.75	11.55	10.5	8.7
	Size of the largest subpopulation	14.3	13.55	14.05	17.35	20.6
	Proportion of the largest subpopulation (%)	15.04	17.07	17.71	23.61	31.02

6 结论

这项工作开发了一种创新的神经网络集合方法（MMD E-ELM-NNE），以同时优化多个ELM模型的结构和权重。增强的MMDE与ELM结合使用，优化了网络结构和连接参数，从而为NNE提供了多个紧凑的基础NN，从而提高了概括性。

为了验证所提出的MMDE对Mul-timodal优化问题的有效性，对二十个多模式优化问题进行了实验，并与现有的11个现有多模式优化算法进行了组合。实验结果显示了MMDE的有效性。此外，一些实验评估了mmde-elm-nne的典型和有效性，证明了其优于当前十三个分类数据集的当前元神经算法。弗里德曼（Friedman）对其测试的准确性测试验证了所有算法之间差异的统计学意义，并且几种灵敏度分析均可验证所提出算法的有效性。总体而言，实验结果表明，MMDE-ELM-NNE以高分类精度实现竞争性能。

未来的研究方向包括探索SLFN的稀疏结构和NNS的深层体系结构。另外，研究多模式多物镜优化算法在求解高维数据上的策略问题方面的组合有望有望进一步发展领域的进步。

补充信息在线版本包含<https://doi.org/10.1007/s12293-025-025-004-61-7>的供应材料。

作者贡献了作者对本文的每个部分也同样贡献。

资助这项工作的部分得到了Shaanxi省的自然科学基金计划（Grant. 2022JM-372和2022JQ-670）和中国国家自然科学基金会（Grant. 61966030, 62276202, 授予62276202, 以及62106186）。

数据可用性根据合理的请求可从通讯作者提供支持本研究的发现的数据。

声明

作者的利益冲突宣称，关于本文的发表没有互动的冲突。

从研究中包括的所有参与者那里获得了知情同意同意。

参考

1. AhmadiMA, Zendeboudi S, Lohi A等人（2013）通过神经网络与混合遗传算法和粒子群优化相结合的神经网络的储层能力预测。 *Geophys Prospect* 61（3）：582–5982. Albadra Maa, Ti una S（2017）极限学习机器：评论。 *Int J Appl Res* 12（14）：4610–46233. AlmeidaLM, Ludermer TB（2010）一种多目标模因和混合方法，用于优化人工神经网络的参数和实现。 *神经计算* 73（7–9）：1438–1450 4. Asuncion A, Newman D（2007）UCI机器学习存储库。可用：<http://www.ics.uci.edu/mllearn.mlrepositoryhtml5>. BiswasS, Kundu S, Das S（2014）通过本地信息共享诱导差异性进化。 *IEEE Trans Evol Comput* 19（2）：246–2636. BrestJ, Greiner S, Boskovic B等（2006）差异进化中的自适应控制参数：关于数字基准问题的比较研究。 *IEEE Trans Evol Comput* 10（6）：646–6577. ChenH, Yao X（2010）基于正则化负相关学习的多目标神经网络集合。 *IEEE Trans Knowl Data Eng* 22（12）：1738–17518. DaY, Xiurun G（2005）用类似的退火技术改进了基于PSO的ANN。 *神经计算* 63：527–533 9. IEEE Trans Magn 42（4）：1203–120610. DonateJP, Li X, SánchezGG等人（2013）通过以遗传算法，差异性进化和分布算法估计的人工神经网络来预测时间序列。 *Neural Comput Appl* 22：11–2011. 上级MG, Li X, Burke EK（2013）用于多模式优化的动态存档差分进化算法。在：2013年IEEE进化计算大会。 *IEEE*, pp 79–86 12. *Int J Mach学习Cybern* 10（10）：2901–2920 13. FriedmanM（1939）校正：使用等级以避免在方差分析中隐含的正态性假设。 *J Am Stat Soccep* 34：10914. GaoW, Yen GG, Liu S（2013）一种基于群集的差异发展，具有自适应策略以进行多峰优化。 *IEEE Trans Cybern.* 44（8）：1314–132715. Gi onisA, Indyk P, Motwani R（1999）通过哈希在高维度中的相似性搜索。在：第25届大型数据基础国际会议论文集。 Morgan Kaufmann Publishers Inc., 旧金山, 第518–529页。16. Golbergde（1989）搜索，优化和机器学习中的遗传算法。 Addison Wesley 1989（102）：3617. Hakl i H, u ˘Guz H（2014）一种新型的粒子群优化算法算法。 *应用软计算* 23：333–345. <https://doi.org/10.1016/j.asoc.2014.06.03418>. HollandJH（1992）自然和人工系统的适应：一项介绍性分析，应用于生物学，控制和人工智能。麻省理工学院出版社，剑桥19. HuangGB, Zhu QY, Siew CK（2004）Extreme Learning Machine：Feedforward神经网络的新学习方案。在：2004年IEEE国际神经网络联合会议（IEEECAT. N o.04CH37541），IEEE, 第985–990页20. HuangGB, Chen L, Siew CK等（2006）使用随机隐藏节点的增量构造供给网络使用增量构建馈电网络。 *IEEE跨神经NetW* 17（4）：879–892

21. HuangGB, Zhu QY, Siew CK (2006) 极限学习机器：理论和应用。神经计算70 (1-3) : 489 – 50122. HuangT, Duan DT, Gong YJ等人 (2020年) 在神经网络集中对多个基础学习者的同时优化：一种适应性的恶化差异进化方法。神经计算396 : 24 – 38. <https://doi.org/10.1016/j.neucom.2020.02.02.02023>. HuiS, Suganthan PN (2015) 集合和基于算术重组的基于多模态优化的基于算术重组的差异性差异。IEEE Trans Cybern 46 (1) : 64 – 7424. JensiR, Jiji GW (2016) 增强的粒子群优化，征收征收的粒子群优化，以实现全局优化。应用软计算43 : 248 – 261. <https://doi.org/10.1016/j.asoc.2016.02.018> 25. Jiang Y, Zhan ZH, Tan KC等 (2023) 优化用于多态优化问题的Niche Center. IEEE Trans Cybern 53 (4) : 2544 – 2557. <https://doi.org/10.1109/tcyb.2021.3125362> 26. Jingqiao Zhang, Sanderson A (2009) Jade : 可选的外部档案库的自适应差异进化。IEEE Trans Evolut comput 13 (5) : 945 – 958. <https://doi.org/10.1109/tevc.2009.201461327> . KarabogaD, Gorkemli B, Gorkemli B, Ozturk C等人 (2014年) 一项综合调查：人工BEE BEE COLONY (ABC) ALGORITHM和应用。Artif Intell Rev 42 : 21 – 5728. KarabogaD等 (2005) 基于蜂蜜蜜蜂群的想法用于数值优化。技术报告-TR06, Erciyes大学, 工程学院, 计算机29. KennedyJ, Eberhart R (1995) 粒子群优化。在：ICNN '95国际神经网络会议的进程, IEEE, 第1942-1948年第30页。KingmaDP (2014) Adam : Adam : 一种随机优化的方法。Arxiv预印型ARXIV : 1412.698031. LiJY, Chow TW, Yu YL (1995) 高阶进料神经网络中隐藏单元数量的估计理论和优化算法。在：ICNN '95-神经网络国际会议论文集, IEEE, 第1229 – 1233页32. LiX (2005) 使用多模式功能优化的物种形成的差异进化。在：第七届遗传和进化计算年度会议论文集, 第873 – 880页。LiX, Engelbrecht A, Empitropakis MG (2013) CEC '2013的基准功能以及针对多态功能优化的NICHING方法进行的CEC '2013特殊会议和竞争。RMIT大学, 进化计算和机器学习组, 澳大利亚, 技术报告34. LiuJ, Lampinen J (2005) 模糊自适应差异进化算法。软计算9 : 448 – 46235. Mengshoel OJ, Goldberg de (2008) 遗传算法中元素的拥挤方法。Evol Comput 16 (3) : 315 – 354 36. Mirjalili S (2016) Dragon-fl Y算法 : 一种用于求解单目标, 离散和多目标问题的新的元元素优化技术。Neural Comput Appl 27 : 1053 – 107337. MirjaliliS (2016) SCA : 一种用于解决光学化问题的正弦余弦算法。基于知识的Sy st 96 : 120 – 13338. MirjaliliS, Hashim SZM, Sardroudi HM (2012) 使用混合粒子群优化和重力搜索算法训练馈送前进神经网络。应用数学计算机218 (22) : 11125 – 1113739. OjhaVK, Abraham A, Sná Š elV (2017) 使用多物镜的遗传编程的异质性浮动神经树的合奏。Appl Soft Comput 52 : 909 – 92440. OjhaVK, Abraham A, Sná Š elV (2017) 馈电神经网络的元启发式设计：二十年研究的评论。Eng Appl Artif Intell 60 : 97 – 11641. PérowskiA (1996) 一种清除程序作为遗传算法的一种利基方法。在：IEEE国际进化计算会议论文集, IEEE, pp 798 – 803
42. PetterssonF, Chakraborti N, SaxénH (2007) 一种基于遗传算法的多目标神经网络, 应用于嘈杂的爆炸炉数据。Appl Soft Comput 7 (1) : 387 – 39743. Qin AK, Huang VL, Suganthan PN (2008) 差异进化算法具有适应全局数值优化的策略。IEEE Trans Evol Comput 13 (2) : 398 – 417 44. IEEE Trans Evol Comput 16 (5) : 601 – 61445. ShengM, Chen S, Liu W等 (2022) 一种具有自适应邻域突变的差异进化, 并局部搜索多模式优化。神经计算489 : 309 – 32246. StornR, Price K (1996) 最大程度地减少了ICEC '96竞赛的实际功能。在：IEEE国际进化计算会议论文集, IEEE, pp 842 – 84447. StornR, Price K (1997) 差异进化 - 简单而有效的启发式启发式对全球优化的持续空间优化。J Global Optim 11 : 341 – 35948. TarkhanehO, Shen H (2019) 使用混合粒子群的培训, 培训用于数据分类的前馈神经网络, MantegnaLévy-lévy-flim-floign and neighbournoop and search。Heliyon 5 (4) : E01275. <https://doi.org/10.1016/j.heliyon.2019.E0127549>. ThomsenR (2004) 使用基于拥挤的基于差异的差异进化的多模式优化。在：2004年进化计算大会 (IEEECAT. 04 TH8753), IEEE, pp 1382 – 1389 50. TieLeman T (2012年) 6.5-RMSProp : Aivide梯度以其最近的平均值的平均值。Coursera神经网络Mach学习4 (2) : 2651. WangX, Huang Y (2011) 在扩展的Kalman Filter基于重复的神经网络的培训中的融合研究。IEEE TRANS NEU-NETW 22 (4) : 588 – 60052. WangZJ, Zhan ZH, Lin Y等人 (2019) 自动构成差异性进化, 具有用于多模式优化问题的轮廓预测方法。IEEE Trans Evol Comput 24 (1) : 114 – 12853. WangZJ, Zhou YR, Zhang J (2020) 自适应估计分布分布分布分布差分进化, 用于多峰优化问题。IEEE Trans Cybern 52 (7) : 6059 – 607054. WangZJ, Zhan ZH, Li Y等人 (2023) 适应性和基于距离的局部搜索, 具有自适应差异进化, 用于多模式优化问题。IEEE Trans Emper Top Comput Intell 7 (3) : 684 – 699. <https://doi.org/10.1109/tetci.2023.323457555>. Wei Z, Gao W, Gao W, Li G等 (2022) 多模式优化的基于惩罚的基于惩罚的差异进化。IEEE Trans Cybern 52 (7) : 6024 – 6033. <https://doi.org/10.1109/tcyb.2021.3117359> 56. Yang Q, Chen WN, Yu Z等人 (2016) 自适应多模式连续蚂蚁菌落优化。IEEE Trans Evol Comput 21 (2) : 191 – 205 57. 在：国际随机算法研讨会。施普林格, 柏林, 第169-178页。58. YinX, Gernay N (1993) 使用共享方案的快速遗传算法, 使用聚类分析方法在多模式函数优化中。在：人工神经网络和遗传算法：奥地利因斯布鲁克国际会议的研究。神经计算69 (7-9) : 825 – 837 60. Zhang J, Morris AJ (1998) 一种sin- gle隐藏层神经网络的顺序学习方法。Neural Netw 11 (1) : 65 – 8061. ZhangJ, Chen D, Yang Q等 (2023) 基于近距离排名的多模式差异进化。Swarm Evol Comput 78 : 101277 62. IEEE Trans Evol Comput 21 (3) : 347 – 362

63. IEEE Trans Evol Comput 24 (2) : 335 – 349 64. IEEE Trans Cybern 50 (7) : 3343 – 3357

出版商的注释Springer自然在已发表的地图和机构之后的法律要求方面仍然保持中立。

Springer Nature或其许可人（例如，社会或其他合作伙伴）根据与作者或其他权利归属人的出版协议享有本文的独家权利；本文接受的手稿版本的作者自我构造仅受此类出版协议和适用法律的条款的约束。