



与混合古典量子卷积神经网络的图像denoising

Xioochang He¹ · lihua gong¹ · nanrun zhou¹

收到：2024年10月1日 /接受：2025年4月22日©作者，根据Springer-verlag GmbH德国的独家许可， Springer Nature 2025

抽象的

由于电子设备故障等因素，可以在图像采集过程中引入噪音，从而使DeNosing对于增强图像质量和解释性至关重要。但是，当训练数据受到限制时，现有的降级神经网络通常会与概括相比，导致次优性能。为了应对这些挑战，提出了一种新型的量子降级卷积神经网络（QDNCNN），以增强图像剥夺有效性。这种方法在输入经典卷积网络之前集成了量子电路，以从量子空间中的嘈杂图像中提取特征。然后将处理后的图像作为卷积神经网络的输入渲染，显着改善了降解性能。量子层使网络能够在更高维的特征空间中有效提取和表示图像信息，在保留更详细的图像详细信息的同时捕获更多的声音，从而增强噪声的鲁棒性。此外，引入了量子参数化的卷积层以对图像数据进行局部转换，从而促进了更多有效的特征提取。实验结果表明，QDNCNN优于SET12，BSD68和MNIST数据集中的传统网络。在现实世界数据集SET12和BSD68下，QDNCNN的性能与常规深度学习方法相当，而在MNIST数据集中，它将结构相似性指数提高了11.4%，峰信号与噪声比率提高了7.6%。QDNCNN具有适用于未来量子计算设备的图像deno算法的巨大潜力。

关键字卷积NE

ural网络·图像denoising ·量子机学习·

量子计算

1简介

图像噪声通常是由于收购过程中传感器缺陷引起的，或在压缩和传输过程中引入的图像噪声必然会降低图像质量[1-3]。更重要的是，噪声干扰关键图像信息将进一步降低后续处理任务的准确性[4]。在数字图像中，通常以亮度，强度或颜色的随机爆发而发出的噪声可能会严重降低视觉质量。因此，作为关键的预处理步骤，图像denoising旨在抑制噪音，增强图像

质量，并保证后续任务的执行[5, 6]。图像处理对于最终的数字图像分析至关重要，包括获取，表示，处理和降解[7]。随着数字技术和人工智能的兴起，图像DeNosing对科学研究产生了深远的影响，特别是在医学成像[8]，遥感[9]和自动驾驶[10]中。像非本地手段（非本地手段）这样的经典图像deno算法可以消除噪音，并通过限制像素相似性来有效地保留细节[11]。K-SVD方法擅长纹理保存，该方法可以通过冗余词典意识到更详细的噪声[12]。

✉ Lihua Gong
lhgong@sues.edu.cn

Xiaochang He
M320122404@sues.edu.cn

Nanrun Zhou
nrzhou@sues.edu.cn

¹ School of Electronic and Electrical Engineering, Shanghai University of Engineering Science, Shanghai 201620, China

机器学习对于随着大数据的迅速发展而对数据分析和自动化变得越来越重要。机器学习的目的是识别数据集中的模式并构建预测模型以及用于后续任务的分析工具[13]。现代的机器学习算法很大程度上强调了他们通过自适应学习的自动决策能力，并减少对人类干预的依赖[14]。最近，机器的关键分支

学习,即深度学习,尤其是卷积神经网络(CNN),在图像处理方面取得了巨大的成功[15]。由于其有效的特征提取,CNN被广泛用于图像DeNoising [16]等各种任务中。DeNoising卷积神经网络(DNCNN)用多层卷积网络有效地模拟噪声[17]。Chen等。引入了一个基于变压器的图像Denoising模型,以通过将多尺度功能与上下文信息集成[18],从而进一步提高性能。随着深度学习模型的深度的增长,模型训练的困难将相应增加。为了在训练过程中加速转化并优化性能,Tian等人。提出了基于残余学习,扩张卷积和批准化的增强的卷积神经剥离工作的网络工作[19]。同时,诸如变压器体系结构和生成对抗网络之类的新兴技术继续推进图像denoising [20, 21]。

由于量子计算的优势[22-25],量子机器学习已迅速发展。通过叠加和纠缠,量子系统在测量过程中产生概率结果,可以大大加快高维数据处理[26-30]。Xia等。提出了具有较高计算效率的量子增强数据分类网络[31]。量子机器学习在计算中显示了独特的优势-例如,图像处理和大数据分析,同时在解决复杂的数据驱动问题(例如图像denoising and Classification)方面面临挑战。Huang等。提出了一种图像加密方法,以保护混合量子古典CNN中的数据隐私,而不会增加复杂性或牺牲模型的认可[32]。Konar等。引入了混合经典的Quantum尖峰馈电神经网络,该网络通过将量子计算与经典的尖峰神经网络整合在一起,从而增强了嘈杂环境中图像分类的鲁棒性[33]。格兰特等。验证了分层量子分类器的有效性及其对分类和量子数据进行分类的能力[34]。Hassan等。设计了一个医疗量子CNN,以在医学MNIST数据集下的生物形象分类中实现可接受的性能[35]。Senokosov等。开发了两个混合量子神经网络模型,以通过引入较少参数的量子备用层来提高多个数据集的图像分类效率[36]。West等。提出了反射等值的量子神经网络,以提高分类准确性和训练效率[37]。Li等。构建了一种用量子进化的量子CNN优化方法,该方法有效地降低了量子电路的复杂性并提高了分类性能[38]。

图像DeNoising是计算机视觉领域的一项基本任务,旨在恢复嘈杂的观察结果清洁图像。最近,许多基于学习的图像

表1基于SOTA深度学习的图像去核方法的比较

Method	Core techniques	Advantages	Disadvantages
DnCNN	Deep CNNs	Simple architecture, stable training	Sensitive to high noise levels
FFDNet	Multi-scale residual networks	Flexible for varying noise levels, high efficiency	Limited performance on extreme noise conditions
Noise2Void	Self-supervised learning	No demand on clean training data, adaptable	Complex training process, reliant on data quality
RIDNet	Residual dense networks	High performance across multiple noise levels	Computationally intensive
MIRNet	Multi-scale information reconstruction Networks	Offers superior reconstruction quality and effectively handles complex noise	Higher memory consumption

已经提出了剥离方法。为了提供综合比较,我们总结了表1中的几种最先进(SOTA)图像denoising方法。

从表1中可以明显看出,尽管现有的方法在图像降级任务中取得了显着的结果,但仍然存在一些局限性。例如,尽管DNCNN提供了一个简单的架构和稳定的培训过程,但在处理高噪声水平时,它的性能不足。FFDNET [39]在处理不同的噪声水平和较高的计算效率方面表现出了灵活性,但是在极端噪声条件下的性能仍然可以提高。Noise2Void [40]不需要干净的训练数据,并且具有强大的适应性;但是,它涉及复杂的培训过程,并在很大程度上取决于数据质量。此外,Ridnet [41]和Mirnet [42]分别在多个噪声水平和出色的重建质量上表现出卓越的性能,但是它们受到高计算复杂性和实质性记忆消耗的阻碍。

受这些限制的激励,提出了一种新型的图像Denois方法,它是通过将多尺度功能提取与轻量级网络体系结构相结合,旨在保持较高的DENOSO绩效,同时降低合成资源要求。

现有的图像denoising方法,尤其是古典中枢神经系统,在平衡计算效率和降解性能方面经常面临挑战,并且在DeNoising过程中他们无法充分保留图像细节。在本文中,一个新的量子降低了concolu-

提出了量子神经网络（QDNCNN）以增强图像降解。一个量子卷积层，其中包括具有经典卷积层相似功能的四个量子滤波器中的标准DNCNN体系结构。该层通过将局部转换应用于输入数据来生成特征地图。量子过滤器的独特方面是，它们从带量子电路的空间局部数据子集中提取特征。通过使用参数化的量子电路进行特征提取，QDNCNN模型可以将输入数据提升到高维空间，并提高表示，准确性和有效性。该模型需要很少的Qubits，因此非常适合当前嘈杂的中间尺度量子（NISQ）设备，并且可以处理不同类型的图像噪声。

这项工作的主要贡献是三倍。首先，我们通过将量子卷积层纳入标准DNCNN体系结构来开发QDNCNN模型。该量子层由四个量子过滤器组成，每个量子滤波器通过量子电路在输入数据上进行局部变换，从而增强了特征提取并降低了有效的噪声。其次，我们设计了针对电流噪声中间尺度量子（NISQ）设备量身定制的参数化量子电路（PQC）。这种插入能够抑制各种形式的图像噪声，同时保持高图像质量，从而使当代量子硬件可行。最后，与经典的CNN相比，QDNCNN模型在Handling复杂的噪声场景中表现出了卓越的性能，从而获得了更高的精度和更少的计算资源来保存最终图像细节。

本文的其余部分如下：拟议的QDNCNN的档案详细介绍了Sec. 2。在SEC中引入了图像denoising的实验设置。3。QDNCNN模型的降解性能在SEC中进行了评估。4。最后，在第二节中得出了一个简洁的结论。5。

2 建议的方法

所提出的新型QDNCNN主要由4位量子卷积块（QBCB），非线性激活层，多特征提取和正常ization层（FENL），图像输出卷积层以及deNOO的前向传播层（DFPL）组成。QDNCNN的出色降解性能归因于QBCB，FENL和DFPL组件。QBCB利用量子卷积来捕获多尺度特征图，这有助于Fenl有效从嘈杂的图像中提取更多的噪声。DFPL有选择地专注于学习嘈杂的图像，使QDNCNN能够进一步捕获其他噪声细节，并更好地保留原始的噪声特征。学习噪声后，

该网络从嘈杂的图像中减去预测的噪声，以产生变性的输出。

2.1 网络体系结构

2.1.1 量子卷积神经网络

量子卷积神经网络在图像降解中的应用由于能够捕获增强的特征表示在量子空间中的能力而引起了显着的关注，这极大地有助于该过程。我们提出了一种最佳利用量子CNN，我们提出了一种方法，可以使用4位量子卷积层，以从嘈杂图像的 2×2 区域中从每个像素中提取特征，从而产生四个具有增强噪声特征的 14×14 噪声图。该策略使我们的QDNCNN可以更有效地从嘈杂的图像中提取噪声，同时更好地保留原始图像细节，从而为Neural网络做准备以完成denoising任务。

2.1.2 残余学习机制

近年来，剩余的学习在图像处理任务（例如图像降解和图像检测）中获得了显着的流行性。由于通常在嘈杂图像的像素上分布噪音，因此我们采用了一种残留的学习方法，在该方法中，网络直接学习噪音而不是原始图像。该策略通过专注于学习噪音本身，进一步改善了降解性能。

2.2 QDNCNN带有quanvolutional层

如图1所示，对解决图像降解问题的混合量子方法进行了详细说明，该方法与量子卷积层和经典的神经网络相结合。还将QDNCNN与其经典的对应物，DNCNN进行了比较。

2.2.1 Quanvolutional层

如图1所示，Quanvolutional层的灵感来自经典的卷积层，但结合了量子的原理以实现增强的特征提取。在经典的卷积层中，大小 $n \times n$ 像素的内核在输入图像上滑动，从而产生了较低的分辨率外部图像。但是，在quanvolutional层的情况下，其内核是由涉及 n_q Qubits的量子电路实现的。量子电路可以分解为三个不同的组件：经典到量子数据编码，变化门和量子测量。这些

Ponents协作以确定内核对输入图像的影响。

有许多将经典数据编码为量子状态的方法。在这种方法中，我们利用角度嵌入技术。嵌入角度从其初始状态 $|0\rangle$ 旋转，这是通过围绕y轴围绕y轴在bloch球体上的单位旋转操作旋转的，其中旋转角 ϕ 由相应像素的值确定。特别是对于经典图像像素值 x_i ，相应的量子状态 $|\psi_i\rangle$ 被编码为

$$|\psi_i\rangle = R_y(\varphi_i)|0\rangle = \cos\frac{\varphi_i}{2}|0\rangle + \sin\frac{\varphi_i}{2}|1\rangle \quad (1)$$

其中 $\varphi_i = \alpha x_i$ 和 α 是一个缩放因素。在通过 R_y 编码经典数据为量子状态后，这些量子状态经历了由变量门定义的单一转换。

Quantvolutional层的变分部分通常包括任意的单品旋转和受控的NOT (CNOT) 门。这些门的排列取决于特定的配置。量子电路中的一级人员通过一组变异的参数进行了参数，这些变量在神经网络的训练过程中进行了优化。训练的目的在于提取这些参数，以发现最大化从量子内核输出中提取的信息的测量基础。该测量涉及计算每条电线任意操作员的期望值以获得经典输出。

对于大小 2×2 的Quantvolutional内核，量子电路由四个Qubits组成。该电路将输入图像转换为四个较小的图像，每个图像代表一个不同的图像通道，有希望的多维特征提取。因此，量化层可以通过量子操作来增强图像表示，从而确保在图像DeNoising (例如DeNoising) 等任务期间更强大的特征提取和噪声弹性。

2.2.2 Quantvolutional层

本节提供了QDNCNN架构的详细描述，如图1所示。最初，经典数据是在每个量子上使用单位旋转 $R_y(\varphi)$ 的角度嵌入技术编码的。之后，我们的变异电路由四个单量旋转组成，通过可训练的权重参数和三个CNOT门进行了参数。在电路结束时，我们测量了每个量子的Pauli-Z运算符 (σ_z) 的期望值。每个通道对应于 14×14 像素图像。之后，四个输出通道被扭转并馈入卷积神经网络层。

2.3 网络设计

如图1(a)所示，QDNCNN包括一个具有四个 2×2 量子过滤器的卷积层，然后是具有三个部分的类神经网络。经典网络由一个具有恢复活化层的初始卷积层组成，中间部分具有18个卷积层，9批归一层层和9个辍学层，以及一个最终的截面，由1个卷积层组成，由1个跨化的汇合层和卷积层组成。量子卷积层涉及一个编码层，一个参数量子电路和测量层。带有多量子滤波器的量子电路从输入数据和输出中提取特征具有图。然后，通过DNCNN网络处理这些地图，以实现更多有效的图像降级。在这项研究中，在所有QDNCNN实例中的编码和测量技术保持一致。

量子卷积过滤器中经典数据的转换过程包括以下步骤：

(1) 处理输入数据：Quantvolutional滤波器从数据集中毫无疑问地提取图像的空间局部小节，将大小 2×2 的矩阵 A_x 定义为矩阵 $A_{x \times 2}$ 。

(2) 编码嘈杂的图像数据：有多种方法将 x 作为量子电路的初始状态进行编码。对于每个Quantvolutional的过滤器，将经典图像数据编码为带有Hadamard Gate的量子数据，并且编码的初始状态将其定义为 $i_x = e(A_x)$ 。(3) 配置量子电路：量子电路初始化为状态 i_x ，并根据关系 $n_x = q(i_x) = q(e(a_x))$ 根据关系映射到quantum电路 n_{x0} 。

(4) 测量后解码数据：有几种方法可以解码 n_x 的信息。为了确保Quantvolutional滤波器的输出与标准经典的卷发一致，最终解码状态定义为 $f_x = d(n_x) = d(q(e(a_x)))$ ，其中 d

●) 是解码函数，而 f_x 是与图像像素数据一致的标量值。

(5) 描述quantvolutional：总体而言，可以将 $d(q(e(a_x)))$ 的变形形式定义为 x 的quantvolutional变换，即， $f_x = Q(a_x, e, q, m)$ 。图1(b)可视化Quantvolutional变换过程，说明编码，用量子电路计算和解码。

根据上述过程，根据算法1所示，基于杂种量子CNN的图像降级算法的伪代码是基于杂种量子CNN的。

2.4 Quantvolutional过滤器设计

在当前的NISQ设备中，量子数据编码是将经典数据转换为量子状态以进行后续量子处理的本质。但是，在当前条件下，资源和量子所需的时间





图1 (a) 带有量子网络和DnCNN的QDNCNN。量子网络将输入数据转换为四个特征地图，然后再将其传递到DnCNN。(b) 将经典数据转换为Quanvolutional过滤器中的量子电路的过程，然后是随后的输出

算法1基于杂种量子CNN的DeNoising算法


要求：清洁图像补丁 $\{x_1, x_2, \dots, x_n\}$ ，噪声级 σ ，Qubits N 的数量，训练时期 n ，批处理大小 B ，学习率 η ，DnCNN模型参数集 θ 。确保：优化模型参数集 θ 。

- 1：量子预处理：2：加载干净的图像补丁 $\{x_1, x_2, x_3, x_4\}$ 。用 σ 保存添加高斯噪声，以生成嘈杂的补丁 $\{y_1, y_2, y_3, y_4\}$ 。
- 3：对于每个补丁 y ：做4：将补丁分为 2×2 个块。
- 5：对于每个块，用 N Qubits 提取量子功能 z_i 的量子电路 q_θ 对其进行处理。
- 6：结束7：保存 $\{y_i, z_i\}$ 进行培训。
- 8：初始化DnCNN模型：9：构建具有输入通道的17层DnCNN 4 (1噪声通道+4量子通道)。
- 10：初始化模型参数集 θ 。
- 11：训练环：12： $t = 1$ 时至 T 做13：shuf fl e训练数据 $\{x_i, y_i, z_i\}$ 。
- 14：结束15：对于大小 B 的每个批次 $\{x_b, y_b, z_b\}$ do 16：形式输入 $I_b = \text{condenate}(y_b, z_b)$ 。
- 17：预测DENOIST IMAGE $\hat{x}_b = \text{DnCNN}_\theta(I_b)$ 。
- 18：计算损失： $L = \frac{1}{B} \sum (\hat{x}_b - x_b)^2$ 。
- 19：更新 $\theta : \theta \leftarrow \theta - \eta \nabla_\theta L$ 。
- 20：结束21：保存结果：22：保存优化的模型参数集 θ 。
- 23：节省量子功能和嘈杂的补丁，以供进一步使用。
- 24：带有优化参数集 θ 的返回训练型模型。


数据编码在汇总复杂性下迅速随数据大小的增加而增加。因此，有效的量子数据编码方法对于管理增加的大规模数据至关重要。适当选择和设计最佳量子填充过滤器对于利用图像处理范围的量子计算的才能，例如图像 denoising 具有重要意义。这些过滤器应通过利用量子等级主义来处理图像并提取有效的特征。但是，量子电路的选择直接决定了量子机器学习算法的性能。为了充分利用量子计算，研究了各种量子数据编码方法。在连续的网络优化和设计改进之后，我们的模型可以实现显著的降级性能。如图2所示，(a) 代表设计的QDNCNN circuit，而 (b) 至 (e) 是进行比较的电路。这些用于卷积操作的量子电路在确定QDNCNN的性能中起着关键作用。如图1 (b) 所示，这些电路被整合到Quanvolution层中。量子卷积电路的设计应考虑数据转换效率以及编码量子数据的完整性和准确性。正确设计的电路使最佳的量子计算可以大大提高图像降解的有效性和速度。此外，不同的量子电路结构可能会影响脱氧的结果。因此，必须比较各种量子电流电路的降解性能。




(a) QDnCNN 1 Circuit




(b) QDnCNN 2 Circuit



(c) QDnCNN 3 Circuit



(d) QDnCNN 4 Circuit



(e) QDnCNN 5 Circuit

图2量子电路。 (一个)设计的量子网络, (b)至(e)对应于量子netwo

RKS在[43-46]中设计

2.5 损失功能

Adam用于最大程度地减少 ℓ 损失功能，即

$$\ell(\Theta) = \frac{1}{2K} \sum_{i=1}^N \|R(y_i; \Theta) - (y_i - x_i)\|_F^2 \quad (2)$$

其中 Θ 是我们QDNCNN的可训练参数集，而 $2N$ 是清洁图像对的数量。另外， y_i 分别是 i -嘈杂的映像和 i -th t ht tht tht tht。为了增强在脱氧过程中的边缘保存，我们将拉普拉斯损失纳入训练目标中。Laplacian损失通过比较DeNoSied输出 I_{output} 和地面真相 I_{target} 的Laplacian梯度来监督模型保留边缘信息的能力。它被定义为

$$L_{\text{Laplacian}} = \frac{1}{K} \sum_{i=1}^N \|\nabla^2 I_{\text{output}}(i) - \nabla^2 I_{\text{target}}(i)\|^2 \quad (3)$$

其中 $\nabla^2 I$ 是捕获二阶空间衍生物的拉普拉斯运算符。通过最大程度地减少这一损失，该模型可以有效地保留边缘细节，同时改善整体deNo的性能。

2.6 绩效评估

为了评估所提出的QDNCNN的性能，将其时间复杂性和资源消耗与多层perceptron (MLP) [47]，条件量子量子电路发生器 (CQCBM) [48]，量子电路发生器 (QCBM) [QCBM] [49]以及条件量子发生器 (条件量子Qubits (Auxil Qubits) 进行了比较。结果汇编在表2中。

使用经典MLP生成 N 维数据的时间复杂性是近似 $O(N^2)$ ，而QCBM量子电路的运行时间与量子数的数量线性缩放（不包括量子状态制备和测量的头顶）。与不受欢迎的QCBM相比，CQCBM通过合并条件信息来增强模型可控性，从而使其能够与特定条件相对应的数据分布。但是，CQCBM只能在不同的量子初始状态下产生目标分布，并且随着条件信息的增加而不能很好地扩展。

相反，AQ-CQCBM和QDNCNN都以促进可伸缩性的方式编码了连接信息。假设目标分布的维度为 N ，分为 d 类，并使用一个量子进行编码一个经典信息，则AQ-CQCBM需要 $N \times d$ Qubits，而建议的QDNCNN方案仅需要 N Qubits N Qubits。这个优势变得更加重要 -

随着条件信息的数量，ICANT会增加，从而大大减少了对量子资源的需求。AQ-CQCBM具有较高的Qubits，具有更大的表现力和纠缠能力，使其更适合生成高度复杂的数据分布。相反，QDNCNN在处理更简单的数据分布中具有更多条件信息，尤其是在有限的量子资源下。

3 个实验

本节首先概述培训和测试数据集并详细介绍实验设置。进行实验以评估QDNCNN在公开可用的合成和现实世界图像数据集上的降解有效性。然后将QDNCNN的降解性能与现有方法进行比较。最后，进行了一项消融研究，以检查QDNCNN中量子成分的分配。

3.1 培训和测试数据集

QDNCNN DENOISIC模型在MNIST数据集并肩作用的Grayscale Train400数据集[17]。为了进行性能评估，采用了三个灰度测试集：MNIST [51]，SET12 [17]和BSD68 [17]。通常，将MNIST数据集分为3,000个培训样本和500个测试样品。

3.2 实验细节

在这项研究中，将量子预处理与17层DNCNN模型集成在一起，以增强图像变形。尺寸 $28 \times 28 \times 1$ 的输入图像被分割为 2×2 个补丁，并通过量子电路与RY，RZ和CNOT盖茨进行处理，生成 $14 \times 14 \times 4$ 的量子特征，然后创建了一个图像。5通道输入。DNCNN体系结构由15个Hidden卷积层组成，每个卷积层具有34个滤波器，具有 3×3 内核大小，然后进行批处理归一化和relu Activation，以及一个产生残留噪声的输出层。培训采用了SumSquaredError损耗函数和ADAM优化器，初始学习率为 1×10^{-3} ，批次大小为128，并结合了 $\sigma = 15, 25, 25, 50$ 的标准偏差，以模拟噪声。实验是在运行Ubuntu的Linux Sys-Tem 20.04上，配备了NVIDIA 3070 GPU，使用Python 3.9作为编程环境。表3显示了实验设置和网络超参数。

表2时间复杂性

Algorithm	Time complexity	Quantum resource consumption
MLP	$O(N^2)$	/
QCBM	$O(N)$	N
CQCBM	$O(N)$	N
AQ-QCBM	$O(N)$	$N + d$
QDnCNN	$O(N)$	N

表3实验设置和网络超参数

Component/Hyperparameter	Version/Value
Operating system	Ubuntu 20.04
Processor	Intel(R) Core(TM) i7-12700H CPU @ 2.30 GHz
Memory	16.0 GB
Python	3.9
Pytorch	1.1.13
PennyLane	0.14.1
Numpy	1.21.2
Noise level (σ)	1, 25, 50
Quantum qubits (N)	4
Training epochs	180
Batch size	128
Learning rate	0.001
Learning rate decay	0.2
Decay milestones	[30, 60, 90]
Quantum feature size	$14 \times 14 \times 4$
CNN layers	17
Hidden filters	64
Kernel size	33

3.3对灰色合成噪声图像的比较

为了评估我们的QDNCNN在灰度合成噪声图像和灰度盲合成噪声图像上的性能，我们将其与set12和BSD68在噪声级别 $\sigma = 15, 25$ 的几种代表性的denoising方法[52-59]进行了比较。表4和5的合成图像的剥夺表明，我们的QDNCNN实现了在标准合作模拟下接近或超过其他最先进方法的PSNR和SSIM值。从PSNR方面，QDNCNN在set12数据集中的第二好的rddcnn ($\sigma = 25$) 相比，QDNCNN提高了0.13 dB，而在BSD68数据集中，在最近提议的MWDCNN ($\sigma = 50$) 中，QDNCNN提高了0.13 dB。此外，图3和图4证明了QDNCNN产生的deno的图像表现出较高的视觉质量。此外，如图2和图所示。5和6，我们的MSDNET在有效消除噪声并保持更清晰的细节方面优于所有其他比较方法。

这些有希望的脱氧结果证实了我们QDNCNN在处理灰度合成图像denoising中的上等。这种增强的性能归因于混合网络设计，该设计将量子神经网络（QNN）与DNCNN集成在一起，从而使模型能够有效地捕获更广泛的噪声范围，同时保留了较大的图像详细信息。

表6列出了SET12和BSD68数据集下提出的QDNCNN的性能评估，利用视觉信息保真度（VIF）和特征相似性（FOM）指标以及相应的测试时间[60-63]。VIF是一个度量标准，可以通过将图像与原始图像进行比较，从而量化图像恢复的感知质量和限制，从而量化这些图像中保留的视觉信息量。另一方面，FOM根据特征表示，衡量了DeNo的图像与地面真相之间的相似性，从而提供了对模型在denoising过程中维持结构完整性的能力的见解。

表6中的结果表明，QDNCNN在两个set12上都达到了上优于VIF和FOM得分

s e v e n e s s o n e r e d h i w 2 l e s n o s d o h e m g n s o n e d i n e r r d r o s i u e r M S S B d R N S P e g a v A 4 e b a r	N N C D Q	3	7	0
		5	1	3
		0	6	8
		9	8	7
		0	0	0
		/	5	8
		/	9	3
		/	2	7
		/	0	2
		/	3	2
N N C D R	N N C D R	3	9	9
		4	9	8
		0	6	7
		9	8	7
		0	0	0
		/	5	3
		/	8	2
		/	4	7
		/	0	2
		/	3	2
N N C E	N N C E	9	5	6
		3	9	7
		0	6	7
		9	8	7
		0	0	0
		/	1	5
		/	8	1
		/	2	7
		/	0	2
		/	3	2
N N C R	N N C R	3	8	0
		3	8	6
		0	6	7
		9	8	7
		0	0	0
		/	6	2
		/	7	1
		/	3	7
		/	0	7
		/	3	2
N N C D	N N C D	3	8	2
		4	9	7
		0	6	7
		9	8	7
		0	0	0
		/	6	7
		/	8	1
		/	2	7
		/	0	7
		/	3	2
L L P E	L L P E	1	3	1
		9	0	9
		8	6	5
		8	8	7
		0	0	0
		/	5	5
		/	1	4
		/	2	6
		/	9	6
		/	3	2
M N N W	M N N W	8	3	0
		1	6	4
		0	6	7
		9	8	7
		0	0	0
		/	0	5
		/	7	0
		/	2	7
		/	0	2
		/	3	2
D 3 M B	D 3 M B	2	1	2
		0	3	7
		0	6	7
		9	8	7
		0	0	0
		/	7	2
		/	8	7
		/	3	9
		/	2	6
		/	3	2
s d o h e M	s d o h e M	5	5	0
		1	2	5
		=	=	=
		=	=	=
		=	=	=
		=	=	=
		=	=	=
		=	=	=
		=	=	=
		=	=	=

s e v e n e s s o n e r e d h i w 2 l e s n o s d o h e m g n s o n e d i n e r r d r o s i u e r M S S B d R N S P e g a v A 4 e b a r	N N C D Q	1	6	6
		2	3	1
		8	2	2
		8	8	7
		0	0	0
		/	1	8
		/	8	3
		/	1	3
		/	9	6
		/	2	2
N N C D W M	N N C D W M	9	5	9
		1	2	9
		8	2	1
		8	8	7
		0	0	0
		/	0	0
		/	7	5
		/	2	2
		/	9	6
		/	3	2
N N C D R	N N C D R	1	8	5
		1	2	7
		8	8	1
		0	0	0
		/	0	0
		/	6	3
		/	7	0
		/	2	3
		/	9	6
		/	3	2
N N C D R B	N N C D R B	7	0	5
		1	3	0
		8	2	2
		8	8	7
		0	0	0
		/	9	6
		/	0	3
		/	7	2
		/	2	6
		/	3	2
N N C E	N N C E	8	8	7
		0	1	6
		8	2	1
		8	8	7
		0	0	0
		/	1	3
		/	2	2
		/	9	6
		/	3	2
		/	2	2
N N C R	N N C R	7	9	1
		9	9	5
		7	1	1
		8	8	7
		0	0	0
		/	4	9
		/	6	1
		/	1	6
		/	9	6
		/	3	2
N N C D S B	N N C D S B	8	5	2
		0	1	6
		8	2	1
		8	8	7
		0	0	0
		/	3	4
		/	3	2
		/	7	2
		/	1	6
		/	3	2
L L P E	L L P E	0	3	5
		6	2	7
		7	1	9
		8	8	6
		0	0	0
		/	2	3
		/	2	7
		/	7	7
		/	1	5
		/	3	2
M N N W	M N N W	3	3	1
		4	1	3
		7	1	0
		8	8	7
		0	0	0
		/	5	7
		/	3	8
		/	1	5
		/	8	5
		/	3	2
D 3 M B	D 3 M B	4	2	0
		0	5	3
		7	0	9
		8	8	6
		0	0	0
		/	7	2
		/	8	5
		/	0	6
		/	1	5
		/	3	2
s d o h e M	s d o h e M	5	5	0
		1	2	5
		=	=	=
		=	=	=
		=	=	=
		=	=	=
		=	=	=
		=	=	=
		=	=	=
		=	=	=

和BSD68数据集。这表明QDNCNN有效地消除了噪声，而与存在的DeNoising方法相比，可以更好地保留基本的视觉信息和结构细节。此外，QDNCNN的记录测试时间突出了其计算效率，使其适用于实时应用程序，并且具有约束的计算资源。这些发现的依据统称为QDNCNN在各种数据集和噪声条件下增强图像质量方面的有效性和实用性，从而强调了其在图像处理任务中广泛应用的潜力。

在MNIST数据集中评估并比较了提出的QDNCNN模型的降解性能。最初，比较了QDNCNN和DNCNN模型的训练损失和脱氧效率。随后，分析了两种模型在各种噪声条件下的降解性能。最后，通过修改PQC电路来证明设计量子网络的优越图像降级能力来进行消融实验。

在MNIST数据集中的图像中添加了噪声。为了比较DNCNN和QDNCNN产生的原始样品之间的差异，SSIM和峰信噪比（PSNR）以评估图像质量。SSIM的范围从0（最差）到1（最佳），用于评估脱氧效果。图7（a）所示的训练损失表明，QDNCNN在收敛速度和损耗值方面优于DNCNN。在图7（b）和（c）中，SSIM和PSNR中的曲线超过250个时期，表明QDNCNN在训练过程中始终优于SSIM中的DNCNN，并且实现了更高的最佳SSIM值。在测试数据集中，具有自定义设计的量子电路的QDNCNN模型的平均SSIM为0.8654，PSNR的平均SSIM为19.652，而DNCNN的平均SSIM为0.7768，其PSNR为18.263。QDNCNN模型在SSIM中提高了11.4%的改善，而PSNR比DNCNN提高了7.6%。这些结果表明，QDNCNN同意表现出优于DNCNN的脱氧性能。

图8可视化量子网络处理后的结果。当QDNCNN处理嘈杂的MNIST图像时，它们首先通过量子电路。 28×28 图像分为四个 14×14 张图像，每个图像捕获不同的噪声特征。图8（b）显示了由神经网络产生的原始图像，嘈杂的图像和噪声图像。尽管几乎无法识别的原始图像的噪音水平很高，但带有QDNCNN和DNCNN的DeNO图像中的噪音已成功削弱，并且检索了不同原始图像的外观。但是，DNCNN的降解能力受到挑战，因为其生成的图像仍然显示出与原始图的显著差异，例如，数字7和0的形状以及Digit 2的不连续性

突出这些差异。这些差异增强了QDNCNN模型的优越性，该模型优于经典DNCNN模型。

为了进一步证明所提出的QDNCNN模型的有效性，在KMNIST数据集中获得了更多结果。当QDNCNN处理噪声系数为0.5的KMNIST图像时，量子电路可以更精确地提取特征，显着提高脱氧质量。从图9可以看出，QDNCNN比经典DNCNN始终如一地恢复原始图像结构。例如，QDNCNN可以更好地保存KMnist特征的复杂笔触和边缘细节。然而，DNCNN仍然在某些形状上挣扎，尤其是在更复杂的KMNIST角色上，在这些字符中，可见残留的噪音和轻微的扭曲。

从验证数据集中，由QDNCNN产生的DeNOCORCET图像达到了0.8145的SSIM，PSNR的SSIM为17.635，而DNCNN的SSIM产生的ssim则产生了0.7628的DeNOIST图像，PSNR为16.106。与DNCNN相比，QDNCNN模型的SSIM提高了6.8%，PSNR提高了9.4%。这些观察结果进一步强调了QDNCNN的优势，因为从KMNIST数据集中处理复杂图像时，它可以始终如一地产生更清晰，更准确的Deno图像，从而明显超过了类别DNCNN模型。

3.4 QDNCNN和DNCNN的培训

进行了一项消融研究，以检查QNN对QDNCNN的脱氧性能的影响。因此，通过单独修改QDNCNN中的QNN组件来开发六个QDNCNN变体，即QDNCNN 1-6。MNIST数据集这六个变量的降解结果表明，不同的QNN配置有助于QDNCNN的降解性能。此外，结果表明，所提出的QNN胜过其他变体，如图10所示。根据图2所示的量子电路在图2中所示的量子电路进行了评估：4 QUBITS：4 QUBITS，4 QUBITS，噪声强度为0.5，无噪声情况和MNist数据集。如图10所示，使用替代量子电路的混合QDNCNN网络比QDNCNN模型1所表现出的效率较低。仅QDNCNN模型2实现了与设计的QDNCNN模型1可比的脱糖性结果，而QDNCNN模型1的表现较差，而与tumn的表现差异很差。这些发现验证了设计的量子网络的优越性，并强调了为图像DeNoising任务选择适当的量子电路的至关重要性。此外，qdnc-的降解能力



图3从set12的灰色图像上的视觉变质结果 $\sigma = 15$ ：原始图像，b噪声图像，c bm3d，d wnm，e epll，f dncnn，G ircnn，h ecndnet，i rddcnn，j qdncnn




图4来自BSD68的灰色图像的视觉降解结果 $\sigma = 15$ ：原始图像，b噪声图像，c bm3d，d wnm，e epll，f dncnn，G ircnn，h ecndnet，i brdnet，j rddcnn，k mwdcnn，l qdncnn




图5从set12的灰色图像上的视觉降解结果 $\sigma = 25$ ：原始图像，b噪声图像，c dncnn，d ecndnet，e rddcnn，f QDNCNN






图6在 $\sigma = 25$ 的BSD68的灰色图像上的视觉降解结果：原始图像，b噪声图像，c dncnn，d ecndnet，e rddcnn，f QDNCNN

表6 set12和BSD68数据集上QDNCNN的deo绩效评估


Dataset	Noise parameters	PSNR(dB)	SSIM	VIF	FOM	Average time (s)
Set12	$\sigma = 15$	32.95	0.9053	0.9276	20.2576	0.0339
	$\sigma = 25$	30.57	0.8617	0.8658	18.8493	0.0336
	$\sigma = 50$	27.38	0.7830	0.7559	17.4478	0.0410
BSD68	$\sigma = 15$	31.81	0.8821	0.8610	20.3070	0.0306
	$\sigma = 25$	29.32	0.8236	0.7672	18.7409	0.0419
	$\sigma = 50$	26.38	0.7216	0.6032	16.6614	0.0432



(a)




(b)




(c)

图7 (a) QDNCNN和DNCNN之间训练损失的比较。QDNCNN的收敛速度更快。(b)和(c)分别在250个QDNCNN和DNCNN的SSIM和PSNR值分别变化




(a)



(b)

图8 (a) 量子处理后的MNIST图像，通过四个通道输出的处理图像进入馈电神经网络。(b) QDNCNN和DNCNN的降噪结果

图9 qdncnn和dncnn在knnist上的结果



具有不同参数化量子电路的NN在不同的噪声条件下有所不同。尽管随着噪声强度的增加，降低的表现下降，但设计的量子网络始终胜过其他量子，在较高的噪声下表现出最小的性能降解。因此，基于设计的量子电路的混合量子网络保持较高的稳定性。

4结论

引入了一种新型的混合量子denoising算法，即Quanto d eNoising卷积神经网络，以解决传统图像降解方法的局限性。通过利用量子计算中固有的并行性和经典卷积神经网络的局部特征提取能力，QDNCNN显着提高了图像剥落任务的效率和性能。QDNCNN的关键创新是

合并量子卷积层，该量子层在量子空间中处理数据以从嘈杂图像中提取深度特征。这种量子增强的特征推断使QDNCNN在复杂的噪声条件下脱氧图像中表现出色。此外，量子电路与经典神经网络架构的无缝集成使QDNCNN能够在当前嘈杂的中间尺度量子设备上有效地运行，从而减少了Qubits，并且可以降低Qubits和有限的量子资源。在包括MNIST，SET12和BSD68在内的多个数据集上进行了全面的实验，以揭示QDNCNN在各种噪声条件下的鲁棒性和出色的脱索能力。与经典的DNCNN相比，QDNCNN表现出训练损失的显着改善，SSIM和PSNR。通常，在MNIST数据集下，QDNCNN的SSIM提高了11.4%，PSNR增长了7.6%。此外，对SET12和BSD68的实验QDNCNN的出色denoising绩效和




图10 (a) 比较不同量子网络的训练损失, QDNCNN 1显示出更快, 更稳定的收敛性。 (b) 和 (c) 在250个QDNCNN 1和其他量子网络模型的250个训练时期的SSIM和PSNR值的变化

计算效率, 使其在实际应用中具有很高的竞争力。该研究还探索了不同参数化量子电路对使用QDNCNN的DE NOIS性能的影响, 突出了最佳量子电路设计在增强模型性能中的关键作用。测试了各种参数化的量子电路, 表明所选的量子电路档位显著影响QDNCNN的降解效果。尽管取得了这些进步, 在扩展到更大且更复杂的数据集时, 诸如QDNCNN之类的混合量子网络会面临挑战。随着Qubits数量的增加, 网络复杂性的提高并降低了计算速度。未来的研究将着重于优化网络结构, 以押注现实世界嘈杂的情况, 并探索量子计算与经典网络的创新集成。开发轻量子神经网络对于确保与NISQ设备的兼容性并增强其在不同现实世界中的适用性至关重要。总体而言, QDNCNN代表了将量子计算与经典深度学习技术集成用于图像DeNoising的重要进步。它有效地结合量子特征提取与经典处理的能力不仅可以提高降级性能, 还为量子增强图像处理的未来发展提供了有希望的前景。

致谢这项工作得到了中国国家自然科学基金会(第62162041号赠款), 上海科学与技术计划项目(赠款号23010501800)和江西省的顶级双重1000人才计划(赠款号JXSSQ201920101055)。

作者贡献Xioochang He: 写作原始草稿, 方法论, 正式分析和数据策展。 Lihua Gong: 写作评论与编辑, 调查, 验证和项目管理。 Nanrun Zhou: 监督, 写作评论与编辑和资金获取。

数据可用性本研究中使用的数据集可应作者的要求提供。

声明

代码可用性在GitHub存储库中公开可用: qdncnn github存储库中公开可用。

参考

1. DiwakarM, Kumar M (2018) 关于CT图像噪声及其降解的评论。生物医学信号处理和控制42: 73-88. <https://doi.org/10.1016/j.bspc.2018.01.010>
2. Yuan X, Haimi-Cohen R (2020) 基于压缩感应的图像压缩: 基于压缩感应: 与JPEG的端到端比较。IEEE多媒体交易22 (11): 2889–2904. <https://doi.org/10.1109/tmm.2020.29676463>
3. BiancoV, Memmolo P, Leo M, Montrador S, Distanto C, Paturzo M, Picart P, Javidi B, Javidi B, Ferraro P (2018) 在数字Holography中减少斑点噪声的策略。光: 科学与应用7 (1): 48. <https://doi.org/10.1038/s41377-018-0050-9>
4. Karimi D, Dou H, Dou H, Warfield SK, Gholipour A (2020) 深度学习噪音标签: 探索医学图像分析中的技术和补救措施。医疗图像分析65: 101759. <https://doi.org/10.1016/j.media.2020.101759>
5. Ilesanmi AE, Ilesanmi TO (2021) 使用卷积神经网络图像denoising的方法: 审查。复杂与智能系统7 (5): 2179–2198. <https://doi.org/10.1007/s40747-021-00428-4>
6. Shao L, Yan R, Li X, Liu X, Liu Y (2014) 从启发式优化到词典学习: 对图像denoising demoing demoing Algorithms的评论和全面比较。IEEE关于控制论的交易44 (7): 1001–1013. <https://doi.org/10.1109/tcyb.2013.2278548>
7. Goyal B, Dogra A, Agrawal S, Sohi B, Sohi B, Sharma A (2020) 图像DINOOSISCHISERCHISE评论: 从经典到先进的方法。信息融合55: 220–244. <https://doi.org/10.1016/j.inffus.2019.09.0038>
8. GengM, Meng X, Yu J, Zhu L, Jin L, Jiang Z, Qiu B, Li H, Kong H, Yuan J, Yuan J, Yang K, Shan H, Han H, Han H, Yang H, Yang Z, Ren Q, Run Q, Lu Y (2022) 内容互补的医学图像互补学习。IEEE医学成像交易41 (2): 407–419. <https://doi.org/10.1109/tmi.2021.3113365>

42. LuJ, Li N, Zhang S, Yu Z, Zheng H, Zheng B (2019) 多尺度的水下图像恢复。光学与激光技术110:105–113. doi:10.1016/j.optlastec.2018.05.048, 特刊: 极端环境的光学成像43. Gong LH, Pei JJ, Zhang TF, Zhou Nr (2024) 基于变量量子通路的量子量子互动神经网络。光学通信550:129993. <https://doi.org/10.1016/j.optcom.2023.129993>. JohriS, Debnath S, Mocherla A, Singk A, Prakash A, Kim J, Kim J, Kerenidis I (2021) 在被困的离子量子计算机上最近的质心分类。NPJ量子信息7(1):122. <https://doi.org/10.1038/s41534-021-00456-545>. KimJ, Huh J, Park DK (2023) 经典到量子卷积神经网络转移学习。神经计算555:126643. <https://doi.org/10.1016/j.neucom.2023.126643>. HurT, Kim L, Park DK (2022) 用于经典数据分类的量子卷积神经网络。量子机intel-ligence 4(1):3. <https://doi.org/10.1007/s42484-021-00061-x47>. GardnerM, Dorling S (1998) 人工神经网络(多层Perceptron) - 大气中的应用程序综述。大气环境32(14–15):2627–2636. [https://doi.org/10.1016/s1352-2310\(97\)00447-048](https://doi.org/10.1016/s1352-2310(97)00447-048). HeZ, Li L, Zheng S, Huang Z, Huang Z, Situ H (2019) 基于量子电路和经典优化的有条件的发电模型。国际理论物理学杂志58(4):1138–1149. <https://doi.org/10.1007/s10773-019-04005-x49>. Kondratyev A (2021) 具有遗传算法的量子循环机器的非差异性倾斜。威尔莫特2021(114):50–61. <https://doi.org/10.1002/wilm.1094350>. Zeng QW, Ge Hy, Gong C, Zhou Nr (2023) 基于混合量子量子式框架的条件Quantum-tum Quanth-tum Quantum course Born机器。Physica A: 统计力学及其应用618:128693. <https://doi.org/10.1016/j.physa.2023.128693>. RudolphMS, Toussaint NB, Katarawa A, Johri S, Johri S, Peropadre B, Perdomo-Ortiz A (Perdomo-tiz a (2022) 使用高分辨率的手绘量化量化量化量化的分辨率。物理评论X 12(3):031010. <https://doi.org/10.1103/physrevx.12.03101052>. Dabov K, Foi A, Foi A, Katkovnik V, Egiazarian K (2007) 图像DEN OIS-DENOIS-DENOIS-DENOIS-DENOIS-SPARSE 3-D TRONSLACT TRONSLUCT-DOMAIN-DOMAIN-DOMAIN-DOMAIN-DOMAIN-DOMAIN COLIGATINACTIANCORATION合作。图像处理的IEEE交易16(8):2080–2095. <https://doi.org/10.1109/tip.2007.90123853>. GuS, Zhang L, Zuo W, Feng X (2014) 加权核定常最小化, 并应用图像DeNoising。在: IEEE计算机视觉和模式识别会议论文集(CVPR) 54. ZoranD, Weiss Y (2011) 从自然图像贴片的学习模型到整个图像恢复。在: 2011年国际计算机愿景, 第479–486页, <https://doi.org/10.1109/iccv.2011.6126278>
55. 在: IEEE计算机视觉和模式识别会议论文集(CVPR)。CAA关于智力技术的交易4(1):17–23. <https://doi.org/10.1049/trit.2018.105457>. Zhang Q, Xiao J, Tian C, Chun-Wei Lin J, Zhang S (2023) 用于图像denois-Ing-Ing denois-Ing。CAA关于智力技术的交易8(2):331–342. <https://doi.org/10.1049/cit2.1211058>. 模式识别134:109050. <https://doi.org/10.1016/j.patcog.2022.10905059>. TianC, Xu Y, Zuo W (2020) 使用深层CNN进行批处理重新归一化的图像。神经网络121:461–473. <https://doi.org/10.1016/j.neunet.2019.08.02260>. KHMAGA (2023) 使用正则化Perona-Malik模型和脉冲耦合的神经网络工作的自然数字图像去除混合噪声。软计算27(21):15523–15532. <https://doi.org/10.1007/S00500-023-09148-Y61>. KHMAG A (2023) 基于生成对抗网络模型和半柔软阈值方法的添加性高斯噪声去除。多媒体工具和应用82(5):7757–7777. <https://doi.org/10.1007/s11042-022-13569-662>. KHMAGA, KAMARUDIN N (2019) 使用递归深度卷积神经网络(R-DBCNN)和第二代小波的自然图像去毛细血管。在: 2019年IEEE信号和图像处理应用程序国际会议(ICSIPA), 第285–290页63. KhmagA, Ramli AR, Kamarudin N (2019) 基于群集的自然图像Denosing使用Wavelet域中的字典学习方法。软计算23(17):8013–8027. <https://doi.org/10.1007/s00500-018-3438-9>

出版商的注释Springer自然在已发表的地图和机构之后的法律要求方面仍然保持中立。

Springer Nature或其许可人(例如, 社会或其他合作伙伴)根据与作者或其他权利归属人的出版协议享有本文的独家权利; 本文接受的手稿版本的作者自我构造仅受此类出版协议和适用法律的条款的约束。